

UNIVERSIDADE DE SÃO PAULO
ESCOLA DE ENGENHARIA DE SÃO CARLOS
DEPARTAMENTO DE ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

Luisa Helena Bartocci Liboni

**Diagnóstico de Falhas em Motores de
Indução Trifásicos Baseado em
Decomposição em Componentes
Ortogonais e Aprendizagem de
Máquinas**

São Carlos
2017

Luisa Helena Bartocci Liboni

**Diagnóstico de Falhas em Motores de
Indução Trifásicos Baseado em
Decomposição em Componentes
Ortogonais e Aprendizagem de
Máquinas**

Tese de doutorado apresentada à Escola de Engenharia de São Carlos da Universidade de São Paulo, como parte dos requisitos para a obtenção do título de Doutor em Ciências, Programa de Engenharia Elétrica.

Área de concentração: Sistemas Dinâmicos

Orientador: Prof. Dr. Ivan Nunes da Silva

São Carlos

2017

Trata-se da versão corrigida da tese. A versão original se encontra disponível na EESC/USP que aloja o Programa de Pós-Graduação de Engenharia Elétrica.

AUTORIZO A REPRODUÇÃO TOTAL OU PARCIAL DESTE TRABALHO,
POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO, PARA FINS
DE ESTUDO E PESQUISA, DESDE QUE CITADA A FONTE.

L696d

Liboni, Luisa Helena Bartocci
Diagnóstico de falhas em motores de indução trifásicos baseado em decomposição em componentes ortogonais e aprendizagem de máquinas / Luisa Helena Bartocci Liboni; orientador Ivan Nunes da Silva. São Carlos, 2017.

Tese (Doutorado) - Programa de Pós-Graduação em Engenharia Elétrica e Área de Concentração em Sistemas Dinâmicos -- Escola de Engenharia de São Carlos da Universidade de São Paulo, 2017.

1. Motor de indução.
2. Aprendizagem de máquinas.
3. Decomposição ortogonal.
4. Diagnóstico de falhas.
5. Redes neurais artificiais.
6. Support vector machines.
7. Extração de características.
- I. Título.

FOLHA DE JULGAMENTO

Candidata: Engenheira **LUISA HELENA BARTOCCI LIBONI**.

Título da tese: "Diagnóstico de falhas em motores de indução trifásicos baseado em decomposição em componentes ortogonais e aprendizagem de máquinas".

Data da defesa: 05/06/2017.

Comissão Julgadora:

Prof. Associado **Ivan Nunes da Silva**
(Orientador)
(Escola de Engenharia de São Carlos/EESC)

Prof. Associado **Rogério Andrade Flauzino**
(Escola de Engenharia de São Carlos/EESC)

Prof. Dr. **Edson Bim**
(Universidade Estadual de Campinas/UNICAMP)

Prof. Dr. **Eduardo Coelho Marques da Costa**
(Escola Politécnica/EP-USP)

Prof. Dr. **Marcelo Suetake**
(Universidade Federal de São Carlos/UFSCar)

Resultado:

Aprovado

Aprovado

APROVADO

Aprovado

Aprovado

Coordenador do Programa de Pós-Graduação em Engenharia Elétrica:
Prof. Associado **Luis Fernando Costa Alberto**

Presidente da Comissão de Pós-Graduação:
Prof. Associado **Luis Fernando Costa Alberto**

Dedico este trabalho aos meus pais, Lúcia e Carlos, pelo exemplo de persistência e garra frente às adversidades da vida. Dedico também, com carinho, ao meu esposo Raphael pelo constante incentivo e compreensão da importância deste trabalho e às minhas amadas irmãs Lara e Lívia que completam minha vida.

Agradecimentos

Em meio a uma tarefa tão desafiadora como esta do desenvolvimento da minha tese de doutorado, a qual exigiu-me a lógica, o pensamento analítico e o rigor matemático, deparo-me, no fim da jornada, com um momento em que posso expressar os sentimentos que me batem à porta.

Bendita seja esta seção de agradecimentos, pela oportunidade de uma pequena poesia nesta época de encerramentos. Uma pequena brecha da matemática para esta moça, que das palavras, gosta de fazer rimas emblemáticas. Que esta nostalgia possa sempre lembrar a todos que a conquista não foi só minha, e sim de todas as pessoas que ajudaram a retirar as pedras do percurso, que não fiz sozinha. Espero tentar agradecer a todos que estiveram cá, e que me apoiando, ajudaram a realizar esse sonho, um tanto quanto particular. Desculpem-me, se por entorpecimento de uma mente cansada, algum parceiro dessa jornada tenha sido esquecido. Mas sintam-se abraçados, aqueles que aqui não estiverem citados, mas, que mesmo sem nota, sabem bem a resposta...do meu coração.

Poesias à parte, me aventuro a tentar agradecer todas aquelas pessoas que, de alguma forma, contribuíram para esta realização. Digo de antemão que esta tentativa será frustrada, já que não conseguiria agradecer a todos, nem mesmo dentre o número de páginas que esta tese contém.

Dou início agradecendo à minha família. Em especial, ao meu grande companheiro, incentivador e esposo querido, Raphael. Obrigada pelo incentivo nas horas difíceis, por não me deixar desistir, por acreditar em mim, pelos elogios e críticas. Obrigada pela paciência todas as vezes em que esta tese nos privou de momentos juntos e por estar disponível para me ajudar sempre que preciso. Agradeço por me receber em seus braços, por me dar ânimo e conforto nos momentos que mais preciso. Você recobre minha mente e inspira minhas tarefas, e não tenha dúvida que esta etapa não teria sido alcançada sem você.

Agradeço aos meus pais, professores da minha vida, inspiradores da minha conduta. Obrigada por terem me aceitado como filha, com todas as minhas particularidades e dificuldades, e por terem me guiado. À minha mãe, que criou três filhas que se espelham

nela o todo tempo, acima de tudo, obrigada por ter nos mostrado o que é ser forte e persistente. Obrigada por cobrar sempre mais das suas filhas, de ser exigente e de nos encorajar a enfrentar os nossos desafios. Ao meu pai, por ser meu modelo e quem deu origem à minha antiga vontade de ser engenheira. Um dos meus orgulhos é sempre tentar segui-lo, sendo ele a pessoa que ainda quero ser “quando crescer”. A sua inteligência e resiliência são exemplos para mim. Serei sempre muito grata pela importância que deram à minha educação. Agradeço pela paciência que tiveram durante a elaboração deste trabalho, em que, por muitas vezes, nos privei de momentos juntos e obrigada a vocês pelo amor incondicional que sempre recebi.

Às minhas irmãs, Lara e Lívia, eternas amigas, meus vínculos com o passado e alicerces do meu futuro. Obrigada pelos exemplos de dedicação e paciência. Obrigada pelos momentos de distração e relaxamento, pelas risadas, pelas músicas cantadas e pelas conversas, mesmo que virtuais. Serei sempre grata pelas broncas e ensinamentos e por sempre me lembrarem que sou mais do que geralmente me considero ser. Sem vocês não seria completa, vocês mudam a minha vida para melhor a cada instante.

Ao Jacques, meu querido melhor amigo, que foi fonte de lazer e distração sempre que o cansaço chegava ao limite. Você mudou a minha vida, me trouxe alegria e motivação. À Pipi, que nunca me abandonou durante as longas horas de trabalho.

Agradeço em especial ao Professor Ivan, pela sua parceria e confiança no meu trabalho. Por ter me incentivado a sempre buscar a perfeição e ter tido paciência comigo em muitos momentos. É muito gratificante trabalhar com pessoas que são confiantes da nossa vitória e com calma alicerçam nosso crescimento. Gostaria de agradecer a todas as oportunidades que tem me dado como pesquisadora e espero que estes trabalhos reforcem ainda mais nossa amizade.

Ao professor Rogério Flauzino, que além de ter sido um amigo querido, muito me orientou neste trabalho e me inspira a todo momento, o meu muito obrigada.

Devo também agradecer ao Professor Marcelo Suetake pela ajuda na elaboração desta tese desde o seu início.

Além disso, gostaria de agradecer ao professor Alessandro Goedtel pelo incentivo e por permitir a obtenção de recursos essenciais para o desenvolvimento desta tese na Universidade Tecnológica Federal do Paraná. Este agradecimento se estende a todos os integrantes do Laboratório de Sistemas Inteligentes do campus Cornélio Procópio.

Ao professor Maurício de Oliveira, que me recebeu carinhosamente em San Diego, durante meu estágio de pesquisa nos EUA, meus sinceros agradecimentos. Sou muito grata pela paciente orientação e não consigo mensurar a importância da minha convivência com este grande pesquisador e pessoa.

Ao professor Eduardo Costa, que me auxiliou na elaboração de diversos trabalhos, obrigada pela confiança.

Aos meus colegas de Doutorado e Mestrado, Rodrigo de Toledo Caropreso, Paulo Ro-

berto Ubaldo, Marcel Ayres de Araújo, obrigada pelo incentivo e amizade. Pelas caronas e longas conversas sobre o futuro e também pelas ajudas durante o desenvolvimento desta tese.

Gostaria também de agradecer ao meu *life coach* e grande amigo Otávio Machado. Sem a sua ajuda, não teria chegado aqui, da forma como eu cheguei. Obrigada por me ensinar a ser a melhor versão de mim mesma e mudar a minha vida.

À Bruna Vanzella, que também é responsável por eu ter finalizado essa etapa da melhor maneira possível, obrigada por acreditar em mim e pelo incentivo.

À Universidade de São Paulo por disponibilizar os recursos necessários para o desenvolvimento deste trabalho.

À Escola Politécnica da Universidade de São Paulo e seus professores, principalmente do Departamento de Engenharia de Energia e Automação Elétricas, por terem tanto contribuído com minha formação técnica e pessoal. Em especial, agradeço ao professor José Roberto Cardoso, pela sua valiosa frase à época de minha formatura: “Venha para a academia” e ao professor Wilson Komatsu pelo incentivo e recomendação.

À Escola de Engenharia de São Carlos da Universidade de São Paulo, por ter me aceitado como uma de suas filhas e investido em mim. Em especial aos professores do Programa de Pós-graduação em Engenharia Elétrica pelos valiosos ensinamentos transmitidos.

Aos colegas do Instituto Federal de Educação, Ciência e Tecnologia de São Paulo campus Sertãozinho pelo incentivo à pós-graduação.

E por fim, mas nunca menos importante, agradeço à Deus, pela oportunidade da vida e por ter me dado a chance de conhecer e agradecer à todas essas pessoas.

Tenho certeza que é a convivência com essas pessoas muito especiais que me impulsiona nestas aventuras. Todo o percurso foi um grande aprendizado e um exercício de gratidão. Tenham certeza que aprendi muito, e que, nos desafios que virão, serei ainda melhor.

The triumphant vindication of bold theories - are these not the pride and justification of our life's work? (Sir Arthur Conan Doyle, The Valley of Fear, Sherlock Holmes novel)

Persistence is the shortest path to success! (Charles Chaplin)

Resumo

Liboni, Luisa. **Diagnóstico de Falhas em Motores de Indução Trifásicos Baseado em Decomposição em Componentes Ortogonais e Aprendizagem de Máquinas.** 154 p. Tese de doutorado – Escola de Engenharia de São Carlos, Universidade de São Paulo, 2017.

O objetivo principal desta tese consiste no desenvolvimento de ferramentas matemáticas e computacionais dedicadas a um sistema de diagnóstico de barras quebradas no rotor de Motores de Indução Trifásicos. O sistema proposto é baseado em um método matemático de decomposição de sinais elétricos, denominado de Decomposição em Componentes Ortogonais, e ferramentas de aprendizagem de máquinas. Como uma das principais contribuições desta pesquisa, realizou-se um aprofundamento do entendimento da técnica de Decomposição em Componentes Ortogonais e de sua aplicabilidade como ferramenta de processamento de sinais para sistemas elétricos e eletromecânicos. Redes Neurais Artificiais e *Support Vector Machines*, tanto para classificação multi-classes quanto para detecção de novidades, foram configurados para receber índices advindos do processamento de sinais elétricos de motores, e a partir deles, identificar os padrões normais e os padrões com falhas. Além disso, a severidade da falha também é diagnosticada, a qual é representada pelo número de barras quebradas no rotor. Para a avaliação da metodologia, considerou-se o acionamento de motores de indução pela tensão de alimentação da rede e por inversores de frequência, operando sob diversas condições de torque de carga. Os resultados alcançados demonstram a eficácia das ferramentas matemáticas e computacionais desenvolvidas para o sistema de diagnóstico, sendo que os índices criados se mostraram altamente correlacionados com o fenômeno da falha. Mais especificamente, foi possível criar índices monotônicos com a severidade da falha e com baixa variabilidade, demonstrando-se que as ferramentas são eficientes extractores de características.

Palavras-chave: Motor de Indução, Aprendizagem de Máquinas, Decomposição Ortogo-

nal, Diagnóstico de Falhas, Redes Neurais Artificiais, *Support Vector Machines*, Extração de Características.

Abstract

Liboni, Luisa **Fault Diagnosis in Three-Phase Induction Motors Based on Orthogonal Component Decomposition and Machine Learning.** 154 p. Ph.D. Thesis – São Carlos School of Engineering, University of São Paulo, 2017.

This doctoral thesis consists of the development of mathematical and computational tools dedicated to a diagnostic system for broken rotor bars in Three Phase Induction Motors. The proposed system is based on a mathematical method for decomposing electrical signals, named the Orthogonal Components Decomposition, and machine learning tools. As one of the main contributions of this research, an in-depth investigation of the decomposition technique and its applicability as a signal processing tool for electrical and electromechanical systems was carried-out. Artificial Neural Networks and Support Vector Machines for multi-class classification and novelty detection were configured to receive indices derived from the processing of electrical signals and then identify normal motors and faulty motors. In addition, the fault severity is also diagnosed, which is represented by the number of broken rotor bars. Experimental data was tested in order to evaluate the proposed method. Signals were obtained from induction motors operating with different torque levels and driven either directly by the grid or by frequency inverters. The results demonstrate the effectiveness of the mathematical and computational tools developed for the diagnostic system since the indices created are highly correlated with the fault phenomenon. More specifically, it was possible to create monotonic indices with the fault severity and with low variability, what supports that the solution is an efficient fault-specific feature extractor.

Keywords: Induction Machine, Machine Learning, Orthogonal Decomposition, Fault Diagnosis, Neural Networks, Support Vector Machines, Feature Extraction.

Listas de ilustrações

Figura 1	Representação das possíveis falhas em um MIT.	28
Figura 2	Representação da intersecção das áreas do conhecimento para um sistema de diagnóstico de falhas: processamento de sinais e sistemas de inferência.	30
Figura 3	Efeito da variação do número de barras quebradas na corrente elétrica de estator de MITs. Motor de 1 cv acionado diretamente pela rede. . . .	37
Figura 4	Efeito da variação do torque de carga na corrente elétrica de estator de MITs com 4bq. Motor de 1 cv acionado diretamente pela rede.	37
Figura 5	Envelope trifásico de um MIT com 4bq e torque de carga nominal. Motor de 1 cv acionado diretamente pela rede.	39
Figura 6	Relação geométrica entre uma função e sua derivada e integral para sinais puramente senoidais e não puramente senoidais.	47
Figura 7	Processo de ortogonalização das bases da decomposição.	48
Figura 8	Decomposição de sinais de tensão de fase no plano das tensões de linha. .	52
Figura 9	Tensões de fase com ruídos $v_A(t)$, $v_B(t)$ e $v_C(t)$ e projeções filtradas no plano das tensões de linha $v_a(t)$, $v_b(t)$ e $v_c(t)$	54
Figura 10	Passos da DCO para a obtenção das componentes ortogonais.	56
Figura 11	Circuito retificador com característica não linear. Pela teoria clássica de potências para sistemas senoidais, possui potência ativa e reativa. Porém, não há fluxo recíproco de energia entre fonte e carga.	58
Figura 12	Circuito simulado para compensação de reativos. Os valores apresentados na coluna (1) se referem ao circuito sem a compensação feita pelo capacitor C . Os valores da coluna (2) se referem ao circuito compensado. A tensão de alimentação é dada por $v(t) = 100 \cos(t) + \frac{100}{5} \cos(5t) + \frac{100}{7} \cos(7t)$	60

Figura 13	Circuitos compensados com elementos reativos onde $v(t) = 100\sqrt{2}(\text{sent} + \text{sen}3t)$. A potência $Q_F = 0$ para o primeiro circuito compensado e $Q_F = 8$ KVA para o segundo circuito compensado.	62
Figura 14	Circuito com compensação ativa de reativos. O circuito foi simulado e a partir de 5 segundos a chave S_1 foi fechada para a compensação.	62
Figura 15	Circuito com compensação ativa de reativos. Formas de onda da tensão $v(t)$ e corrente $i(t)$ próximas à $t = 5$ s, quando a chave S_1 é fechada.	63
Figura 16	Espectro da corrente $i(t)$ para o circuito com compensação ativa de reativos. Na esquerda está representado o espectro da corrente $i(t)$ do circuito antes da compensação. Na direita está o espectro de $i(t)$ após a compensação.	63
Figura 17	Circuito simulado para compensação de reativos. Compensação máxima é atingida pelo capacitor $C = 0,136$ F. Com $v(t) = 100\sqrt{2}\text{sent} + \frac{100}{11}\sqrt{2}\text{sen}(11t) + \frac{100}{13}\sqrt{2}\text{sen}(13t)$	67
Figura 18	Valores eficazes das componentes $i_a^p(t)$, $i_a^{q\parallel}(t)$ e $i_a^{q\perp}(t)$ obtidas pela aplicação dos dois princípios da DCO em sinais reais de um motor de 1 cv saudável até o instante 4 s e para o mesmo motor com 4bq após 4 s.	70
Figura 19	Sistema de coordenadas para modelagem trifásica e ortogonal de MITs.	72
Figura 20	Sistema de referencial ortogonal λ genérico para a modelagem de MITs.	74
Figura 21	Modelagem das malhas no rotor de gaiola de esquilo.	75
Figura 22	Modelagem das malhas no rotor de gaiola de esquilo	76
Figura 23	Corrente nas barras do rotor para 1bq (Barra 3).	77
Figura 24	Corrente nas barras do rotor para 2bq (Barra 3 e Barra 4).	78
Figura 25	Neurônio Artificial.	81
Figura 26	Ilustração da rede PMC.	85
Figura 27	Notação da rede PMC.	86
Figura 28	Contribuição do termo de <i>Momentum</i> (TM) e da taxa de aprendizagem (TA) na convergência do treinamento de redes PMC.	88
Figura 29	Representação de hiperplanos de separação de classes.	90
Figura 30	Método de confrontação binária de SVMs para três classes.	92
Figura 31	Função de decisão para vários parâmetros de uma SVM com <i>Kernel</i> Gaussiano.	94
Figura 32	Exemplo de curva de aprendizado.	96
Figura 33	Esquema geral do laboratório de ensaios de máquinas elétricas.	100
Figura 34	Excitação do enrolamento de campo do GCC.	100
Figura 35	Sensores Hall de corrente e tensão.	101
Figura 36	Procedimento para a inserção de falhas em rotores.	102
Figura 37	Fluxograma da metodologia proposta.	104

Figura 38	Sistema de Diagnóstico proposto.	106
Figura 39	Banco de dados de MITs ensaiados com barras quebradas.	108
Figura 40	Tensão da fase A de um motor de 1 cv acionado por inversor de frequência.	109
Figura 41	Tensão filtrada da fase A de um motor de 1 cv acionado por inversor de frequência.	110
Figura 42	Correntes trifásicas de um motor de 1 cv acionado por inversor de frequência.	110
Figura 43	Comparação dos efeitos de barras quebradas, no torque do motor e velocidade, para um MIT simulado com diferentes carregamentos. De 0 a 4 segundos o motor está sadio, e após 4 segundos insere-se um falha de 4bq.	112
Figura 44	Espectro de corrente da fase A do estator do motor simulado para carregamento de 8 Nm, 4bq e 2 Nm, 4bq.	113
Figura 45	Valores RMS das componentes ortogonais do motor simulado de 2 hp, 60 Hz, 4 polos, 380 V, 3.6 A e 28 barras no rotor. Em $t = 4$ s uma falha de 4bq é provocada.	114
Figura 46	Valores <i>Root Mean Square</i> (RMS) das componentes ortogonais do motor de 2-hp, 60 Hz, 4 polos, 380 V, 3.6 A e 28 barras no rotor. Em $t = 4$ s uma falha de 2bq é provocada.	115
Figura 47	Oscilação do valor eficaz da componente ortogonal $v_a^p(t)$ em diferentes torques	117
Figura 48	Correlação entre os índices R de algumas componentes ortogonais em uma janela de 3 s como função do carregamento.	119
Figura 49	Correlação entre os valores RMS medianos das componentes ortogonais em uma janela de 1 s como função do carregamento.	120
Figura 50	Valores RMS das componentes ortogonais do motor de 2 hp, 60 Hz, 4 polos, 380 V, 3.6 A e 28 barras no rotor. Em $t = 4$ s uma carga oscilante é simulada.	122
Figura 51	Tensões e correntes trifásicas do MIT normal sob carga de 4,0 Nm.	123
Figura 52	Análise espectral da tensão e corrente da fase A do MIT normal sob carga de 4 Nm.	123
Figura 53	Janela deslizante	124
Figura 54	Valores RMS das componentes de tensão ortogonais ao plano das tensões de linha. Até 4 s estão os valores reais de um motor saudável com carregamento nominal. Depois de 4 s apresentam-se os dados reais de um motor com 4bq e carregamento nominal.	125
Figura 55	Sinais RMS de motores com 4bq e motores saudáveis e seus respectivos valores R para a componente ortogonal $i_a^p(t)$	126

Figura 56	Espectro do valor RMS da componente ortogonal $i_a^{q }(t)$ para motores com 1bq, 2bq, 2x2bq e 4bq com carga nominal.	129
Figura 57	Amostras de motores normais e com falha com relação aos três primeiros atributos escolhidos pelo CFS utilizando-se o índice R e os sinais referentes a todas as fases.	130
Figura 58	Índices correlacionados com a falha - Índice 1 com monotonicidade - Índice 2 sem monotonicidade	135
Figura 59	Amostras de motores normais e com falha com relação aos três primeiros atributos escolhidos pelo CFS utilizando-se o índice R e os sinais referentes a fase A.	135
Figura 60	Curvas de aprendizagem para os detectores de novidade utilizando-se como entrada a mediana dos valores eficazes das componentes ortogonais referentes a fase A.	136
Figura 61	Tensões e correntes trifásicas do MIT normal sob carga de 4,0 Nm, acionado por inversor de frequência em 55 Hz.	137
Figura 62	Sinais RMS de motores com 4 barras quebradas e motores saudáveis em 40 Hz e 50 Hz, com carregamento nominal, para a componente ortogonal $i_a^p(t)$ sem filtragem dos sinais de corrente.	138
Figura 63	Amostras de motores normais e com falha com relação aos três primeiros atributos escolhidos pelo CFS utilizando-se o índice R e os sinais referentes a fase A.	140

Lista de tabelas

Tabela 1	Principais funções de ativação.	83
Tabela 2	Teste estatístico. ANOVA para o banco de dados com o índice R dos valores eficazes das componentes ortogonais em partida direta.	126
Tabela 3	Acurácia da classificação de motores normais e defeituosos e de severidade (1bq, 2bq, 2x2bq, 2bq) da falha para motores em partida direta utilizando-se o índice R e os sinais referentes à todas as fases.	128
Tabela 4	Acurácia da classificação de motores normais e defeituosos e de severidade da falha (1bq, 2bq, 2x2bq, 4bq) para o banco de dados de motores em partida direta utilizando-se o índice R e os sinais referentes à fase A.	131
Tabela 5	Acurácia da classificação de motores normais e defeituosos dividido em: 0 a 40% do torque nominal e 75% a 100% do torque nominal utilizando o índice R e os sinais referentes a todas as fases para motores em partida direta.	132
Tabela 6	Acurácia da classificação de motores normais e defeituosos dividido em: 0 a 40% do torque nominal e 75% a 100% do torque nominal utilizando-se o índice R e os sinais referentes a fase A para motores em partida direta.	132
Tabela 7	Acurácia da classificação de motores normais e defeituosos e de severidade da falha (1bq, 2bq, 2x2bq, 4bq) para motores em partida direta utilizando-se os valores medianos e os sinais referentes à fase A.	133
Tabela 8	Acurácia da classificação de motores normais e defeituosos em partida direta utilizando-se SVMs de uma só classe com o índice R e os sinais referentes à fase A.	134
Tabela 9	Acurácia da classificação de motores normais e defeituosos em partida direta utilizando-se SVMs de uma só classe com os valores medianos e os sinais referentes à fase A.	134

Tabela 10	Acurácia da classificação entre motores normais e defeituosos e de severidade da falha (1bq, 2bq, 2x2bq, 4bq) para motores em partida por inversor de frequência utilizando-se o índice R e os sinais referentes à fase A.	139
Tabela 11	Acurácia da classificação de motores normais e defeituosos em partida direta utilizando-se SVMs de uma só classe com o índice R e os sinais referentes à fase A.	139
Tabela 12	Teste estatístico. ANOVA para o banco de dados com valores eficazes das componentes ortogonais em partida por inversor de frequência com apenas uma fase.	140

Lista de siglas

AG Algoritmo Genético

ANOVA Análise de Variância

BEN Balanço Energético Nacional

CFS *Correlation Feature Selection*

DCO Decomposição em Componentes Ortogonais

FIR *Finite Impulse Response*

FFT *Fast Fourier Transform*

GCC Gerador de Corrente Contínua

KMD *Kusters and Moore Decomposition*

MCC Máquina de Corrente Contínua

MCSA *Motor Current Signature Analysis*

MIRGE Motor de Indução com Rotor em Gaiola de Esquilo

MIT Motor de Indução Trifásico

PMC *Perceptron Multi-Camadas*

PSO *Particle Swarm Optimazation*

RNA Rede Neural Artificial

RMS *Root Mean Square*

SIF Sistema de Inferência *Fuzzy*

SV *Support Vector*

SVM *Support Vector Machine*

WT *Wavelet Transform*

Sumário

1	Introdução	27
1.1	Motivação e Relevância do Trabalho	27
1.2	Diagnóstico de Falhas	29
1.2.1	Processamento de Sinais	30
1.2.2	Sistemas de Inferência	31
1.3	Objetivos e Contribuições	33
1.3.1	Objetivos	33
1.3.2	Contribuições	34
1.4	Organização do Trabalho	34
2	Aspectos da Falha de Barras Quebradas	35
2.1	Surgimento de Bandas Laterais no Espectro de Frequências	35
2.2	Formação de Envelope Trifásico nas Correntes	38
2.3	Modificação no Consumo de Potências	39
3	Técnica de Decomposição em Componentes Ortogonais	43
3.1	Primeiro Princípio - Decomposição de Funções Sobre o Subespaço de Outras Funções	44
3.2	Segundo Princípio - Relação Geométrica das Tensões de Linha em Sistemas Trifásicos	50
3.3	Obtendo as Componentes Ortogonais	54
3.4	Contribuições da Decomposição em Componentes Ortogonais à Teoria de Potências	55
4	Ferramentas Matemáticas e Computacionais	71
4.1	Modelagem de Assimetrias em Motores de Indução	71
4.1.1	Modelo Simétrico Clássico - dq	71
4.1.2	Modelo Assimétrico - Inserção de falha de barras quebradas	73

4.2	Mineração de Dados, Seleção de Atributos, Diminuição da Dimensionalidade e Algoritmo Recursivo Baseado em Correlação	77
4.3	Sistemas de Inferência	79
4.3.1	Análise de variância Kruskal-Wallis	80
4.3.2	Redes Neurais Artificiais	80
4.3.3	<i>Support Vector Machines</i>	88
4.3.4	Problemas de Generalização - <i>Overfitting</i>	95
4.3.5	Validação Cruzada de K partições	95
4.3.6	Curvas de Aprendizagem	96
4.4	Filtros FIR - Finite Impulse Response	97
5	Aspectos da Bancada Experimental para Ensaios de Falhas em Motores de Indução Trifásicos	99
5.1	Disposição Geral da Bancada de Experimentos	99
5.2	Inserção de Defeitos nas Barras de Rotores	102
6	Metodologia	103
6.1	Simulações Computacionais	105
6.2	Sistema de Diagnóstico	105
6.3	Ensaios de Barras Quebradas e Aspectos da aquisição de sinais	105
6.4	Inferência	108
7	Resultados e Discussões	111
7.1	Simulações Computacionais	111
7.1.1	Efeitos da falha	111
7.1.2	Criação de índices para a classificação	116
7.1.3	Distinção entre barras quebradas e cargas oscilantes	119
7.2	Ensaios Experimentais	121
7.2.1	Barras Quebradas no Rotor	121
7.2.2	Partida Direta	121
7.2.3	Partida por Inversor de Frequência	136
8	Conclusões e Diretivas Futuras	143
8.1	Conclusões	143
8.2	Trabalhos Futuros	146
8.3	Publicações	146
Referências		149

CAPÍTULO 1

Introdução

1.1 Motivação e Relevância do Trabalho

A qualidade em serviços e a excelência de produtividade são hoje um paradigma crescente na produção industrial (SANTOS; SILVA; SUETAKE, 2012; MCCOY; DOUGLASS, 2014). Com o advento de microprocessadores de alto desempenho e com o avanço da eletrônica de potência, os Motores de Indução Trifásicos (MITs) passaram a ser utilizados em todos os tipos de aplicações, inclusive aquelas de velocidade variável.

Segundo McCoy e Douglass (2014), o consumo total de energia advindo de equipamentos movidos por motores elétricos nos Estados Unidos foi de 1,431 bilhões de KWh em 2006, o que aponta para 38,4% do uso total da energia elétrica daquele país. Dentro do setor industrial norte americano, estima-se que 62,5% do total da energia elétrica seja consumida pelo uso de equipamentos movidos por motores elétricos. Já de acordo com o Balanço Energético Nacional (BEN) de 2009, cerca de 60% do consumo energético da indústria brasileira é proveniente de motores elétricos. Por fim, estima-se que sistemas movidos por motores elétricos representem entre 43% a 46% do total da energia elétrica consumida no mundo (WAIDE; BRUNNER, 2011).

Em particular, os Motores de Indução com Rotor em Gaiola de Esquilo (MIRGEs) merecem ainda maior ênfase, em função de particularidades como robustez, baixo custo e longa vida útil, sendo vantajosos do ponto de vista de construção e manutenção (FITZ-GERALD; KINGSLEY; UMANS, 2006; TOLIYAT et al., 2012).

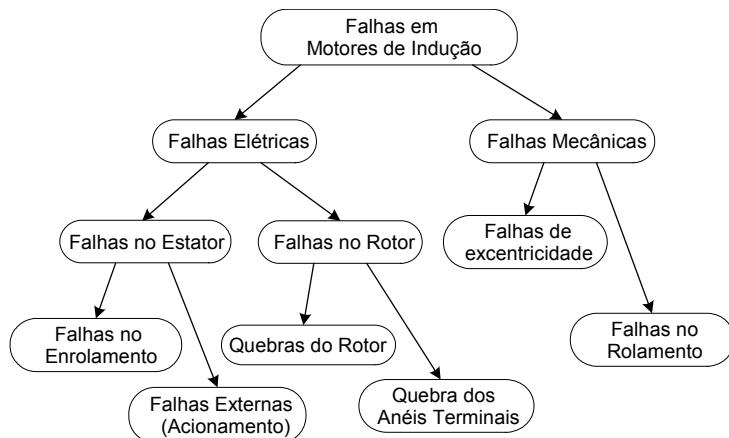
Pelo importante papel desempenhado pelos MITs na indústria, estudos de melhoria em eficiência energética, técnicas de controle mais precisas, manutenção preventiva, qualidade de energia elétrica e identificação de falhas têm sido bastante motivados e passaram a ter importância ímpar.

Na maioria das aplicações de MITs, as condições ambientais e o pouco conhecimento técnico das cargas acopladas ao eixo podem ocasionar diminuição em seu rendimento, sobreaquecimento com consequente redução em sua vida útil, má utilização da energia elétrica sob o aspecto do baixo fator de potência, defeitos mecânicos e elétricos, entre

outros. Desta forma, observa-se na literatura recente a crescente necessidade da detecção de falhas, permitindo identificação suficientemente rápida e evitando-se assim o desligamento da produção e reduzindo custos da manutenção corretiva (SANTOS, 2013; DRIF; CARDOSO, 2014; GHANBARI, 2016).

As possíveis falhas em motores de indução podem ser classificadas conforme representadas na Figura 1.

Figura 1: Representação das possíveis falhas em um MIT.



Fonte: Suetake (2012).

As falhas mecânicas podem resultar do desalinhamento do centro do eixo do rotor com o centro do estator, denominadas falhas de excentricidade, e podem causar empenamento do eixo e danos no rolamento. Geralmente são ocasionadas por montagens incorretas ou erros de fabricação. Os desgastes dos rolamentos causam comprometimento do desempenho da máquina, já que o atrito e a excentricidade comprometem o regime de trabalho (NANDI; TOLIYAT; LI, 2005; MEHRJOU et al., 2011; BINDU; THOMAS, 2014; SEERA et al., 2014).

As falhas nos enrolamentos ocorrem devido às deformidades na isolação estatórica, podendo ocasionar curto-circuito entre os enrolamentos do motor. Umidade, valores dielétricos intensos, esforços mecânicos, contaminações por óleo e folga na lamination do núcleo magnético são causas de defeitos na isolação. Essas falhas ocasionam altas correntes elétricas influenciando diretamente a condição de operação do motor e causando sua degradação já que são falhas acumulativas. (NANDI; TOLIYAT; LI, 2005; MEHRJOU et al., 2011; BINDU; THOMAS, 2014; DRIF; CARDOSO, 2014).

As falhas que ocorrem nos dispositivos de acionamento dos MITs são consideradas falhas externas e influenciam diretamente o desempenho do motor, tanto com relação ao torque do motor quanto à velocidade. As anormalidades nos acionamentos advêm de desbalanceamento de tensão, sobretensão e subtensão (SANTOS, 2013).

Por fim, problemas no rotor, na grande maioria dos casos, devem-se às quebras das barras da gaiola de esquilo. Essas quebras são consequência de vibrações excessivas, osci-

lações de torque do motor e mudanças bruscas na dinâmica de partida (NANDI; TOLIYAT; LI, 2005; MEHRJOU et al., 2011; BINDU; THOMAS, 2014; SEERA et al., 2014; GU et al., 2015; GHORBANIAN; FAIZ, 2015; COSTA; KASHIWAGI; MATHIAS, 2015). Essas falhas causam redução do tempo de serviço, diminuem o torque médio do motor e produzem vibrações. Além disso, esse tipo de falha é acumulativa e destrutiva, pois barras adjacentes também se deterioram devido ao estresse mecânico e térmico (MATIC et al., 2012). A rachadura dos anéis da gaiola de esquilo também contribui para a composição dos defeitos em MITs, porém são menos incidentes (SANTOS, 2013).

Com todo o exposto anteriormente, percebe-se que o desenvolvimento de técnicas de diagnóstico de falhas justifica-se diante da necessidade de confiabilidade nos processos e mitigação de consequências das falhas, de forma a garantir maior segurança e disponibilidade nas operações.

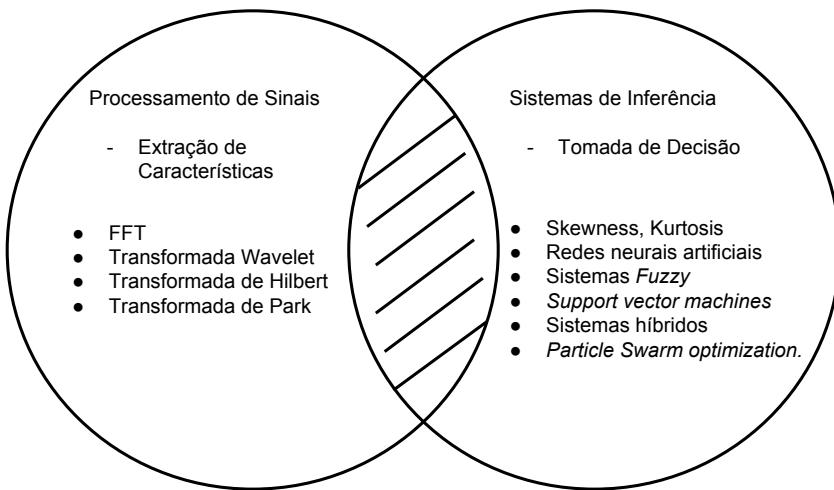
1.2 Diagnóstico de Falhas

Os sistemas de diagnóstico de falhas podem ser classificados em sistemas baseados em modelo ou em sinais. Os sistemas baseados em modelo utilizam modelos computacionais do sistema dinâmico em análise para se obter referências dos pontos de operação desejados. Porém, esses sistemas de diagnóstico possuem restrições como incertezas nos modelos e complexidade computacional. Consequentemente, sistemas baseados em sinais têm sido amplamente considerados pela literatura específica ao tema nos últimos anos, principalmente devido à complexidade de se modelar sistemas eletromecânicos (GHANBARI, 2016).

Os métodos de diagnóstico de falhas baseados em sinais consistem na leitura de variáveis do motor e em técnicas de processamento de sinais com o objetivo de extrair características ou índices relevantes que possam apontar o acontecimento de um evento anormal. Por meio dessas características ou índices, sistemas de inferência, estáticos ou inteligentes, são ajustados para acusar o acontecimento de uma falha, assim como diagnosticar sua severidade de forma automática. Desta forma, o estado da arte de sistemas de diagnóstico surge da junção de duas grandes áreas do conhecimento: processamento de sinais e sistemas de inferência, como evidenciado na Figura 2.

Um bom sistema de diagnóstico implica em um projeto com adequadas escolhas de variáveis de monitoramento, técnicas de processamento de sinais e análise de compromisso entre custo e aplicabilidade de recursos. Segundo Ostojic et al. (2013), o sistema de identificação deve ainda ser dedicado a encontrar a severidade das falhas, de forma a auxiliar o tratamento das ocorrências. Variáveis como tensão e corrente elétricas, vibração mecânica, temperatura e velocidade são alguns exemplos de sinais monitorados. Uma análise cuidadosa da relação dessas variáveis com as possíveis falhas de um MIT foi explicitada em Santos, Silva e Suetake (2012), por meio de uma minuciosa compilação da literatura.

Figura 2: Representação da intersecção das áreas do conhecimento para um sistema de diagnóstico de falhas: processamento de sinais e sistemas de inferência.



Fonte: elaborado pela autora.

1.2.1 Processamento de Sinais

Como explicitado anteriormente, uma importante parte do sistema de diagnóstico de falhas reside no processamento de sinais monitorados. Este processamento é essencial para um sistema de identificação confiável e preciso, pois é ele o responsável por extrair, dos sinais, índices altamente correlacionados ao acontecimento de uma falha, de forma a permitir que classificadores inteligentes ou estatísticos consigam realizar o diagnóstico de forma automática. Sinais como corrente e tensão elétricas, vibrações mecânicas e sinais térmicos estão dentre os monitoramentos mais comuns. Atualmente, métodos de processamento desses sinais se dão por ferramentas aplicadas no domínio do tempo ou da frequência, e no domínio tempo-frequência, como por exemplo, *Fast Fourier Transform* (FFT) e *Wavelet Transform* (WT) (MEHRJOU et al., 2011; EBRAHIMI; FAIZ; AKIN, 2012; COSTA; KASHIWAGI; MATHIAS, 2015; YANG et al., 2016).

A grande maioria dos sistemas de diagnóstico possuem suas análises de sinais baseadas em transformadas no domínio da frequência, mais especificamente no processamento de sinais advindos da assinatura espectral da corrente elétrica do motor, *Motor Current Signature Analysis* (MCSA) (GARCÍA-ESCUDERO et al., 2011; GARCIA-PEREZ et al., 2011; RANGEL-MAGDALENO et al., 2014; GU et al., 2015; YANG et al., 2016). Análises da potência elétrica instantânea também são encontrados em Drif e Cardoso (2009), Bossio et al. (2009a), Drif e Cardoso (2012), Drif e Cardoso (2014). Uma das vantagens em se utilizar sinais elétricos para o monitoramento dos MITs se dá pelo fato desses sinais serem facilmente adquiridos de forma não invasiva e por meio de sensores já existentes na operação do motor.

Pela leitura cuidadosa da literatura correlata, fica claro, que problemas relacionados

principalmente com a extração de características dos sinais monitorados ainda estão em aberto (MEHRJOU et al., 2011; YANG et al., 2016). Pode-se citar dificuldades de extração de características devido ao espalhamento espectral em algoritmos de processamento no domínio da frequência, à necessidade de largos períodos de aquisição de sinais, à falta de imunidade a ruídos dos algoritmos, principalmente quando os motores são alimentados por inversores de frequência, entre outros. Em algoritmos de processamento no domínio do tempo, dificuldades de extração de características ocorrem em motores em baixo torque. Desta forma, novos estudos na área de identificação e diagnóstico de falhas, principalmente na área de processamento de sinais, são necessários, de forma a perpassar problemas existentes.

Os índices provenientes do processamento de variáveis monitoradas devem revelar informações importantes para a manutenção e diagnóstico das máquinas de indução, e dessa forma, facilitar o trabalho dos sistemas de inferência. Em estudos de prognóstico de degradação e vida útil de motores de indução (COBLE; HINES, 2009), definem-se métricas para analisar se um índice resultante do processamento de sinais monitorados é um bom indicador de degradação do equipamento. Um bom índice de prognóstico deve ser monotônico com a severidade da falha, ou seja, deve ser estritamente crescente ou decrescente com a severidade. Além disso, o equipamento deve ser diagnosticado com falha dentro de um intervalo pequeno de valores desse índice, ou seja, possuir baixa variabilidade. Outro importante aspecto advindo dos conceitos de prognóstico é que os índices indicativos da degradação devem ter a mesma tendência, ou seja, a mesma orientação funcional durante o tempo. Essas três características são denominadas de monotonicidade, variabilidade e trendabilidade.

Pode-se estender esses conceitos para a aplicação no diagnóstico de falhas. A monotonicidade de um índice indicativo da falha é importante, pois apresenta relação com a severidade da ocorrência. A variabilidade também deve ser tida como característica importante, pois, ela mostra uma medida de variância do valor do índice indicativo de falha dentre uma população de equipamentos. Uma grande variância pode resultar em dificuldades para sistemas de identificação e proteção. Já a trendabilidade mostra que os índices de degradação de uma população possuem a mesma tendência funcional.

Com essas importantes características, os sistemas de inferência, denominados também de sistemas de tomada de decisão, podem então proceder com a identificação e diagnóstico de falhas de forma facilitada.

1.2.2 Sistemas de Inferência

Os sistemas de classificação e tomada de decisão para indicar a ocorrência da falha também são extremamente importantes. Eles devem aprender a identificar características específicas da falha nos índices resultantes do processamento de sinais. Análises estatísti-

cas e classificadores advindos da aprendizagem de máquinas são algumas das ferramentas utilizadas como sistemas de inferência.

Ferramentas baseadas em aprendizagem de máquinas abrangem a aquisição automática de conhecimento a partir de observações, e podem ser empregadas para solucionar problemas de engenharia, como por exemplo, identificação de sistemas e reconhecimento de padrões. Essas ferramentas consistem em diferentes algoritmos computacionais e técnicas de processamento visando a organização, reconhecimento de informações e aprendizado a partir de dados. Desta forma, de maneira autônoma essas ferramentas podem aumentar o desempenho ou robustez de um sistema em análise.

Os sistemas inteligentes, advindos da aprendizagem de máquinas, são um conjunto de ferramentas computacionais que tentam simular alguns mecanismos inteligentes encontrados na natureza (SILVA; SPATTI; FLAUZINO, 2010; SILVA et al., 2016). Cada ferramenta possui um potencial distinto para diferentes aplicações, porém, todas possibilitam o desenvolvimento de estratégias que facilitam o trabalho, muitas vezes complexo, quando comparadas às técnicas computacionais convencionais. As aplicações para os sistemas inteligentes são vastas, tais como as seguintes:

- ❑ Estimação e controle;
- ❑ Otimização;
- ❑ Classificação de padrões e
- ❑ Aproximação de funções, entre outras.

Nota-se na literatura recente uma crescente tendência em se utilizar sistemas inteligentes e outras ferramentas baseadas em aprendizagem de máquinas como classificadores em problemas de identificação e diagnóstico de falhas. Essa tendência ocorre em virtude das inúmeras vantagens apresentadas por esses sistemas, como fácil implementação em software, baixa complexidade computacional, habilidade de mapear sistemas não lineares e variantes no tempo e a não necessidade de modelos matemáticos precisos que façam a representação do problema em análise.

Para detecção de barras quebradas, tema central desta tese, vários trabalhos utilizam diversos sistemas inteligentes e outras ferramentas de aprendizagem de máquinas para a tomada de decisão, como as Redes Neurais Artificiais (RNAs) (SADEGHIAN; YE; WU, 2009; PAWLAK; KOWALSKI, 2010; GODOY et al., 2016), Sistemas de Inferência *Fuzzy* (SIFs) (ROMERO-TRONCOSO et al., 2011; SEERA et al., 2014), *Support Vector Machines* (*SVMs*) (BACCARINI et al., 2011; MATIC et al., 2012; GODOY et al., 2016), *Particle Swarm Optimization* (PSO) (SOUALHI; CLERC; RAZIK, 2013), Algoritmo Genético (AG) (RAZIK; CORREA; SILVA, 2009) e classificadores Bayesianos (SILVA; POVINELLI; DEMERDASH, 2008; SILVA; POVINELLI; DEMERDASH, 2013). Nestes trabalhos não só a detecção de falhas é realizada,

mas também um diagnóstico de sua severidade, a qual é representada pelo número de barras quebradas no rotor.

As mais novas pesquisas relatam também o uso de classificadores de uma só classe para a detecção dos defeitos (SMART; BROWN; AXEL-BERG, 2013) através do uso de *SVMs*. Nessas aplicações, o conceito de detecção de novidade é empregado, no qual deve-se indicar anomalias em novas observações tendo-se apenas amostras da população saudável.

1.3 Objetivos e Contribuições

Mediante a relevância do tema, é proposto nesta tese, um sistema automático de diagnóstico de falhas com base em uma nova ferramenta de processamento de sinais elétricos, denominada Decomposição em Componentes Ortogonais (DCO) e ferramentas de aprendizagem de máquinas.

A DCO, inicialmente desenvolvida por Flauzino (2007), é uma nova ferramenta com grande potencial para a solução de problemas em sistemas elétricos, principalmente relacionados à identificação de processos não lineares, detecção de eventos, filtragem de sinais e estimação de parâmetros. A nova técnica, diferentemente de consagradas técnicas de processamento de sinais, decompõe os sinais elétricos do sistema dinâmico em análise nos próprios sinais do sistema, ou seja, é independente de coordenadas previamente estabelecidas para a decomposição (FLAUZINO, 2007). A decomposição resulta em produtos sensíveis às condições de operação do sistema analisado. Em Batista et al. (2016) resultados promissores foram obtidos com a utilização da DCO para auxiliar a identificação de falhas de alta impedância em sistemas de distribuição.

Esta pesquisa versa sobre a identificação de barras quebradas no rotor e visa-se, por meio da aplicação da ferramenta de DCO, a extração de características das formas de onda de tensão e corrente elétricas de MITs, que permitam a sistemas inteligentes inferir sobre a ocorrência ou não de falhas. Além disso, o sistema de detecção deve indicar a severidade da falha, representada pelo número de barras quebradas.

1.3.1 Objetivos

O objetivo central desta pesquisa foi, então, investigar, desenvolver, implementar e validar um método de diagnóstico de falhas em MITs, automatizado, utilizando a ferramenta de DCO em conjunto com técnicas de aprendizagem de máquinas. Neste contexto do objetivo central da pesquisa pode-se então pontuar todos os objetivos específicos como descritos a seguir:

- ❑ Desenvolver estratégias baseadas na técnica de decomposição ortogonal visando sua utilização como ferramenta de processamento de sinais para auxiliar na identificação de falhas em MITs;

- ❑ Selecionar, projetar e empregar ferramentas de aprendizagem de máquinas que, a partir das características extraídas no processamento, sejam capazes de identificar a ocorrência de falhas e
- ❑ Testar e validar os métodos desenvolvidos.

1.3.2 Contribuições

Desta forma, pontua-se aqui que as principais contribuições da pesquisa:

- ❑ Desdobrar a aplicação de uma nova ferramenta matemática na detecção de falhas em MITs;
- ❑ Disponibilizar maior investigação sobre a nova ferramenta, permitindo que esta possa ser testada e validada em outras áreas do conhecimento pela comunidade científica e
- ❑ Integrar a técnica de DCO com os sistemas inteligentes a fim de identificar e classificar as falhas ocorridas nos MITs e perpassar atuais dificuldades da área de forma a avançar a fronteira do conhecimento.

Nesta tese mostra-se, por meio de simulações computacionais e experimentos, que a aplicação da DCO resulta índices altamente correlacionados com as falhas. A classificação das falhas e o diagnóstico é então facilitada para os sistemas inteligentes utilizados.

1.4 Organização do Trabalho

Esta tese é organizada em capítulos. O Capítulo 2 descreve o estado da arte em diagnóstico de falhas nos MITs para os casos de barras quebradas no rotor. No Capítulo 3 faz-se uma extensa investigação da ferramenta de DCO e no Capítulo 4 descreve-se os métodos matemáticos e computacionais utilizados para a obtenção do sistema de diagnóstico. O Capítulo 5 exibe os materiais da bancada experimental utilizada neste trabalho. Já o Capítulo 6 apresenta o método de trabalho, e o Capítulo 7 apresenta e discute os resultados obtidos. Por fim, no Capítulo 8, são reportadas as conclusões do trabalho de pesquisa e diretrizes para trabalhos futuros.

CAPÍTULO 2

Aspectos da Falha de Barras Quebradas

Esta tese possui como objeto de estudo as quebras nas barras do rotor de MITs. Mais detalhes sobre o fenômeno das falhas são apresentados neste capítulo, de forma a criar uma base de conhecimento para o desenvolvimento desta pesquisa.

Notadamente, a quebra de barras causa assimetrias na estrutura do rotor e distorções na corrente elétrica da gaiola, o que consequentemente ocasionam assimetrias e distorções na corrente elétrica de estator.

2.1 Surgimento de Bandas Laterais no Espectro de Frequências

Quando uma barra se quebra, o campo magnético rotativo no entreferro da máquina se torna não simétrico, o que leva ao aparecimento de uma componente de campo magnético de sequência negativa e que gira ao contrário da componente de sequência positiva no entreferro. Dado que a alimentação do MIT seja realizada por uma fonte senoidal de tensões trifásicas, ou seja,

$$v_A(t) = \sqrt{2}V \cos(\omega t) \quad (1)$$

$$v_B(t) = \sqrt{2}V \cos\left(\omega t - \frac{2\pi}{3}\right) \quad (2)$$

$$v_C(t) = \sqrt{2}V \cos\left(\omega t + \frac{2\pi}{3}\right) \quad (3)$$

componentes de frequência próximas à frequência fundamental de acionamento do motor, características da falha, são encontradas no espectro das correntes elétricas de estator. Essas componentes de frequência resultam em bandas laterais à frequência fundamental no espectro de corrente do estator.

As correntes elétricas de fase podem ser caracterizadas como em Drif e Cardoso

(2014):(??)

$$\begin{aligned} i_A(t) &= \sqrt{2}I \cos(\omega t - \varphi) + \dots \\ &\dots + \sqrt{2} \sum_{k=1}^{\infty} [I_{b1} \cos((\omega - k \omega_b)t - \varphi_{b1}) + I_{b2} \cos((\omega + k \omega_b)t - \varphi_{b2})] \end{aligned} \quad (4)$$

$$\begin{aligned} i_B(t) &= \sqrt{2}I \cos\left(\omega t - \varphi - \frac{2\pi}{3}\right) + \dots \\ &\dots + \sqrt{2} \sum_{k=1}^{\infty} \left[I_{b1} \cos\left((\omega - k \omega_b)t - \varphi_{b1} - \frac{2\pi}{3}\right) + I_{b2} \cos\left((\omega + k \omega_b)t - \varphi_{b2} - \frac{2\pi}{3}\right) \right] \end{aligned} \quad (5)$$

$$\begin{aligned} i_C(t) &= \sqrt{2}I \cos\left(\omega t - \varphi + \frac{2\pi}{3}\right) + \dots \\ &\dots + \sqrt{2} \sum_{k=1}^{\infty} \left[I_{b1} \cos\left((\omega - k \omega_b)t - \varphi_{b1} + \frac{2\pi}{3}\right) + I_{b2} \cos\left((\omega + k \omega_b)t - \varphi_{b2} + \frac{2\pi}{3}\right) \right] \end{aligned} \quad (6)$$

onde ω é a frequência angular de alimentação do motor, ω_b é a frequência angular induzida pela falha de barras quebradas, I e φ são, respectivamente, o valor eficaz e a defasagem da corrente elétrica fundamental e I_{b1} , I_{b2} , φ_{b1} e φ_{b2} são os valores eficazes e defasagem das bandas laterais.

Observa-se que as componentes induzidas pela falha são encontradas nas seguintes frequências:

$$f_{1,2} = (1 \pm 2ks)f = (f \pm kf_b) \quad (7)$$

onde k é um inteiro, s é o escorregamento, f é a frequência síncrona e

$$f_b = 2sf \quad (8)$$

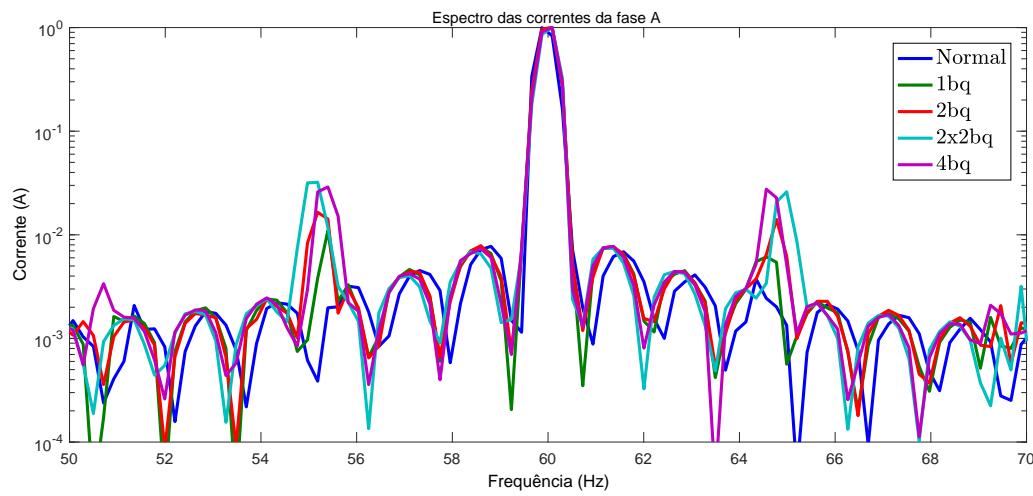
A componente de sequência negativa do campo rotativo é a responsável por causar o aparecimento da sequência de bandas laterais esquerdas, múltiplas da frequência f_1 . De fato, essas componentes assimétrica de corrente nas frequências múltiplas de $(1 - 2s)f$ causam então um torque pulsado e oscilante, o qual gera a sequência de bandas laterais direitas, múltiplas da frequência f_2 , devido à modulação angular causada pela velocidade pulsada (BELLINI et al., 2001).

A localização das bandas laterais depende diretamente do escorregamento do motor. Já a amplitude dessas componentes, depende da posição das barras quebradas, do número de barras quebradas, além do torque de carga. Quanto maior o torque de carga, maior a amplitude dessas bandas laterais, assim como, quanto maior o número de barras adjacentes quebradas, maior a amplitude dessas componentes (JOKSIMOVIC et al., 2013; CONCARI et al., 2013).

Em Sizov et al. (2009) os efeitos de quebras de barras adjacentes ou não adjacentes foram estudados. Concluiu-se que os efeitos de barras não adjacentes podem influenciar

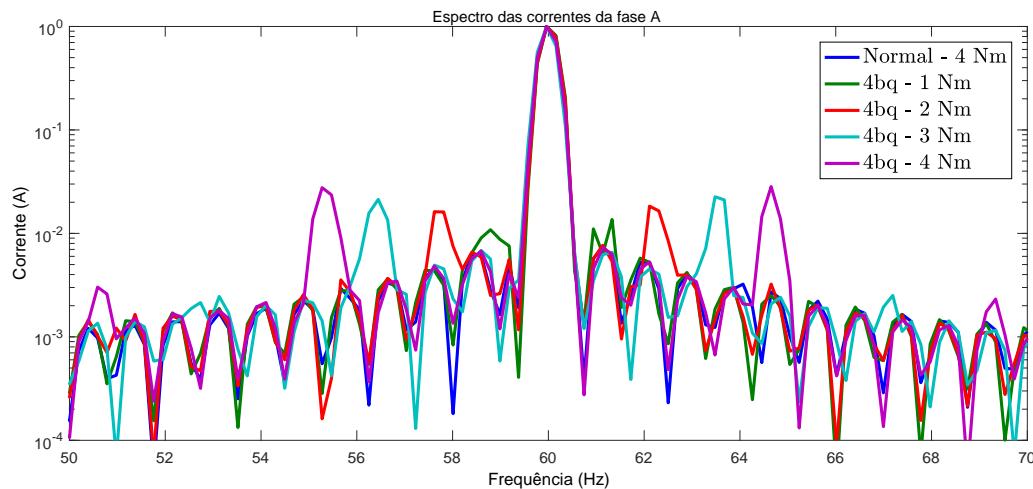
o diagnóstico, particularmente para barras com distanciamento de 90° elétricos. No caso em qual barras quebradas estiverem sob polos de mesmo nome, essas falhas possuirão praticamente os mesmos efeitos na corrente de estator que a quebra de barras consecutivas, ou seja, o aparecimento de bandas laterais de mesma magnitude. A Figura 3 e a Figura 4 mostram o espectro de corrente de um motor de 1 cv, com diferentes números de barras quebradas, designados pela sigla (bq). Pode-se observar inclusive os efeitos no espectro de corrente do motor para uma quebra de quatro barras, sendo duas barras adjacentes quebradas em lados radialmente opostos (2×2 bq).

Figura 3: Efeito da variação do número de barras quebradas na corrente elétrica de estator de MITs. Motor de 1 cv acionado diretamente pela rede.



Fonte: elaborado pela autora.

Figura 4: Efeito da variação do torque de carga na corrente elétrica de estator de MITs com 4bq. Motor de 1 cv acionado diretamente pela rede.



Fonte: elaborado pela autora.

A identificação de barras quebradas quando o motor está levemente carregado é bastante dificultada quando utilizadas análises no domínio da frequência da corrente elétrica de estator (SILVA; POVINELLI; DEMERDASH, 2008; BINDU; THOMAS, 2014). Isto se deve à proximidade das bandas laterais com a frequência fundamental. Desta forma, grandes espalhamentos espectrais podem sobrepor as bandas laterais e dificultar o diagnóstico. Além disso, com baixo torque de carga, a perturbação causada pela falha é pequena, pois, o circuito elétrico do motor se aproxima do estado de alta impedância em vazio, assim, os efeitos de uma falha são demasiadamente pequenos nas grandezas elétricas. Portanto, a acurácia dessas técnicas depende da resolução espectral e necessita de um largo intervalo de aquisição de dados objetivando minimizar o espalhamento no domínio da frequência (MEHRJOU et al., 2011). Além disso, quando a severidade da falha, considerada como o número de barras quebradas, é pequena, as bandas laterais são muito pequenas em amplitude.

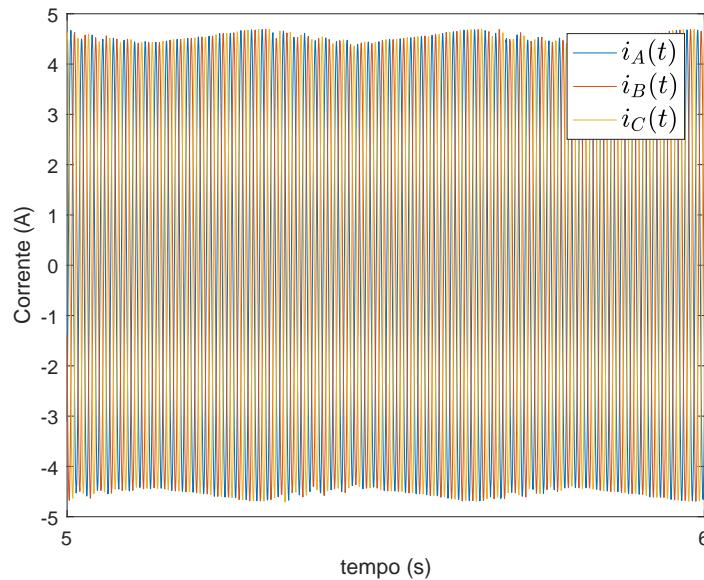
2.2 Formação de Envelope Trifásico nas Correntes

Métodos de diagnóstico baseados na análise do envelope das correntes elétricas trifásicas de estator também apresentam dificuldades de identificação em situações de baixo torque de carga (SILVA; POVINELLI; DEMERDASH, 2008), pois a modulação trifásica fica praticamente imperceptível. O envelope trifásico é resultado das modulações criadas nas correntes elétricas de estator devido à presença das componentes que formam as chamadas bandas laterais. Um ponto negativo desse método é também a dificuldade em separar a ocorrência das falhas com eventuais desbalanços de tensão entre as fases. Na Figura 5 mostra-se o envelope criado pelas correntes elétricas trifásicas para um motor com 4bq, torque de carga nominal e acionado diretamente pela rede.

Outro fator relevante para o diagnóstico de barras quebradas, e que deve ser discutido, é que as frequências $f_{1,2}$ são deslocadas para mais longe da frequência fundamental quando o escorregamento aumenta. Já que os métodos mais comuns de diagnósticos baseados na assinatura espectral da corrente de estator utilizam as amplitudes de diversas componentes de frequência ao redor da frequência fundamental como entradas para sistemas de tomada de decisão, a acurácia do diagnóstico pode diminuir. Portanto, para impedir este problema, algoritmos de processamento precisam saber, a priori, a velocidade do motor ou escolherem dinamicamente o número de pontos utilizados ao redor da frequência fundamental.

Em diversos trabalhos da literatura correlata, como por exemplo em, Ye, Wu e Sadeghian (2003), Baccarini (2005), Drif e Cardoso (2012), Drif e Cardoso (2014), mostra-se que a tarefa de distinguir as condições de falha das condições normais usando a assinatura de motores é extremamente difícil tanto no tempo quanto no seu espectro de frequências. É explicitado que a classificação de motores normais e com defeitos por simples inspeção

Figura 5: Envelope trifásico de um MIT com 4bq e torque de carga nominal. Motor de 1 cv acionado diretamente pela rede.



Fonte: elaborado pela autora.

da assinatura das variáveis monitoradas é uma tarefa complexa. Ainda mais, vibrações mecânicas podem causar certas bandas laterais e, como já explicitado, se a análise espectral for feita com presença de ruídos ou com baixa resolução e alto espalhamento, o diagnóstico é prejudicado. Por fim, um perfil de carga com torque oscilante em baixa frequência pode também causar bandas laterais que mascaram o fenômeno de uma falha de barras quebradas (DRIF; CARDOSO, 2012). Algumas cargas como compressores alternativos e condições de defeito na transmissão podem inserir anormalidades no torque que causam as mesmas bandas laterais no espectro de motores com barras quebradas, porém, essas anormalidades não introduzem nenhum defeito no rotor e podem ser classificadas erroneamente. É preciso ainda lembrar que na assinatura do motor, as correntes elétricas do estator não são exatamente trifásicas, pois, os enrolamentos não são iguais e a distribuição do campo magnético não é homogênea nas ranhuras. Todos esses aspectos dificultam o diagnóstico de falhas.

2.3 Modificação no Consumo de Potências

Sabe-se ainda que a quebra de barras possui uma característica reativa (BOSSIO et al., 2009a; DRIF; CARDOSO, 2009; DRIF; CARDOSO, 2012; DRIF; CARDOSO, 2014), já que quando uma barra se quebra, o motor perde magnetização e, dessa forma, consome mais potência reativa para manter o mesmo torque. Outras abordagens para identificação de falhas utilizam como ferramentas de processamento de sinais a decomposição dos sinais

instantâneos de potência ativa e reativa. Em Drif e Cardoso (2009), Bossio et al. (2009a), Drif e Cardoso (2012), Drif e Cardoso (2014) mostra-se que a potência instantânea sofre oscilações quando o fenômeno de barras quebradas ocorre. A potência instantânea ativa $p(t)$ e $q(t)$ podem calculadas por intermédio da teoria generalizada de potências, como delineado em Drif e Cardoso (2012):

$$p(t) = v_A(t)i_A(t) + v_B(t)i_B(t) + v_C(t)i_C(t) \quad (9)$$

$$q(t) = \sqrt{3}(v_A(t)i_B(t) - v_B(t)i_A(t)) \quad (10)$$

As potências instantâneas, ativa e reativa, para o caso do motor saudável, onde as bandas laterais não estão presentes, assumem então:

$$p(t) = 3VI \cos(\varphi) \quad (11)$$

$$q(t) = 3VI \sin(\varphi) \quad (12)$$

No caso do motor com falha de barras quebradas no rotor, as potências instantâneas passam a ser:

$$p(t) = 3VI \cos(\varphi) + 3V \left(\sum_{k=1}^{\infty} [I_{b1} \cos(k \omega_b t + \varphi_{b1}) - I_{b2} \cos(k \omega_b t - \varphi_{b2})] \right) \quad (13)$$

$$q(t) = 3VI \sin(\varphi) + 3V \left(\sum_{k=1}^{\infty} [I_{b1} \sin(k \omega_b t + \varphi_{b1}) - I_{b2} \sin(k \omega_b t - \varphi_{b2})] \right) \quad (14)$$

Desta forma, as potências instantâneas ativa e reativa se tornam diferentes para os casos de motores saudáveis e motores com falha de barras quebradas. Nota-se que essas potências possuem um valor médio e um valor oscilante com frequência f_b . Agrupando-se os termos de mesma frequência, as potências instantâneas resultam:

$$p(t) = P_0 + \sum_{k=1}^{\infty} [P_m \cos(\omega_b t + \phi_m)]$$

$$q(t) = Q_0 + \sum_{k=1}^{\infty} [Q_m \cos(\omega_b t + \phi_m)]$$

onde:

$$P_m = 3V \sqrt{I_{b1}^2 + I_{b2}^2 + 2I_{b1}I_{b2} \cos(\varphi_{b1} + \varphi_{b2})}$$

$$Q_m = 3V \sqrt{I_{b1}^2 + I_{b2}^2 - 2I_{b1}I_{b2} \cos(\varphi_{b1} + \varphi_{b2})}$$

Em Bossio et al. (2009b) mostra-se que a relação entre o máximo dessas oscilações e seus valores médios é monotônico crescente com o número de barras quebradas; característica muito importante para o diagnóstico de falhas.

De acordo com Bellini et al. (2001), pode-se assumir que, na presença de barras quebradas:

- As bandas laterais da corrente elétrica de estator possuem a mesma amplitude ($I_{b1} = I_{b2} = I_b$);
- A soma das defasagens das bandas laterais é igual a π .

Além disso, sabe-se que a soma das defasagens das bandas laterais quando causadas por uma carga oscilante é igual a 2π . Portanto, para cargas com perfil de torque oscilante, a potência ativa instantânea deixa de possuir a parcela extra, enquanto a potência reativa instantânea continua com a parcela oscilatória. Desta forma, essa abordagem trouxe grandes benefícios, pois mediante a combinação dos índices de potência instantânea ativa e reativa, pôde-se separar o fenômeno de barras quebradas no rotor de uma possível carga oscilante no eixo rotativo do motor.

Um novo paradigma foi então adotado para os diagnósticos de barras quebradas, no qual, as informações extraídas para o sistema de tomada de decisão devem ser capazes de diferenciar barras quebradas de cargas com perfis de torque oscilantes.

Ainda assim, dificuldades de detecção de barras quebradas e sua distinção com cargas oscilantes foram encontradas em situações de baixo torque de carga. Desta forma, novas técnicas de processamento, mineração de dados e sistemas inteligentes devem ser conjuntamente investigadas e utilizadas para a realização do diagnóstico de barras quebradas.

CAPÍTULO 3

Técnica de Decomposição em Componentes Ortogonais

No panorama apresentado nos Capítulos 1 e 2, destacou-se pesquisas e trabalhos relacionados à identificação de falhas em MITs. Um aspecto em comum dentre todas as metodologias citadas, as quais podem ser realizadas por métodos convencionais ou com o auxílio de sistemas inteligentes, é a necessidade de se realizar o processamento dos sinais monitorados. O processamento de sinais tem por objetivo preparar os dados para uma análise ou interpretação do problema investigado. Desta forma, os dados devem ser processados por meio de ferramentas que resultem em índices com alta sensibilidade às falhas.

Neste capítulo serão detalhados os conceitos da DCO. A ferramenta desenvolvida por Flauzino (2007) realiza a decomposição dos sinais elétricos em uma base resultante dos próprios sinais analisados e não em bases pré-determinadas. A DCO pode ser considerada uma nova ferramenta de processamento de sinais, pensada inicialmente para o uso em sistemas elétricos, de forma a auxiliar, principalmente, as tarefas de detecção de eventos, estimativa de parâmetros e filtragem de sinais. Em Flauzino (2007) e Batista et al. (2016), a DCO foi utilizada de forma promissora na detecção e localização de faltas de alta impedância em sistemas de distribuição de energia elétrica. Pode-se afirmar que a técnica é altamente sensível à operação do sistema em análise e resulta em sinais no domínio do tempo, o que permite a aplicação de outras ferramentas existentes de processamento de sinais para melhorar a extração de características.

A nova abordagem de diagnóstico de barras quebradas baseada na técnica da DCO poderá constituir, juntamente com métodos amplamente utilizados, uma nova perspectiva para a detecção de eventos em sistemas eletromecânicos. Assim, uma das principais contribuições desta pesquisa é o aprofundamento do entendimento da técnica e de sua aplicabilidade não só em sistemas elétricos, mas também em sistemas eletromecânicos.

Toda a formulação matemática da técnica de DCO encontra-se desenvolvida em Flauzino (2007). Porém, neste capítulo, uma nova abordagem é dada à formulação já desenvol-

vida, de forma a auxiliar, de maneira heurística, seu entendimento e a interpretação das várias componentes resultantes da aplicação do método. Além disso, uma contribuição adicional deste trabalho foi introduzir conceitos de potência elétrica associados à DCO.

A ferramenta foi desenvolvida para analisar aplicações de sistemas elétricos, consequentemente, todos os sinais analisados são considerados contínuos, finitos e periódicos.

Seja $f(t)$ e $g(t)$ alguns desses sinais com periodicidade T . Pode-se considerar que cada uma dessas funções pertence ao espaço vetorial \mathbb{R}^∞ . Dessa forma, o operador matemático de produto interno, representado por $\langle \cdot, \cdot \rangle$, pode ser definido como:

$$\langle f(t), g(t) \rangle = \frac{1}{T} \int_{t-T}^t f(\tau)g(\tau)d\tau \quad (15)$$

Assim, pode-se também definir um operador de norma quadrática, representado por $\|\cdot\|^2$ e calculado como a seguir:

$$\|f(t)\|^2 = \langle f(t), f(t) \rangle \quad (16)$$

Ainda, considerando-se que os sinais analisados são sinais elétricos, é interessante estender a definição de norma quadrática para a definição de valor eficaz (RMS) como mostrado a seguir. Nesta tese os termos RMS e valor eficaz serão utilizados de forma indistinta.

$$F_{rms}(t) = \|f(t)\| = \sqrt{\frac{1}{T} \int_{t-T}^t f(\tau)^2 d\tau} \quad (17)$$

A ferramenta é baseada em dois princípios advindos da álgebra linear e trata os sinais analisados como vetores no espaço \mathbb{R}^∞ . Com as definições anteriores, uma breve introdução a esses princípios matemáticos da decomposição será desenvolvida nas próximas subseções.

3.1 Primeiro Princípio - Decomposição de Funções Sobre o Subespaço de Outras Funções

Considere duas funções contínuas, finitas e periódicas, advindas de um sistema elétrico, chamadas de $i(t)$ e $v(t)$. Por facilidade, ir-se-á tratar a partir deste ponto da tese, correntes elétricas apenas por correntes e tensões elétricas apenas por tensões. Como já mencionado, essas funções são consideradas vetores no espaço vetorial \mathbb{R}^∞ . É possível definir a função derivada, $\dot{i}(t)$, e a função integral, $\tilde{i}(t)$, pelas equações (18) e (19) respectivamente.

$$\dot{i}(t) = \frac{d i(t)}{dt} \quad (18)$$

$$\frac{d \tilde{i}(t)}{dt} = i(t) \quad (19)$$

O objetivo da DCO é ser altamente sensível aos parâmetros do sistema elétrico em análise e representar informações elétricas desse sistema. Desta forma, a decomposição formulada em (20) se mostra bastante interessante para atingir este objetivo, na qual a função $v(t)$ é decomposta em quatro partes. A parcela de tensão $v^p(t)$ é proporcional à corrente elétrica do sistema e, assim, carrega uma informação da resistência (R) do sistema por meio do coeficiente γ_1 . Além disso, o coeficiente γ_2 , na parcela de tensão $v^{q\parallel}(t)$, carrega uma informação de indutância (L) pois essa parcela é proporcional à derivada da corrente elétrica. Por fim, γ_3 carrega informações da capacidade ($1/C$), devido à proporcionalidade entre a parcela $v^{q\sim}(t)$ e a função integral da corrente elétrica. A última parcela na equação (20) se faz necessária, pois, o vetor $v(t)$ em \mathbb{R}^∞ não pode ser gerado apenas pela combinação linear de três vetores. Consequentemente, a última parcela da decomposição carrega informações que não podem ser puramente modeladas por intermédio de componentes elétricos passivos e que são necessárias para complementar o restante da combinação linear das bases de \mathbb{R}^∞ .

$$v(t) = \underbrace{\gamma_1 i(t)}_{v^p(t)} + \underbrace{\gamma_2 \dot{i}(t)}_{v^{q\parallel}(t)} + \underbrace{\gamma_3 \tilde{i}(t)}_{v^{q\sim}(t)} + v^d(t) \quad (20)$$

É essencial que os vetores nos quais um sinal é decomposto, ou seja, os vetores da base da decomposição sejam linearmente independentes e ortogonais entre si, de forma que os coeficientes γ em (20) sejam índices não correlacionados. Para analisar se a ortogonalidade ocorre entre as parcelas da decomposição toma-se a representação das funções da base da decomposição em séries de Fourier:

$$i(t) = \sum_{k \in \Omega_i} I_k \cos(k\omega t + \delta_k) \quad (21)$$

$$\dot{i}(t) = -\omega \sum_{k \in \Omega_i} k I_k \sin(k\omega t + \delta_k) \quad (22)$$

$$\tilde{i}(t) = \frac{1}{\omega} \sum_{k \in \Omega_i} \frac{I_k}{k} \sin(k\omega t + \delta_k) \quad (23)$$

onde I_k representa o valor de pico do $k^{\text{ésimo}}$ harmônico, δ_k é a defasagem do $k^{\text{ésimo}}$ harmônico, $\omega = 2\pi/T$ e Ω_i representa o conjunto de todos os índices harmônicos na função $i(t)$, dessa forma, $\Omega_i \in \mathbb{N}$.

Sabendo-se que o produto interno entre duas funções ortogonais é zero, uma proposição sobre o arranjo espacial de vetores $i(t)$, $\dot{i}(t)$ e $\tilde{i}(t)$ é feita no Teorema 1:

Teorema 1 (Ortogonalidade). *Seja $i(t)$ uma função real, contínua, finita e com periodicidade T . É verdade que $i(t)$ é mutuamente ortogonal a sua função derivada $\dot{i}(t)$ e sua função integral $\tilde{i}(t)$, que por sua vez, não são ortogonais entre si, sendo colineares (antiparalelas) se $i(t)$ for puramente senoidal.*

Portanto, o Teorema 1 prova que:

$$\begin{aligned}
 \langle i(t), \dot{i}(t) \rangle &= \frac{1}{T} \int_{t-T}^t i(\tau) \dot{i}(\tau) d\tau \\
 &= \frac{1}{T} \int_{i(t-T)}^{i(t)} i(\tau) di(\tau) \\
 &= \frac{1}{T} \frac{1}{2} i^2(\tau) \Big|_{i(t-T)}^{i(t)} \\
 &= \frac{1}{T} \frac{1}{2} (i^2(t) - i^2(t-T)) \\
 &= 0
 \end{aligned} \tag{24}$$

$$\begin{aligned}
 \langle i(t), \tilde{i}(t) \rangle &= \frac{1}{T} \int_{t-T}^t i(\tau) \tilde{i}(\tau) d\tau \\
 &= \frac{1}{T} \tilde{i}^2(\tau) \Big|_{t-T}^t - \underbrace{\frac{1}{T} \int_{t-T}^t i(\tau) \tilde{i}(\tau) d\tau}_{\langle i(t), \tilde{i}(t) \rangle} \\
 &= \frac{1}{T} (\tilde{i}^2(t) - \tilde{i}^2(t-T)) \\
 &= 0
 \end{aligned} \tag{25}$$

$$\begin{aligned}
 \langle \dot{i}(t), \tilde{i}(t) \rangle &= \frac{1}{T} \int_{t-T}^t \dot{i}(\tau) \tilde{i}(\tau) d\tau \\
 \langle \dot{i}(t), \tilde{i}(t) \rangle &= \frac{1}{T} \underbrace{\left[i(\tau) \tilde{i}(\tau) \right] \Big|_{t-T}^t}_0 - \underbrace{\frac{1}{T} \int_{t-T}^t i^2(\tau) d\tau}_{\|i(t)\|^2} \\
 &= -\|i(t)\|^2
 \end{aligned} \tag{26}$$

Os resultados provados no Teorema 1 mostram que $i(t)$ e $\dot{i}(t)$ são ortogonais em um período T . De forma similar, $i(t)$ e $\tilde{i}(t)$ são também ortogonais dentro desse mesmo período. Porém, provou-se que $\dot{i}(t)$ e $\tilde{i}(t)$ não são sempre ortogonais. Pela definição de produto interno, o ângulo θ entre as funções $\dot{i}(t)$ e $\tilde{i}(t)$ pode ser calculado pela equação (27).

$$\cos(\theta) = \frac{\langle \dot{i}(t), \tilde{i}(t) \rangle}{\|\dot{i}(t)\| \|\tilde{i}(t)\|} = -\frac{\|i(t)\|^2}{\|\dot{i}(t)\| \|\tilde{i}(t)\|} \tag{27}$$

Utilizando-se da notação em séries de Fourier, o termo $\|\dot{i}(t)\| \|\tilde{i}(t)\|$ no denominador de (27) pode ser calculado pela somatória a seguir:

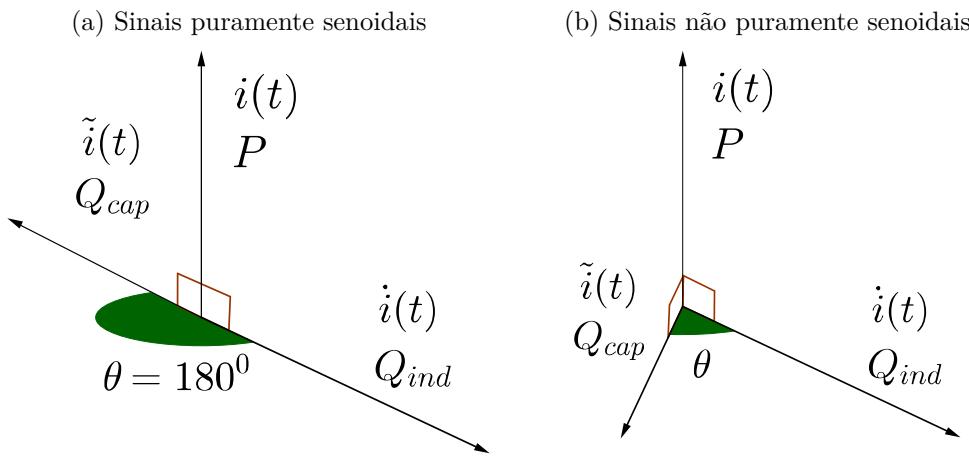
$$\|\dot{i}(t)\|^2 \|\tilde{i}(t)\|^2 = \frac{1}{4} \sum_{k \in \Omega_i} \sum_{l \in \Omega_i, l \neq k} I_k^2 I_l^2 \left(\frac{k^2}{l^2} - 2 \right) + \|i(t)\|^4 \tag{28}$$

De fato, se $i(t)$ for puramente senoidal, o denominador de (27) é simplificado para $\|\dot{i}(t)\| \|\tilde{i}(t)\| = \|i(t)\|^2$, resultando em $\cos(\theta) = -1$. Assim, certifica-se que $\dot{i}(t)$ e $\tilde{i}(t)$ são

colineares, mais especificamente, vetores antiparalelos quando $i(t)$ é puramente senoidal. Esse resultado é consistente com estudos de sistemas elétricos em condições de regime permanente e com sinais puramente senoidais, onde correntes de origem capacitiva e correntes de origem indutiva possuem efeitos opostos. Porém, quando os sinais possuem harmônicos, essa relação deixa essa condição e se torna muito mais complexa.

Na Figura 6(a), os sinais $i(t)$, $\dot{i}(t)$ e $\tilde{i}(t)$ são puramente senoidais e estão relacionadas, respectivamente, com a potência elétrica ativa (P), potência elétrica reativa com característica indutiva (Q_{ind}) e potência elétrica reativa com característica capacitiva (Q_{cap}). Nota-se que as correntes reativas possuem efeitos contrários. Já na Figura 6(b) fica explicitado o arranjo espacial das funções quando os sinais não são puramente senoidais. É possível observar que nem sempre os efeitos reativos são completamente opostos e há um ângulo de separação entre os vetores da função derivada e integral

Figura 6: Relação geométrica entre uma função e sua derivada e integral para sinais puramente senoidais e não puramente senoidais.



Fonte: elaborado pela autora.

Consequentemente, para que a decomposição da função $v(t)$ na equação (20) seja uma decomposição adequada, uma ortogonalização dos sinais da base é necessária. Para isso utiliza-se o conceito de projeção de um vetor $g(t)$ em um vetor $f(t)$:

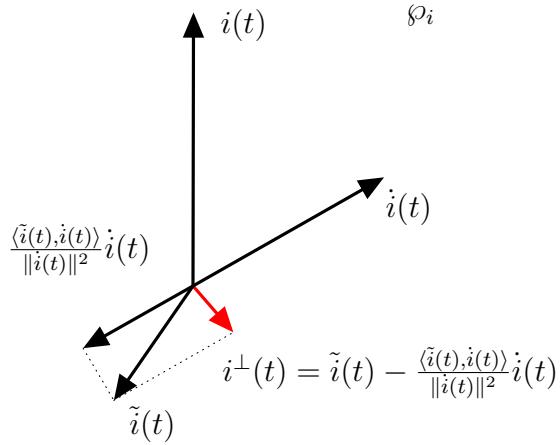
$$\text{proj } g(t)_{f(t)} = \frac{\langle g(t), f(t) \rangle}{\|f(t)\|^2} f(t) \quad (29)$$

O processo de ortogonalização, baseado na técnica de Gram-Schmidt, é mostrado na Figura 7 e explicitado em (30).

$$i^\perp(t) = \tilde{i}(t) - \frac{\langle \tilde{i}(t), \dot{i}(t) \rangle}{\|\dot{i}(t)\|^2} \dot{i}(t) \quad (30)$$

Após o processo de ortogonalização, um novo conjunto de vetores ortogonais a serem

Figura 7: Processo de ortogonalização das bases da decomposição.



Fonte: elaborado pela autora.

utilizados como base para decomposição de $v(t)$ é obtido, como mostrado em (31).

$$\begin{cases} i(t) \\ \dot{i}(t) \\ i^\perp(t) = \tilde{i}(t) - \frac{\langle \tilde{i}(t), \dot{i}(t) \rangle}{\|\dot{i}(t)\|^2} \dot{i}(t) \end{cases} \quad (31)$$

Assim, pode-se reescrever a decomposição em (20) como formulada em (32), na qual todas as parcelas da decomposição não são correlacionadas, pois, o vetor $\tilde{i}(t)$ foi substituído por $i^\perp(t)$, que é ortogonal à $i(t)$ e $\dot{i}(t)$.

$$v(t) = \underbrace{\gamma_1 i(t)}_{v^p(t)} + \underbrace{\gamma_2 \dot{i}(t)}_{v^{q\parallel}(t)} + \underbrace{\gamma_3 i^\perp(t)}_{v^{q\perp}(t)} + v^d(t) \quad (32)$$

Como resultado, a decomposição final apresentada em (32) mostra uma parcela de tensão proporcional à corrente ativa $i(t)$ e relacionada com a potência ativa; uma parcela de tensão proporcional a corrente $\dot{i}(t)$ e relacionada com a potência reativa e uma parcela de tensão proporcional a $i^\perp(t)$ também relacionada à potência reativa, mas não redundante com a anterior. Por fim, há ainda uma última parcela contendo o restante do sinal. Se o sinal $i(t)$ for puramente senoidal, então o termo $v^{q\perp}(t)$ se anula e todos os efeitos reativos recaem sobre $v^{q\parallel}(t)$, já que, nesta situação, tanto o efeito capacitivo quanto o indutivo são colineares e podem ambos ser expressos por $v^{q\parallel}(t)$.

O conjunto de vetores ortogonais $i(t)$, $\dot{i}(t)$ e $i^\perp(t)$ geram um subespaço de \mathbb{R}^∞ denominado aqui de \wp_i . O sinal $v^d(t)$ não é decomposto em \wp_i e pode ser calculado como

demonstrado em (33). Além disso, como $v^d(t)$ não é parte do subespaço \wp_i , uma combinação linear dos vetores $i(t)$, $\dot{i}(t)$ e $i^\perp(t)$ não formam $v^d(t)$, e portanto, $v^d(t)$ é ortogonal aos outros termos em (32).

$$v^d(t) = v(t) - \underbrace{\gamma_1 i(t)}_{v^p(t)} - \underbrace{\gamma_2 \dot{i}(t)}_{v^{q\parallel}(t)} - \underbrace{\gamma_3 i^\perp(t)}_{v^{q\perp}(t)} \quad (33)$$

O vetor $v^d(t)$ representa a porção restante do sinal de tensão $v(t)$ que não está contido no subespaço \wp_i , formado por $i(t)$, $\dot{i}(t)$ e $i^\perp(t)$, o qual permite a interpretação e modelagem dos sinais com apenas elementos passivos. Uma propriedade importante de $v^d(t)$ é sua ortogonalidade com \wp_i , o que permite que a norma quadrática de $v(t)$ seja calculada como:

$$\|v(t)\|^2 = \|v^p(t)\|^2 + \|v^{q\parallel}(t)\|^2 + \|v^{q\perp}(t)\|^2 + \|v^d(t)\|^2 \quad (34)$$

Todos os passos realizados para obter a decomposição formulada em (32) podem também ser utilizados para se obter a decomposição de $i(t)$ no subespaço \wp_v das tensões elétricas, formado por $v(t)$, $\dot{v}(t)$ e $v^\perp(t)$, e em uma parcela $i^d(t)$ ortogonal ao subespaço \wp_v , como mostrado em (35).

$$i(t) = \underbrace{\alpha_1 v(t) + \alpha_2 \dot{v}(t) + \alpha_3 v^\perp(t)}_{\in \wp_v} + i^d(t) \quad (35)$$

Dessa forma, para um sistema elétrico, cada par de corrente e tensão elétricas resulta em oito funções ortogonais, as quais são produtos dessa decomposição e recebem o nome de componentes ortogonais. Para cada par $i(t)$ e $v(t)$, oito componentes ortogonais são obtidas: $i^p(t)$, $i^{q\parallel}(t)$, $i^{q\perp}(t)$, $i^d(t)$, $v^p(t)$, $v^{q\parallel}(t)$, $v^{q\perp}(t)$ e $v^d(t)$.

Os coeficientes da decomposição podem ser calculados pela projeção da função que se quer decompor, individualmente, nos vetores ortogonais do subespaço. Desta forma, os coeficientes são dados por:

$$\gamma_1 = \frac{\langle v(t), i(t) \rangle}{\|i(t)\|^2} \quad (36)$$

$$\alpha_1 = \frac{\langle i(t), v(t) \rangle}{\|v(t)\|^2} \quad (37)$$

$$\gamma_2 = \frac{\langle v(t), \dot{i}(t) \rangle}{\|\dot{i}(t)\|^2} \quad (38)$$

$$\alpha_2 = \frac{\langle i(t), \dot{v}(t) \rangle}{\|\dot{v}(t)\|^2} \quad (39)$$

$$\gamma_3 = \frac{\langle v(t), i^\perp(t) \rangle}{\|i^\perp(t)\|^2} \quad (40)$$

$$\alpha_3 = \frac{\langle i(t), v^\perp(t) \rangle}{\|v^\perp(t)\|^2} \quad (41)$$

3.2 Segundo Princípio - Relação Geométrica das Tensões de Linha em Sistemas Trifásicos

O segundo princípio, no qual a DCO está alicerçada é baseado no relacionamento geométrico das funções de linha de um sistema trifásico. Seja $v_A(t)$, $v_B(t)$ e $v_C(t)$ funções continuas, periódicas em T e pertencentes ao espaço \mathbb{R}^∞ . Essas funções representam tensões de fase de qualquer sistema trifásico onde $v_{AB}(t)$, $v_{BC}(t)$ e $v_{CA}(t)$ são as tensões de linha do sistema:

$$v_{AB}(t) = v_A(t) - v_B(t) \quad (42)$$

$$v_{BC}(t) = v_B(t) - v_C(t) \quad (43)$$

$$v_{CA}(t) = v_C(t) - v_A(t) \quad (44)$$

A condição em (45), considerada no intervalo $t - T \leq \tau \leq t$, ou seja, dentro de um período T , pode ser atingida fazendo-se $k_{AB} = k_{BC} = k_{CA} = k \neq 0$.

$$k_{AB}v_{AB}(\tau) + k_{BC}v_{BC}(\tau) + k_{CA}v_{CA}(\tau) = 0 \quad (45)$$

Sabe-se da álgebra linear que quando a condição anterior é atingida com coeficientes simultaneamente não nulos, o conjunto de vetores é linearmente dependente (FLAUZINO, 2007). Além disso, quando a condição em questão é atingida, sabe-se que três vetores linearmente dependentes pertencem a um plano. Esse resultado fomenta a proposição a seguir:

Teorema 2 (Coplanaridade). *Sejam $v_{AB}(t)$, $v_{BC}(t)$ e $v_{CA}(t)$ tensões de linha, contínuas e periódicas de um sistema trifásico qualquer. Essas funções são sempre linearmente dependentes, isto é, coplanares, independentemente do conteúdo das tensões de fase $v_A(t)$, $v_B(t)$ e $v_C(t)$.*

O Teorema 2 demonstra então que:

$$\begin{aligned} k(v_A(t) - v_B(t)) + k(v_B(t) - v_C(t)) + k(v_C(t) - v_A(t)) &= 0 \\ v_A(t)(k - k) + v_B(t)(k - k) + v_C(t)(k - k) &= 0 \\ 0v_A(t) + 0v_B(t) + 0v_C(t) &= 0 \\ 0 &= 0 \end{aligned} \quad (46)$$

O propósito do segundo princípio é filtrar sinais antes de se obter as componentes ortogonais. As tensões de linha são sempre funções filtradas, pois essas tensões são obtidas pela diferença entre duas tensões de fase. Assim, qualquer ruído que incida igualmente nas grandezas de fase é eliminado nas grandezas de linha. Independentemente se as tensões de fase são balanceadas ou não, simétricas ou não ou corrompidas por ruídos e não linearidades, as tensões de linha serão sempre, de certa forma, filtradas e estarão

posicionadas em um plano. As tensões de fase $v_A(t)$, $v_B(t)$, $v_C(t)$ e de neutro $v_N(t)$ podem ter qualquer conteúdo, como ruídos, e não linearidades, assim, podem não estar contidas no plano das tensões de linha. Todavia, é possível obter a projeção destas grandezas de fase no plano das tensões de linha. Uma base ortogonal que gera o plano das tensões de linha pode ser obtida adotando-se arbitrariamente, como primeiro vetor da base, uma das tensões de linha. O segundo vetor da base deve ser ortogonal ao primeiro, dessa forma a base geradora do plano pode ser obtida por:

$$\begin{cases} v_{b_1}(t) = v_{AB}(t) \\ v_{b_2}(t) = v_{BC}(t) - \frac{\langle v_{AB}(t), v_{BC}(t) \rangle}{\|v_{AB}(t)\|^2} v_{AB}(t) \end{cases} \quad (47)$$

Sinais de fase podem ser entendidos, então, como a soma de duas parcelas. As primeiras parcelas são as parcelas planares, ou seja, aquelas que foram decompostas no plano, denominadas de $v_a(t)$, $v_b(t)$, $v_c(t)$ e $v_n(t)$. Estas parcelas são resultado da combinação linear das bases do plano, que são, por sua vez, funções filtradas, e, portanto, essas parcelas são consideradas versões filtradas dos sinais de fase originais. As segundas parcelas, denotadas como $v_{\bar{a}}(t)$, $v_{\bar{b}}(t)$, $v_{\bar{c}}(t)$ e $v_{\bar{n}}(t)$, não são geradas pela base do plano e são necessárias, já que os sinais de fase podem não estar contidos no plano, visto que podem possuir ruídos e não linearidades. As equações (48) - (51) demonstram o exposto anteriormente.

$$v_A(t) = \underbrace{\beta_a v_{b_1}(t) + \delta_a v_{b_2}(t)}_{v_a(t)} + v_{\bar{a}} \quad (48)$$

$$v_B(t) = \underbrace{\beta_b v_{b_1}(t) + \delta_b v_{b_2}(t)}_{v_b(t)} + v_{\bar{b}} \quad (49)$$

$$v_C(t) = \underbrace{\beta_c v_{b_1}(t) + \delta_c v_{b_2}(t)}_{v_c(t)} + v_{\bar{c}} \quad (50)$$

$$v_N(t) = \underbrace{\beta_n v_{b_1}(t) + \delta_n v_{b_2}(t)}_{v_n(t)} + v_{\bar{n}} \quad (51)$$

onde $v_a(t)$, $v_b(t)$, $v_c(t)$ e $v_n(t)$ representam a projeção de $v_A(t)$, $v_B(t)$, $v_C(t)$ e $v_N(t)$, respectivamente, no plano das tensões de linha e podem ser considerados sinais filtrados, já que são combinações lineares da base do plano, que por sua vez são filtradas. As parcelas que não são geradas pela base do plano são os sinais $v_{\bar{a}}(t)$, $v_{\bar{b}}(t)$, $v_{\bar{c}}(t)$ e $v_{\bar{n}}(t)$ e são consideradas ortogonais ao plano.

Os coeficientes β e δ em (48) - (51) são calculados por:

$$\beta_a = \frac{\langle v_A(t), v_{b_1}(t) \rangle}{\|v_{b_1}(t)\|^2} \quad (52)$$

$$\delta_a = \frac{\langle v_A(t), v_{b_2}(t) \rangle}{\|v_{b_2}(t)\|^2} \quad (53)$$

$$\beta_b = \frac{\langle v_B(t), v_{b_1}(t) \rangle}{\|v_{b_1}(t)\|^2} \quad (54)$$

$$\delta_b = \frac{\langle v_B(t), v_{b_2}(t) \rangle}{\|v_{b_2}(t)\|^2} \quad (55)$$

$$\beta_c = \frac{\langle v_C(t), v_{b_1}(t) \rangle}{\|v_{b_1}(t)\|^2} \quad (56)$$

$$\delta_c = \frac{\langle v_C(t), v_{b_2}(t) \rangle}{\|v_{b_2}(t)\|^2} \quad (57)$$

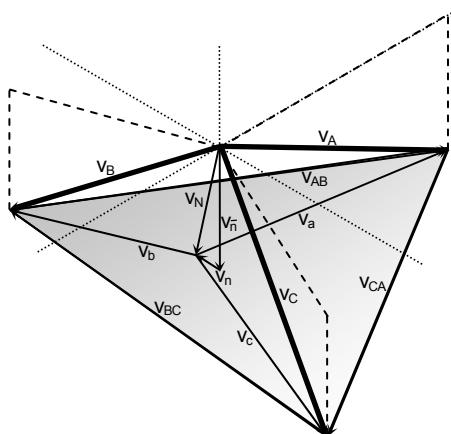
$$\beta_n = \frac{\langle v_N(t), v_{b_1}(t) \rangle}{\|v_{b_1}(t)\|^2} \quad (58)$$

$$\delta_n = \frac{\langle v_N(t), v_{b_2}(t) \rangle}{\|v_{b_2}(t)\|^2} \quad (59)$$

O desenvolvimento utilizado para projetar as tensões de fase e neutro no plano das tensões de linha pode ser utilizado para decompor, também, as correntes de fase $i_A(t)$, $i_B(t)$ e $i_C(t)$ e de neutro $i_N(t) = i_A(t) + i_B(t) + i_C(t)$ no plano.

A Figura 8 mostra as projeções $v_a(t)$, $v_b(t)$, $v_c(t)$ e $v_n(t)$ no plano das tensões de linha para ilustrar a decomposição apresentada. Nessa figura é possível ver o plano formado pelas tensões $v_{AB}(t)$, $v_{BC}(t)$ e $v_{CA}(t)$. Também são mostrados os sinais a serem projetados no plano $v_A(t)$, $v_B(t)$, $v_C(t)$ e $v_N(t)$. As parcelas ortogonais ao plano $v_{\bar{a}}(t)$, $v_{\bar{b}}(t)$ e $v_{\bar{c}}(t)$ não são mostradas para não carregar visualmente o diagrama, entretanto, a tensão $v_{\bar{n}}(t)$ foi deixada para demonstrar um desses sinais fora do plano.

Figura 8: Decomposição de sinais de tensão de fase no plano das tensões de linha.



Fonte: adaptado de Flauzino (2007).

Como pode ser observado na Figura 8, as equivalências $v_{AB}(t) = v_{ab}(t)$, $v_{BC}(t) = v_{bc}(t)$ e $v_{CA}(t) = v_{ca}(t)$ são verdadeiras. A fim de demonstrar esse resultado, faz-se a seguinte

verificação, considerando-se que $v_{b1}(t) = v_{AB}(t)$ e que $v_{b2}(t)$ é ortogonal à $v_{AB}(t)$:

$$\begin{aligned}
 v_{ab}(t) &= v_a(t) - v_b(t) = \beta_a v_{b1} + \delta_a v_{b2}(t) - \beta_b v_{b1} - \delta_b v_{b2}(t) \\
 &= (\beta_a - \beta_b)v_{AB}(t) + (\delta_a - \delta_b)v_{b2}(t) \\
 &= \left(\frac{\langle v_A(t), v_{AB}(t) \rangle}{\|v_{AB}(t)\|^2} - \frac{\langle v_B(t), v_{AB}(t) \rangle}{\|v_{AB}(t)\|^2} \right) v_{AB}(t) + \dots \\
 &\dots + \left(\frac{\langle v_A(t), v_{b2}(t) \rangle}{\|v_{b2}(t)\|^2} - \frac{\langle v_B(t), v_{b2}(t) \rangle}{\|v_{b2}(t)\|^2} \right) v_{b2}(t) \\
 &= \left(\frac{\langle v_A(t) - v_B(t), v_{AB}(t) \rangle}{\|v_{AB}(t)\|^2} \right) v_{AB}(t) + \left(\frac{\langle v_A(t) - v_B(t), v_{b2}(t) \rangle}{\|v_{b2}(t)\|^2} \right) v_{b2}(t) \\
 &= \left(\frac{\|v_{AB}(t)\|^2}{\|v_{AB}(t)\|^2} \right) v_{AB}(t) + \left(\frac{0}{\|v_{b2}(t)\|^2} \right) v_{b2}(t) \\
 &= v_{AB}(t)
 \end{aligned} \tag{60}$$

Pela mesma abordagem, verifica-se que as seguintes equivalências são todas verdadeiras:

$$v_{AB}(t) = v_{ab}(t) \tag{61}$$

$$v_{BC}(t) = v_{bc}(t) \tag{62}$$

$$v_{CA}(t) = v_{ca}(t) \tag{63}$$

o que demonstra a validade das projeções no plano das funções de linha.

Como consequência da projeção de $v_N(t)$ no plano e das equivalências (61) - (63), o sinal $v_n(t)$ é calculado pela soma das projeções $v_a(t)$, $v_b(t)$ e $v_c(t)$. Da mesma forma, $i_n(t)$ é dada pela soma das projeções $i_a(t)$, $i_b(t)$ e $i_c(t)$. Esses corolários podem ser observados na Figura 8 e são dados por (64) e (65).

$$v_n(t) = v_a(t) + v_b(t) + v_c(t) \tag{64}$$

$$i_n(t) = i_a(t) + i_b(t) + i_c(t) \tag{65}$$

Aplicando este segundo princípio, versões filtradas das tensões e correntes de fase e neutro, chamadas de tensões e correntes planares são obtidas: $v_a(t)$, $v_b(t)$, $v_c(t)$, $v_n(t)$, $i_a(t)$, $i_b(t)$, $i_c(t)$ e $i_n(t)$. Versões não filtradas, chamadas de não planares também são obtidas: $v_{\bar{a}}(t)$, $v_{\bar{b}}(t)$, $v_{\bar{c}}(t)$, $v_{\bar{n}}(t)$, $i_{\bar{a}}(t)$, $i_{\bar{b}}(t)$, $i_{\bar{c}}(t)$ e $i_{\bar{n}}(t)$.

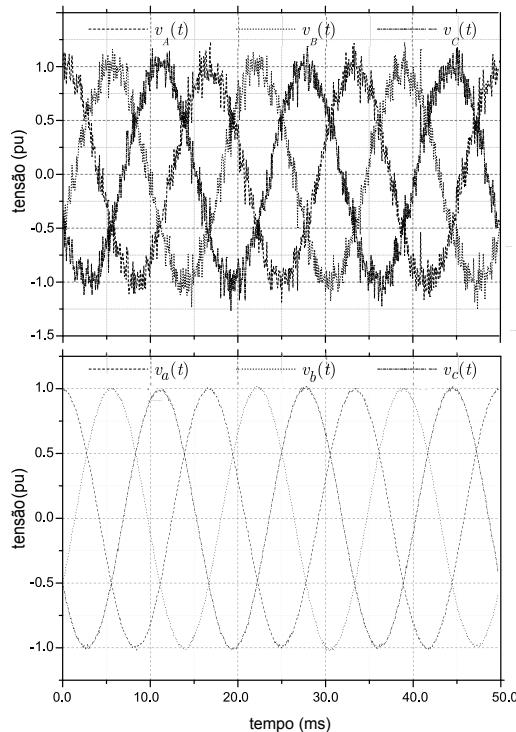
Uma demonstração simples mostra como o segundo princípio é capaz de filtrar sinais trifásicos. Considere os seguintes sinais de fase para um sistema trifásico:

$$\begin{cases} v_A(t) = \cos(120\pi t) + r_A(t) \\ v_B(t) = \cos(120\pi t - 2/3\pi) + r_B(t) \\ v_C(t) = \cos(120\pi t + 2/3\pi) + r_C(t) \end{cases} \tag{66}$$

onde $r_A(t)$, $r_B(t)$ e $r_C(t)$ são ruídos brancos. Esses ruídos podem representar, por exemplo, interferências de um sistema de aquisição. A Figura 9 ilustra essas formas de onda expressas em (66).

Como já exposto, as tensões de linha para um sistema trifásico são linearmente dependentes e coplanares e qualquer projeção no plano das tensões de linha resulta em sinais gerados pela base desse plano, ou seja, resulta em sinais filtrados. A projeção dos sinais de fase em (66), representadas por $v_a(t)$, $v_b(t)$ e $v_c(t)$, são calculadas de acordo com (48) - (51). Na Figura 9 mostra-se a redução do ruído nos sinais projetados no plano.

Figura 9: Tensões de fase com ruídos $v_A(t)$, $v_B(t)$ e $v_C(t)$ e projeções filtradas no plano das tensões de linha $v_a(t)$, $v_b(t)$ e $v_c(t)$.



Fonte: elaborado pela autora.

Em sistemas trifásicos é então possível utilizar os dois princípios para obter as componentes ortogonais, como explicita-se a seguir.

3.3 Obtendo as Componentes Ortogonais

Os dois princípios apresentados anteriormente são utilizados para obter as componentes ortogonais. Primeiramente, os sinais são decompostos em parcelas planares e não planares utilizando-se o segundo princípio. Depois cada par tensão/corrente obtido é adicionalmente decomposto em informações elétricas utilizando-se o primeiro princípio. Dessa forma, 64 componentes ortogonais são obtidas. Por exemplo, uma função de corrente planar da fase A, $i_a(t)$, pode ser decomposta no subespaço das tensões planares da

fase A, $v_a(t)$, $\dot{v}_a(t)$ e $v_a^\perp(t)$, além de i_a^d , utilizando-se o primeiro princípio:

$$i_a(t) = \underbrace{i_a^p(t)}_{v_a^p(t)} + \underbrace{i_a^{q\parallel}(t)}_{v_a^{q\parallel}(t)} + \underbrace{i_a^{q\perp}(t)}_{v_a^{q\perp}(t)} + i_a^d(t) \quad (67)$$

Da mesma forma, uma tensão não planar da fase A, $v_{\bar{a}}(t)$, pode ser decomposta no subespaço da corrente não planar da fase A, $i_{\bar{a}}(t)$, $\dot{i}_{\bar{a}}(t)$ e $i_{\bar{a}}^\perp(t)$, além de $v_{\bar{a}}^d(t)$. Isso resulta em:

$$v_{\bar{a}}(t) = \underbrace{\gamma_1 i_{\bar{a}}^p(t)}_{v_{\bar{a}}^p(t)} + \underbrace{\gamma_2 i_{\bar{a}}^{q\parallel}(t)}_{v_{\bar{a}}^{q\parallel}(t)} + \underbrace{\gamma_3 i_{\bar{a}}^{q\perp}(t)}_{v_{\bar{a}}^{q\perp}(t)} + v_{\bar{a}}^d(t) \quad (68)$$

Uma justificativa heurística do porque essa decomposição é sensível à condição de operação e aos parâmetros do sistema é relacionada ao fato dos coeficientes α e γ representarem resistências e potência ativa, capacitâncias, indutâncias e potências reativas e o restante das parcelas serem relacionados com conteúdos não lineares ou que não são possíveis de serem representados por componentes elétricos passivos. É importante observar que as componentes ortogonais são altamente sensíveis a eventos que mudem a condição e os parâmetros do sistema, assim como seu consumo de potência. Dessa forma, 64 componentes ortogonais, dependentes do tempo, são obtidas como mostra o diagrama da Figura 10.

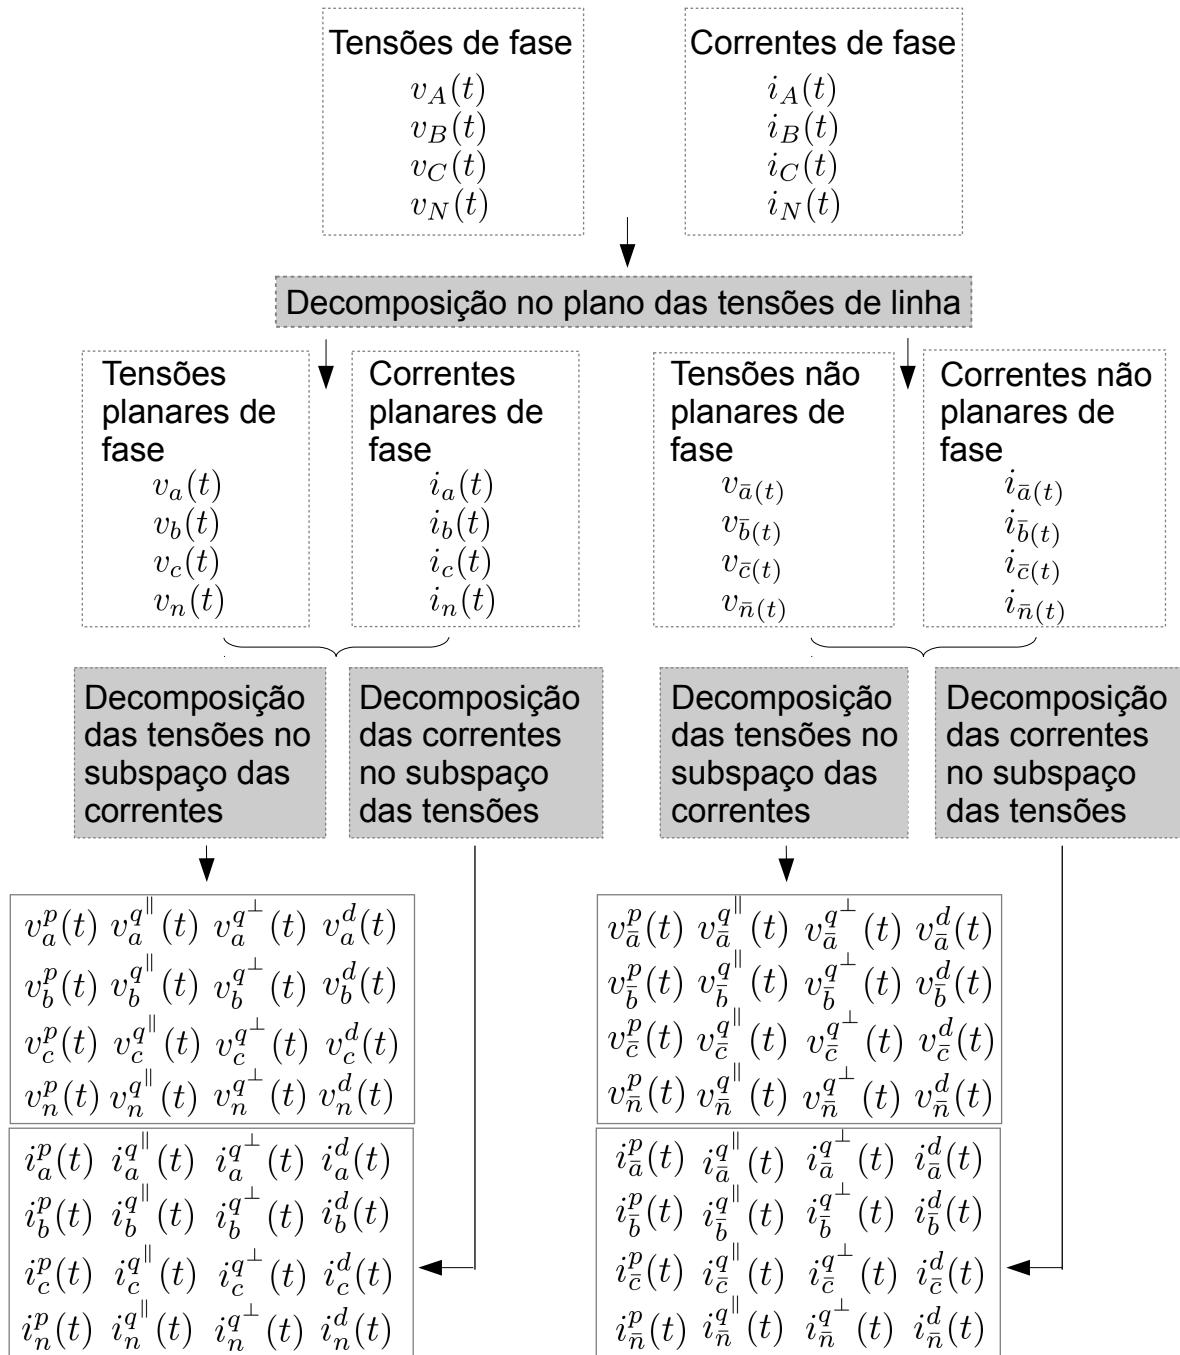
3.4 Contribuições da Decomposição em Componentes Ortogonais à Teoria de Potências

Uma das contribuições deste trabalho é detalhar e desdobrar a ferramenta matemática da DCO. Frente a análises cuidadosas de seu desenvolvimento matemático e da literatura, percebe-se que a ferramenta pode contribuir positivamente com novas definições na área de teoria de potências. A seguir faz-se um detalhamento dessas contribuições, que podem também ser, em parte, encontradas no artigo que foi publicado no periódico *Electric Power System Research* durante a elaboração desta pesquisa (LIBONI et al., 2016).

O intuito de definir termos e modelar sinais elétricos é prevenir tensões e correntes não desejadas, permitir medições não ambíguas e perceber mudanças em parâmetros do sistema em análise. Inúmeras decomposições de sinais elétricos diferem principalmente na interpretação física dada ao fenômeno de transferência de potência e a definição dos termos que os representam (CZARNECKI, 2011). Essas decomposições compõem o campo de conhecimento denominado teoria de potências. Muitas decomposições de sinais elétricos são estudadas no campo de teoria de potências, como, por exemplo, as decomposições de Budeanu, Fryze, Shephard e Zakikhani, Kusters e Moore, Czarnecki, entre outras.

Na teoria clássica de potência para circuitos puramente senoidais definem-se termos como P , Q e S referindo-se às potências ativa, reativa e aparente complexa. Porém, esse

Figura 10: Passos da DCO para a obtenção das componentes ortogonais.



Fonte: elaborado pela autora

modelo clássico não se mostra aplicável a circuitos com conteúdo harmônico e não linear, já que o balanço de energia não se sustenta. De forma a analisar essa questão, considera-se um circuito monofásico puramente senoidal alimentado por uma tensão $v(t)$ e consumindo uma corrente $i(t)$ dados por:

$$v(t) = \sqrt{2}V \cos(2\omega t + \alpha) \quad (69)$$

$$i(t) = \sqrt{2}I \cos(2\omega t + \beta) \quad (70)$$

onde $\varphi = \alpha - \beta$.

A potência instantânea é então definida como:

$$\begin{aligned} p(t) &= v(t)i(t) = VI \cos \varphi (1 + \cos(2\omega t + 2\alpha)) + VI \sin \varphi \sin(2\omega t + 2\alpha) \\ p(t) &= P (1 + \cos(2\omega t + 2\alpha)) + Q \sin(2\omega t + 2\alpha) \end{aligned} \quad (71)$$

onde

$$P = VI \cos \varphi \quad (72)$$

$$Q = VI \sin \varphi \quad (73)$$

A primeira parcela em (71) descreve uma parte da potência instantânea não negativa com amplitude $2P$ e valor médio P e representa uma quantidade unidirecional de energia sendo levada para a carga. A segunda parcela descreve uma parte da potência que é alternada e com valor médio nulo. Essa parcela descreve o fluxo bidirecional de energia entre a fonte e a carga. Essa última, não se faz presente caso o circuito apresente $\varphi = 0$. Assim, para circuitos puramente senoidais, a quantidade de energia Q é utilizada para gerar campos elétricos e magnéticos em elementos passivos reativos. Já a potência complexa S não possui um sentido físico, sendo puramente uma quantidade computada. Representando-se os sinais por fasores, a potência complexa é definida como:

$$S = \mathbf{V} \mathbf{I}^* = P + jQ \quad (74)$$

$$|S| = |\mathbf{V}| |\mathbf{I}| \quad (75)$$

$$|S|^2 = P^2 + Q^2 \quad (76)$$

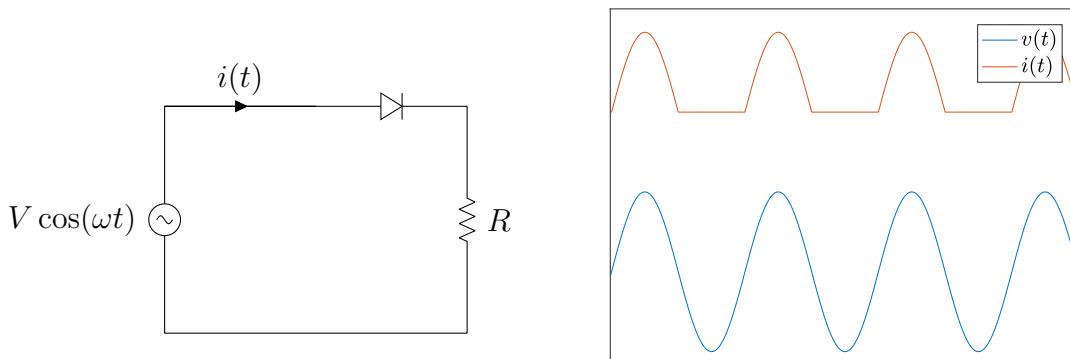
onde $|S|$ é denominado potência aparente, \mathbf{V} e \mathbf{I} são, respectivamente, a representação fasorial de $v(t)$ e $i(t)$ e o operador “ $*$ ” representa o conjugado de uma grandeza complexa. Pela forma a qual foi definida, a quantidade complexa S , ativa P e reativa Q estão sujeitas a um balanço de energia, como mostrado em (76). Por fim, o fator de potência λ é definido como a relação entre potência ativa e potência aparente:

$$\lambda = \cos \varphi = \frac{P}{|S|} \quad (77)$$

Em sistemas puramente senoidais, o fator de potência indica uma relação entre potências, ou seja, uma redução da quantidade reativa (compensação) da potência deve causar

a minimização do valor RMS da corrente elétrica, sem alterar a potência ativa. Porém, pode-se provar que em sistemas não lineares e não puramente senoidais a potência reativa, como definida para sistemas senoidais não se relaciona apenas à acumulação de energia em componentes passivos reativos e pode estar presente inclusive em circuitos puramente resistivos (CZARNECKI, 1985). Por exemplo, considere o circuito retificador na Figura 11.

Figura 11: Circuito retificador com característica não linear. Pela teoria clássica de potências para sistemas senoidais, possui potência ativa e reativa. Porém, não há fluxo recíproco de energia entre fonte e carga.



Fonte: elaborado pela autora.

No circuito da Figura 11, pela teoria clássica de potências, a potência ativa e reativa são dadas por (72) e (73) e valem $P = Q = V^2/(4R)$. Porém, a potência instantânea como calculada em (71) é sempre positiva e desta forma, não há fluxo recíproco de energia entre a carga e a fonte, como pode ser comprovado pela multiplicação das formas de onda de tensão e corrente, além de não possuir elementos armazenadores de energia.

Ademais, no caso de sinais não puramente senoidais em circuitos lineares, a discussão clássica em potência e correntes de natureza reativa e suas definições são controversas (CZARNECKI, 1987; CZARNECKI, 1991; BALCI; HOCAOGLU, 2008). O conceito de reativo como definido em sistemas puramente senoidais é perdido e sua modelagem não preenche as condições causadas por tensões e correntes não senoidais (BALCI; HOCAOGLU, 2008). Algumas teorias foram então pensadas para circuitos lineares não puramente senoidais.

A teoria mais difundida para o estudo de potências em circuitos lineares com forma de ondas distorcidas é a teoria de potência de Budeanu. Nessa teoria, na qual a tensão $v(t)$ e a corrente $i(t)$ são dadas por (78) e (79), define-se a potência ativa e a potência reativa como uma superposição das respectivas potências de todas as harmônicas presentes nos

sinais, como mostrado em (80) e (81). A potência aparente resultante é descrita em (82).

$$v(t) = V_0 + \sqrt{2}V_h \cos(h\omega t + \alpha_h) \quad (78)$$

$$i(t) = I_0 + \sqrt{2}I_h \cos(h\omega t + \beta_h) \quad (79)$$

$$P = V_o I_o + \sum_{h=1}^{\infty} V_h I_h \cos(\varphi_h) = \sum P_h \quad (80)$$

$$Q_b = \sum_{h=1}^{\infty} V_h I_h \sin(\varphi_h) = \sum Q_h \quad (81)$$

$$|S| = \sqrt{\left(\sum_{h=1}^{\infty} V_h^2 \right) \left(\sum_{h=1}^{\infty} I_h^2 \right)} \quad (82)$$

Uma inequação surge quando os termos são definidos dessa forma, pois, $|S|^2 \geq |P|^2 + |Q_b|^2$, diferentemente do que se obteria para circuitos puramente senoidais. De forma a completar a inequação, Budeanu introduziu uma nova quantidade chamada de potência de distorção D_b :

$$|S|^2 = P^2 + Q_b^2 + D_b^2 \quad (83)$$

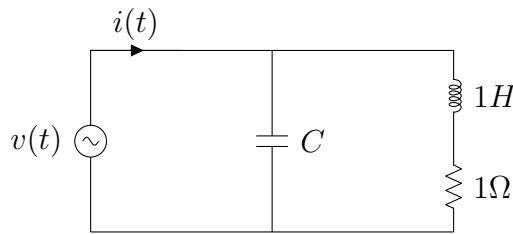
Porém, o conceito de distorção nunca foi definido. De fato, D_b se anula quando as formas de onda do circuito em análise são senoidais, porém também se anula se as tensões distorcidas forem aplicadas a cargas resistivas, ou seja, nas quais a corrente elétrica da carga não é distorcida em relação à tensão.

Como definido, a potência reativa e de distorção de Budeanu não se relacionam completamente com o fenômeno real de transferência de potência em circuitos lineares e, dessa forma, seus valores não fornecem informações necessárias para o projeto de circuitos compensadores de reativos. Com essas definições a teoria perde o sentido físico já que os reativos, para Budeanu, significam a soma de amplitudes Q_h . Entretanto, cada componente tem uma diferente frequência e pode ter diferentes defasagens. Assim, essa soma não traduz a amplitude da soma total das componentes alternadas da potência instantânea. Como exemplo, pode-se obter uma soma Q_b nula mesmo com valores não nulos de Q_h , ou seja, mesmo havendo fluxo alternado de energia entre a fonte e a carga. Dessa forma, a potência de distorção D_b também é afetada por potências recíprocas entre carga e fonte e não pode ser separada do fenômeno da presença de elementos reativos em um circuito linear não senoidal.

Para explicitar que o efeito reativo é ambíguo nessa teoria, Czarnecki (1987) mostra um circuito não puramente senoidal, no qual o objetivo é minimizar o valor RMS da corrente do circuito e maximizar o fator de potência mediante de uma compensação passiva de reativos. Nesse circuito, apesar da potência Q_b ser compensada, o fator de potência praticamente não se altera, demonstrando que o efeito físico do reativo não é retratado em Q_b , já que não houve diminuição do valor eficaz da corrente consumida e há ainda potência instantânea recíproca entre fonte e carga. O circuito simulado pode ser visto na Figura 12.

Em seus trabalhos, Czarnecki também mostra que apesar do nome tratar de distorção, a parcela D_b não provê informações sobre a distorção das formas de onda, mostrando que em circuitos sem distorção entre tensão e corrente, a quantidade D_b pode existir (CZARNECKI, 1985; CZARNECKI, 1987; CZARNECKI, 2011). Na realidade essa quantidade apenas veio a preencher a inequação conseguida por Budeanu.

Figura 12: Circuito simulado para compensação de reativos. Os valores apresentados na coluna (1) se referem ao circuito sem a compensação feita pelo capacitor C . Os valores da coluna (2) se referem ao circuito compensado. A tensão de alimentação é dada por $v(t) = 100 \cos(t) + \frac{100}{5} \cos(5t) + \frac{100}{7} \cos(7t)$.



Quantidade	Unidade	(1)	(2)
C	F	-	0.3802
S	VA	7296	7259
Q_b	VA	5105	0
D_b	VA	1407	5244
λ	-	0.688	0.691 %

Fonte: adaptado de (CZARNECKI, 1987).

A teoria de Fryze surgiu depois da teoria de Budeanu, em 1931, para sistemas não senoidais e considera a modelagem dos sinais elétricos no domínio tempo, ou seja, considerando-os como vetores no tempo. Desta forma, a potência ativa, aparente e o fator de potência de um circuito monofásico são definidos como:

$$P = \frac{1}{T} \int_{t-T}^t v(t)i(t)dt \quad (84)$$

$$|S| = \sqrt{\frac{1}{T} \int_{t-T}^t v(t)^2 dt} \sqrt{\frac{1}{T} \int_{t-T}^t i(t)^2 dt} \quad (85)$$

$$\lambda = \frac{P}{|S|} \quad (86)$$

Fryze tentou generalizar a descrição de energia para formas de onda puramente senoidais e também para qualquer onda periódica. A teoria diz que a corrente elétrica pode ser decomposta na soma de duas funções reciprocamente ortogonais, ou seja:

$$i(t) = i_p(t) + i_F(t) \quad (87)$$

A corrente $i_p(t)$ traduz uma relação linear com a tensão dada por:

$$i_p(t) = \frac{\frac{1}{T} \int_{t-T}^t v(t)i(t)dt}{\|v(t)\|^2} v(t) \quad (88)$$

Como as duas componentes são ortogonais, a potência ativa P pode então ser reescrita como abaixo:

$$\begin{aligned} P &= \frac{1}{T} \int_{t-T}^t v(t)i(t)dt = \frac{1}{T} \int_{t-T}^t v(t)i_p(t)dt \\ P &= \|v(t)\| \|i_p(t)\| \end{aligned} \quad (89)$$

Na decomposição de Fryze as definições de potência são uma consequência da decomposição dos sinais elétricos de corrente. Mantendo-se a ortogonalidade, pode-se dizer que:

$$\|i(t)\|^2 = \|i_p(t)\|^2 + \|i_F(t)\|^2 \quad (90)$$

Multiplicando-se a equação anterior por $\|v(t)\|^2$ obtém-se uma equação de potência como consequência:

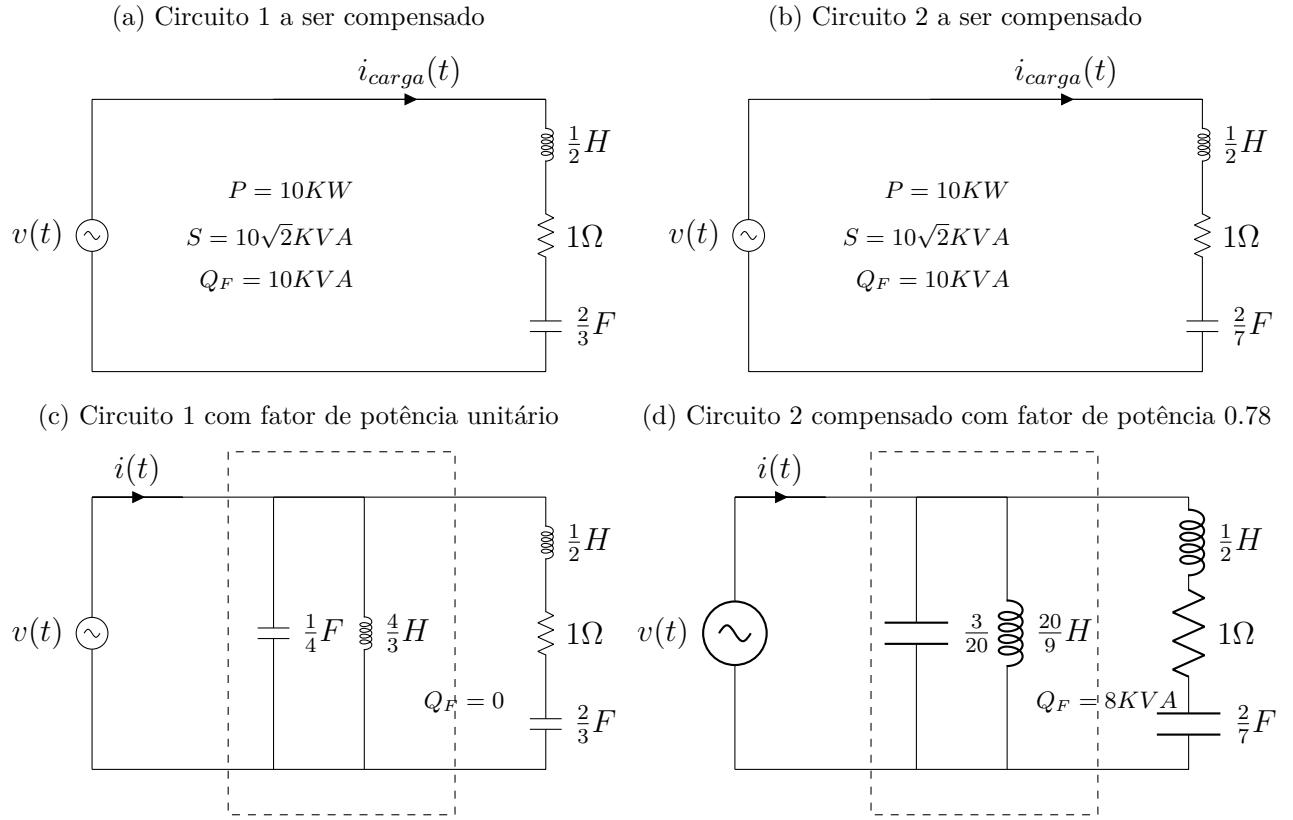
$$|S|^2 = P^2 + Q_F^2 \quad (91)$$

A potência reativa de Fryze é então definida como o remanescente da corrente depois de calculada a corrente ativa, como evidenciado em (92).

$$Q_F = \|v(t)\| \|i_F(t)\| \quad (92)$$

A decomposição de Fryze possui uma maior funcionalidade se comparada com a de Budeanu, pois a decomposição em partes ativas e reativas de corrente se dá com quantidades primárias (tensões e correntes) e a utilização das séries de Fourier não é necessária. Porém, novamente, a teoria de Fryze não esclarece o porquê, a priori, uma rede linear de reatâncias não é capaz de compensar totalmente o fator de potência de determinados circuitos com harmônicas, como exemplificado em (CZARNECKI, 1985). Isso demonstra que Q_F pode não representar o fluxo de energia bidirecional no sistema, pois em algumas redes com iguais características, a minimização da potência aparente para o valor da potência ativa não se realiza. Na Figura 13, os dois circuitos não compensados possuem a mesma descrição de P , Q_F e S . Pela decomposição de Fryze, a potência reativa Q_F no primeiro circuito compensado se torna nula com a inserção do conjunto reativo em destaque. Já no caso da segunda rede, a potência Q_F assume 8 KVA após a compensação. Desta forma, não é possível saber a priori, com as informações de P , Q_F e S , se é possível ou não compensar um circuito completamente à partir de um conjunto reativo. Portanto, Q_F representa uma medida de eficiência do sistema, mas não explica corretamente o efeito da troca recíproca de energia entre elementos.

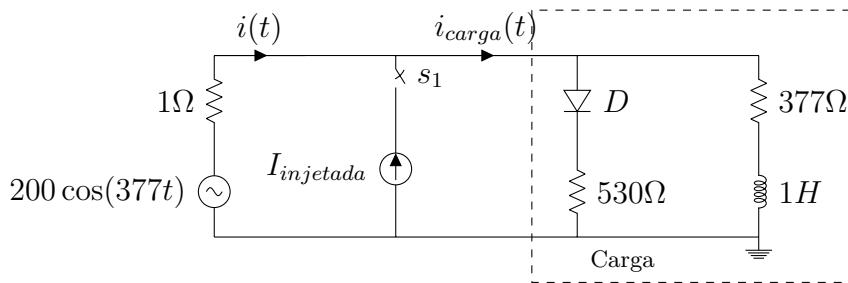
Figura 13: Circuitos compensados com elementos reativos onde $v(t) = 100\sqrt{2}(\text{sent} + \text{sen}3t)$. A potência $Q_F = 0$ para o primeiro circuito compensado e $Q_F = 8 \text{ KVA}$ para o segundo circuito compensado.



Fonte: elaborado pela autora

De qualquer forma, a teoria de Fryze permitiu o surgimento da compensação por filtros ativos, onde a corrente desejada no circuito é a corrente ativa $i_p(t)$. Na Figura 14, mostrase um circuito não linear com carga reativa a ser compensado por um ramo paralelo. O ramo compensador é conectado de forma a se obter a situação de minima potência consumida, na qual a corrente com defasagem deve ser compensada, assim como correntes com conteúdo harmônico distintos da tensão.

Figura 14: Circuito com compensação ativa de reativos. O circuito foi simulado e a partir de 5 segundos a chave S_1 foi fechada para a compensação.



Fonte: elaborado pela autora

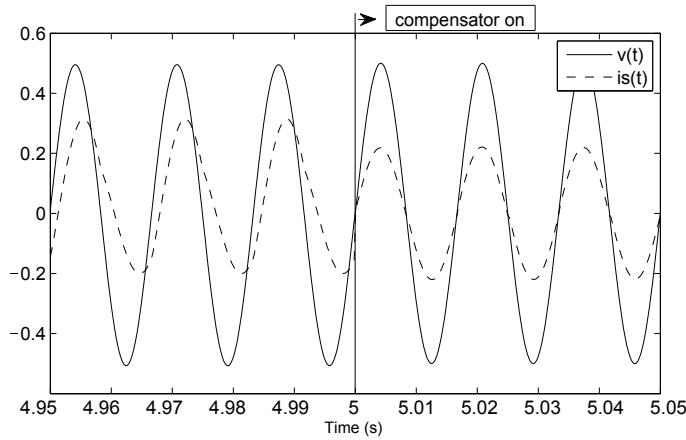
A corrente injetada pelo compensador é dada por:

$$i_{injetada} = i(t) - i_p(t) \quad (93)$$

A corrente injetada, representa a diferença entre as corrente total da carga $i(t)$ e a corrente $i_p(t)$, que é responsável por fornecer a potência ativa. Dessa forma, pela injeção de $i_{injetada}(t)$, a corrente de linha se torna igual à $i^p(t)$ e, portanto, colinear à tensão de alimentação.

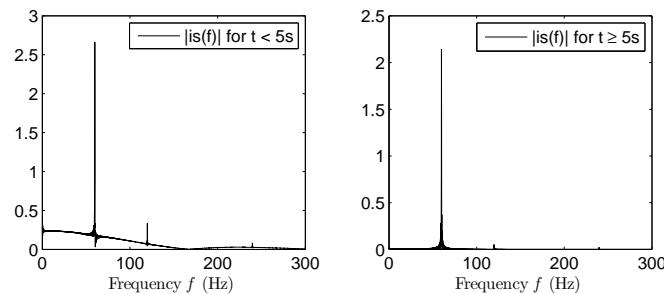
A Figura 15 mostra que a compensação removeu as defasagens entre tensão e corrente. Além disso, a Figura 16 mostra que houve redução de conteúdo harmônico após a compensação, sendo a corrente praticamente senoidal.

Figura 15: Circuito com compensação ativa de reativos. Formas de onda da tensão $v(t)$ e corrente $i(t)$ próximas à $t = 5s$, quando a chave S_1 é fechada.



Fonte: elaborado pela autora

Figura 16: Espectro da corrente $i(t)$ para o circuito com compensação ativa de reativos. Na esquerda está representado o espectro da corrente $i(t)$ do circuito antes da compensação. Na direita está o espectro de $i(t)$ após a compensação.



Fonte: elaborado pela autora

Outras decomposições de potência e sinais elétricos abordaram o problema no domínio da frequência, já que a representação da potência flutuante ainda está em aberto. Em

1980, Kusters e Moore apresentaram uma teoria que ainda decompunha os sinais no domínio do tempo. Eles decomporam a corrente em corrente ativa, corrente reativa (capacitiva ou indutiva) e corrente reativa residual, apresentando uma parcela a mais de corrente em relação à decomposição de Fryze. Essas parcelas são decompostas como a seguir:

$$i(t) = i_p(t) + i_q(t) + i_{qr}(t) \quad (94)$$

$$i_p(t) = \frac{\frac{1}{T} \int_{t-T}^t v(t)i(t)dt}{\|v(t)\|^2} v(t) \quad (95)$$

$$i_q(t) = \frac{\frac{1}{T} \int_{t-T}^t v'(t)i(t)dt}{\|v'(t)\|^2} v'(t) \quad (96)$$

$$i_{qr}(t) = i(t) - i_p(t) - i_q(t) \quad (97)$$

Na decomposição de Kusters e Moore, *Kusters and Moore Decomposition* (KMD), o sinal é decomposto em corrente ativa $i_p(t)$, a qual a definição é a mesma que a componente ortogonal $i^p(t)$ em (35) e em (88), conhecida como a corrente ativa de Fryze; em corrente reativa capacitiva ou indutiva $i_q(t)$, dependendo da característica geral da carga, a qual possui a mesma definição da componente ortogonal $i^{q\parallel}(t)$ em (35); e por fim, em uma corrente residual $i_{qr}(t)$.

Como já explicitado para sinais puramente senoidais, a corrente reativa $i_q(t)$ pode ser completamente compensada com componentes passivos, resultando em fator de potência unitário. Por exemplo, uma corrente senoidal capacitiva pode ser totalmente compensada com a injeção de uma corrente senoidal indutiva devido aos seus efeitos opostos, como mostrado na Figura 6. Desta forma, na KMD os termos reativos são definidos de forma inequívoca, pelo menos quando os sinais são puramente senoidais.

Ao traçar um paralelo entre a KMD e a DCO, percebe-se que a ortogonalização feita em (31) pode definir um novo conceito de corrente reativa e pode rastrear componentes reativos de uma maneira mais apropriada, principalmente quando o sistema analisado é linear com presença de conteúdo harmônico. Como formulado no primeiro princípio da DCO quando um componente reativo, por exemplo um capacitor, é inserido em um sistema não puramente senoidal, uma parte de sua contribuição, designada $i^{q\parallel}(t)$, conta para a corrente reativa clássica, que é a mesma computada no termo $i_q(t)$ da KMD. Entretanto, uma outra parte dessa contribuição e que não está presente na KMD, denominada $i^{q\perp}(t)$, é também computada. Neste caso, o processo de ortogonalização consegue rastrear mais este aspecto do parâmetro reativo, traduzindo, de forma, mais completa, o efeito de sua existência em um sistema não puramente senoidal.

Esta nova parcela $i^{q\perp}(t)$ calculada pela DCO estaria, então, mascarada na parcela residual $i_{qr}(t)$ da KMD, a qual também conta com informações que não podem ser modeladas por elementos elétricos passivos. Já na DCO, uma completa separação e conhecimento

dos efeitos de um elemento reativo em um sistema não senoidal é atingido. Assim, não cabe apenas à corrente reativa $i_q^{\parallel}(t)$ representar a potência reativa sob o aspecto de armazenamento de energia em elementos passivos, mas sim à $i^{q\parallel}(t) + i^{q\perp}(t)$.

Como exemplo deste novo conceito, aplicou-se a DCO nos exemplos monofásicos da Figura 13. A decomposição da corrente $i_{carga}(t)$ no subespaço da tensão $v(t)$ no circuito (a) sem compensação resultou em:

$$i_{carga}(t) = \underbrace{0,5 v(t)}_{i_{carga}^p(t)} - \underbrace{0,1 \dot{v}(t)}_{i_{carga}^{q\parallel}(t)} - \underbrace{0,75 v(t)^{\perp}}_{i_{carga}^{q\perp}(t)} + 0 i^d(t) \quad (98)$$

O ramo compensador introduz uma corrente $i_{comp}(t)$. Essa corrente, pode ser também decomposta no subespaço de $v(t)$ e resulta em:

$$i_{comp}(t) = 0 v(t) + 0,1 \dot{v}(t) + 0,75 v(t)^{\perp} + 0 i^d(t) \quad (99)$$

Nota-se que o ramo compensador é capaz de anular todos os termos reativos do circuito e a corrente $i(t)$ do circuito compensado (c) pode ser decomposta em:

$$i(t) = 0,5 v(t) + 0 \dot{v}(t) + 0 v(t)^{\perp} + 0 i^d(t) \quad (100)$$

Este resultado é coerente com o fato de que a potência instantânea $p(t)$ do circuito compensado não possui parcelas flutuantes entre a carga e a fonte.

Já para o circuito (b) sem compensação, a decomposição da corrente $i_{carga}(t)$ no subespaço da tensão $v(t)$ resulta em:

$$i_{carga}(t) = 0,5 v(t) - 0,06 \dot{v}(t) - 0,045 v(t)^{\perp} + i^d(t) \quad (101)$$

A corrente $i^d(t)$ é não nula e vale $i^d(t) = -56,57 \text{ sent} + 56,57 \text{ sen}3t$. O ramo compensador introduz uma corrente $i_{comp}(t)$. Essa corrente, pode ser também decomposta no subespaço de $v(t)$ e resulta em:

$$i_{comp}(t) = 0 v(t) + 0,06 \dot{v}(t) + 0,045 v(t)^{\perp} + 0 i^d(t) \quad (102)$$

Então, finalmente, a corrente $i(t)$ do circuito compensado (d) pode ser decomposta em:

$$i(t) = 0,5 v(t) + 0 \dot{v}(t) + 0 v(t)^{\perp} + i^d(t) \quad (103)$$

Nota-se que o ramo compensador é capaz de anular os termos $i_{carga}^{q\parallel}(t) = -0,06 \dot{v}(t)$ e $i_{carga}^{q\perp}(t) = -0,045 v(t)^{\perp}$ do circuito, porém, ele não é capaz de gerar a corrente $i^d(t)$. Essa parcela, é uma parcela que não pode ser obtida por elementos passivos reativos e, então, sua existência prévia na decomposição da corrente de carga indica que o circuito não terá eficiência máxima e não poderá ser completamente compensado com a inserção de um ramo reativo em paralelo.

A análise de Fryze para ambos os circuitos sem compensação da Figura 13 (a) e (b) resultava em $Q_F = 10 \text{ KVA}$. Desta forma, não se poderia explicar de antemão o porquê

o segundo circuito não poderia ser totalmente compensado. Com a DCO, uma análise a priori consegue mostrar que a existência de $i^d(t)$ no segundo circuito indica que um ramo capacitivo-indutivo não será capaz de compensá-lo. Consequentemente, há componente recíproca da potência instantânea no circuito (b). Fato este, que não ocorre no circuito (a).

Como já explicitado em (35), a norma quadrática da corrente elétrica pode ser obtida por:

$$\|i(t)\|^2 = \|i^p(t)\|^2 + \|i^{q\parallel}(t)\|^2 + \|i^\perp(t)\|^2 + \|i^d(t)\|^2 \quad (104)$$

e multiplicando-se por $\|v(t)\|^2$ de ambos os lados de forma a se introduzir conceitos de potência junto à DCO obtém-se:

$$|S|^2 = P^2 + Q^{\parallel 2} + Q^{\perp 2} + E^2 \quad (105)$$

onde P é a potência ativa, Q^{\parallel} e Q^{\perp} são potências reativas passíveis de serem compensadas por elementos reativos e E é uma potência que não é passível de compensação por estes elementos e ajuda a representar a eficiência do circuito. Nos exemplos tratados, a DCO consegue mostrar que se as potências reativas Q^{\parallel} , Q^{\perp} e a potência E forem todas nulas, então, não há, em um circuito linear, uma parcela recíproca da potência instantânea entre a fonte e a carga, como é o caso do circuito compensado (c). Já no circuito compensado (d), apesar da compensação completa de Q^{\parallel} e Q^{\perp} , há ainda uma parcela não compensada e está leva à existência de fluxo recíproco de energia entre carga e fonte.

No circuito da Figura 17, o fator de potência máximo de aproximadamente 0,52 é obtido com a inserção do capacitor C com valor 0,1356 F. A DCO consegue explicar, a priori, o porque não é possível compensar totalmente este circuito com um ramo capacitivo e a existência de potência flutuante entre a carga e a fonte. A decomposição da corrente $i(t)$ do circuito não compensado nas novas potências trazidas pela DCO resulta em:

$$P_{carga} = 2 \text{ KW} \quad (106)$$

$$Q^{\parallel}_{carga} = 2366,88 \text{ KVA} \quad (107)$$

$$Q^{\perp}_{carga} = 3260 \text{ KVA} \quad (108)$$

$$E_{carga} = 236 \text{ KVA} \quad (109)$$

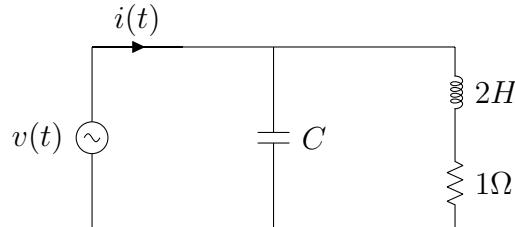
Assim, nenhum conjunto capacitivo conseguirá compensar completamente a existência de Q^{\perp}_{carga} e E_{carga} . O ramo compensador introduz uma corrente $i_{comp}(t)$, que é apenas capaz de compensar Q^{\parallel} , como visto a seguir.

$$Q^{\parallel}_{comp} = 2367,22 \text{ KVA} \quad (110)$$

$$Q^{\perp}_{comp} = 0 \text{ KVA} \quad (111)$$

$$E_{comp} = 0 \text{ KVA} \quad (112)$$

Figura 17: Circuito simulado para compensação de reativos. Compensação máxima é atingida pelo capacitor $C = 0,136 \text{ F}$. Com $v(t) = 100\sqrt{2} \text{ sent} + \frac{100}{11}\sqrt{2} \text{ sen}(11t) + \frac{100}{13}\sqrt{2} \text{ sen}(13t)$.



Fonte: elaborado pela autora

Dessa forma, ainda há potência flutuante entre a carga e a fonte no circuito. Um sistema elétrico linear não terá potência flutuante entre carga e fonte, somente se todas as parcelas de potência reativas Q_{carga}^{\parallel} , Q_{carga}^{\perp} e da potência E_{carga} se anularem, como é o caso do circuito (a), no qual, o conjunto capacitivo-indutivo é capaz de compensar Q_{carga}^{\parallel} e Q_{carga}^{\perp} e não há a existência prévia da potência E_{carga} .

Em circuitos não lineares, os termos da DCO a descontar a corrente ativa, indicam a eficiência do sistema e podem não estar inteiramente relacionados com a potência flutuante entre carga e fonte, porém seus termos trazem um novo benefício de forma a interpretar o fenômeno de transferência de energia. Considerando-se o caso do retificador da Figura 11, a decomposição de potências associadas à DCO resulta em:

$$P_{carga} = \frac{V^2}{4R} \text{ KW} \quad (113)$$

$$Q_{carga}^{\parallel} = 0 \text{ KVA} \quad (114)$$

$$Q_{carga}^{\perp} = 0 \text{ KVA} \quad (115)$$

$$E_{carga} = \frac{V^2}{4R} \text{ KVA} \quad (116)$$

Diferentemente de outras decomposições em sistemas não lineares, a existência de E com a concomitante inexistência de Q^{\parallel} , Q^{\perp} indica que não há elementos reativos passivos no sistema, ou eles foram completamente compensados. Este resultado é vantajoso em relação às teorias clássicas, de Fryze e da KMD, já que todas as outras, indicariam uma parcela reativa Q existente no circuito.

Portanto, a DCO vem a contribuir de forma a definir inequivocamente a existência da potência recíproca entre carga e fonte para circuitos lineares, tanto em situações puramente senoidais quanto em situações com a presença de harmônicos. Além disso, em circuitos não lineares, a DCO consegue mostrar se há no circuito a presença de elementos armazenadores de energia e desvincular sua presença ao fator de potência não unitário.

Além de todas as potencialidades da DCO já explicitadas, a partir das definições e conceitos abordados, é possível então determinar mutuamente o valor de capacidade e

indutância que se colocados em paralelo, independente da característica da carga, minimizam a potência aparente a partir dos vetores de corrente e tensão no \mathbb{R}^∞ .

O valor da capacitância e da indutância de compensação devem tornar nula a derivada primeira da corrente de alimentação, dada por:

$$\|i(t)\|^2 = \left\| i_{carga}(t) + C\dot{v}(t) + \frac{1}{L}\tilde{v}(t) \right\|^2 \quad (117)$$

Assim, pode-se escrever:

$$\frac{\partial \|i(t)\|^2}{\partial C} = \frac{\partial}{\partial C} \left(\|i_{carga}(t)\|^2 + C^2 \|\dot{v}(t)\|^2 + \frac{1}{L^2} \|\tilde{v}(t)\|^2 + 2C \langle \dot{v}(t), i_{carga}(t) \rangle + \dots \right) \quad (118)$$

$$\dots + \frac{2}{L} \langle \tilde{v}(t), i_{carga}(t) \rangle + 2\frac{C}{L} \langle \dot{v}(t), \tilde{v}(t) \rangle \quad (119)$$

$$\frac{\partial \|i_{carga}(t)\|^2}{\partial C} = 2C \|\dot{v}(t)\|^2 + 2 \langle \dot{v}(t), i_{carga}(t) \rangle + 2L \langle \dot{v}(t), \tilde{v}(t) \rangle \quad (120)$$

Igualando-se a expressão a zero obtém-se:

$$\hat{C} = -\frac{\langle \dot{v}(t), i_{carga}(t) \rangle}{\|\dot{v}(t)\|^2} - \frac{1}{L} \frac{\langle \dot{v}(t), \tilde{v}(t) \rangle}{\|\dot{v}(t)\|^2} \quad (121)$$

Agora calcula-se a derivada parcial da corrente $i_{carga}(t)$ em relação à L :

$$\frac{\partial \|i_{carga}(t)\|^2}{\partial L} = \frac{\partial}{\partial L} \left(\|i_{carga}(t)\|^2 + C^2 \|\dot{v}(t)\|^2 + \frac{1}{L^2} \|\tilde{v}(t)\|^2 + 2C \langle \dot{v}(t), i_{carga}(t) \rangle + \dots \right) \quad (122)$$

$$\dots + \frac{2}{L} \langle \tilde{v}(t), i_{carga}(t) \rangle + 2\frac{C}{L} \langle \dot{v}(t), \tilde{v}(t) \rangle \quad (123)$$

$$\frac{\partial \|i_{carga}(t)\|^2}{\partial L} = -\frac{2}{L^3} \|\tilde{v}(t)\|^2 - \frac{2}{L^2} \langle \tilde{v}(t), i_{carga}(t) \rangle - 2\frac{C}{L^2} \langle \dot{v}(t), \tilde{v}(t) \rangle \quad (124)$$

Substituindo \hat{C} em (124) obtem-se:

$$\frac{1}{\hat{L}} = -\frac{\|\dot{v}(t)\|^2 \langle \tilde{v}(t), i_{carga}(t) \rangle + \|v(t)\|^2 \langle \dot{v}(t), i_{carga}(t) \rangle}{\|v(t)\|^4 - \|\dot{v}(t)\|^2 \|\tilde{v}(t)\|^2} \quad (125)$$

e substituindo \hat{L} em (125) obtem-se:

$$\hat{C} = -\frac{\|\tilde{v}(t)\|^2 \langle \dot{v}(t), i_{carga}(t) \rangle + \|v(t)\|^2 \langle \tilde{v}(t), i_{carga}(t) \rangle}{\|v(t)\|^4 - \|\dot{v}(t)\|^2 \|\tilde{v}(t)\|^2} \quad (126)$$

Por intermédio da mesma abordagem, pode-se chegar ao capacitor ou indutor de compensação ótimos quando esses são colocados sozinhos em paralelo e resultam:

$$\hat{C} = -\frac{\langle \dot{v}(t), i_{carga}(t) \rangle}{\|\dot{v}(t)\|^2} \quad (127)$$

$$\hat{L} = -\frac{\langle \tilde{v}(t), i_{carga}(t) \rangle}{\|\tilde{v}(t)\|^2} \quad (128)$$

Apesar da DCO não ter surgido como uma decomposição de sinais de potência, mas sim de sinais elétricos, a nova ferramenta demonstra ter potencial para novas definições de troca de energia em sistemas elétricos.

Outras teorias de potência e decomposições são ainda debatidas, como a teoria de potências instantâneas, porém, um consenso sobre a interpretação dos fenômenos de troca de energia ainda não se deu completamente. Outros benefícios da utilização da ferramenta como uma nova teoria de potências deverão ser investigados em profundidade em trabalhos futuros. Espera-se que com este panorama geral da DCO, este trabalho fomente a ferramenta e crie um embasamento maior para trabalhos por vir.

Percebe-se ainda que a segunda etapa da DCO, na qual, realiza-se a decomposição dos sinais no plano das tensões de linha, tem como objetivo realizar uma etapa de filtragem em sistemas que sejam trifásicos, principalmente em relação à ruídos de medição de modo comum ou seja, que atinjam as fases igualmente, permitindo-se assim, a criação de componentes ortogonais filtradas e não filtradas.

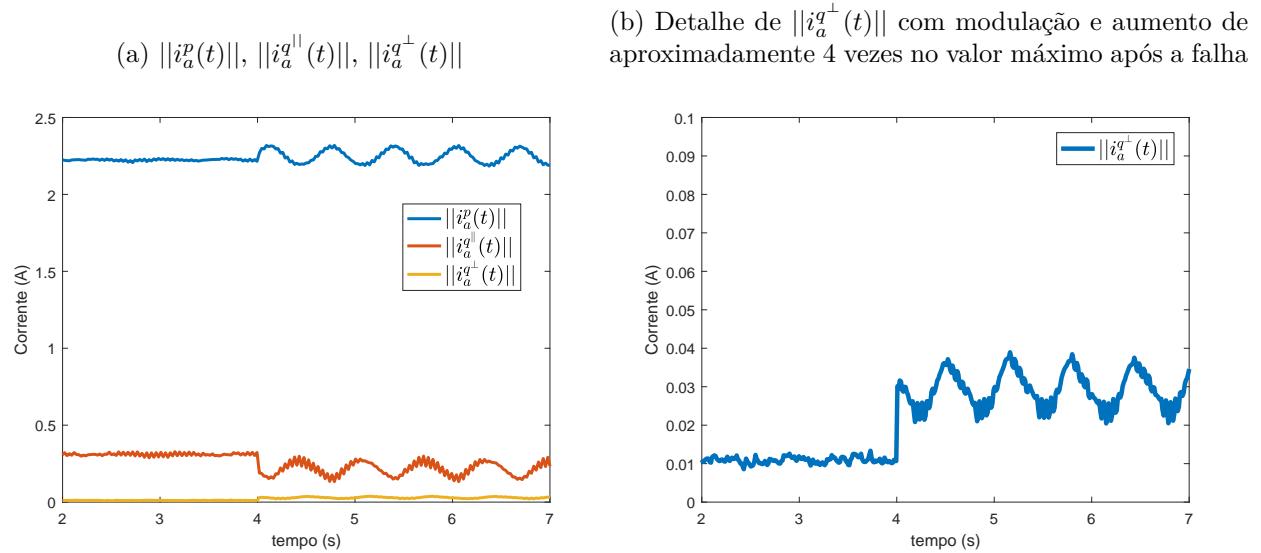
Nesta tese, a DCO é utilizada como ferramenta de extração de características. No caso da condição de barras quebradas, a corrente elétrica do sistema fica modulada por frequências próximas à frequência fundamental. Desta forma, os coeficientes α , γ , β e δ em (36)-(41) e (52)-(59), dados pelo cálculo da integral dos sinais elétricos em um período, não serão constantes, como no caso de circuitos puramente senoidais ou afetados por componentes múltiplas da frequência fundamental. Isso fará com que os resultados da DCO funcionem como um indicativo da ocorrência das falhas.

Em motores saudáveis, nos quais a corrente de estator não é modulada, os coeficientes γ , α , β e δ resultantes serão constantes e os diversos termos da decomposição possuirão valores eficazes constantes, assim como serão constantes os vários termos de potência. Na ocorrência de uma falha, a modulação da corrente acarretará modulação nas componentes ortogonais, em seus valores eficazes e em seus termos de potência devido à modulação dos coeficientes γ , α , β e δ .

Ademais, as parcelas ortogonais $i^\perp(t)$ das correntes de fase serão muito pequenas para motores saudáveis, visto que, o sistema saudável é próximo de um sistema puramente senoidal. Após um fenômeno de barras quebradas, esses termos tornam-se não nulos e modulados, já que o sistema torna-se não puramente senoidal, assim como os termos remanescentes $i^d(t)$, fenômeno que será melhor discutido no Capítulo 7, mas que pode ser visto na Figura 18.

Com todo o exposto, dada a grande potencialidade da DCO e dada a importância do processamento de sinais para o diagnóstico de falhas em MITs, justifica-se então o uso da DCO como extrator de características.

Figura 18: Valores eficazes das componentes $i_a^p(t)$, $i_a^{q\parallel}(t)$ e $i_a^{q\perp}(t)$ obtidas pela aplicação dos dois princípios da DCO em sinais reais de um motor de 1 cv saudável até o instante 4 s e para o mesmo motor com 4bq após 4 s.



Fonte: elaborado pela autora.

CAPÍTULO 4

Ferramentas Matemáticas e Computacionais

4.1 Modelagem de Assimetrias em Motores de Indução

Nesta pesquisa, utiliza-se modelos computacionais de MITs para se investigar os fenômenos das falhas estudadas e também a extração de características específicas dessas falhas realizadas pela DCO. Detalha-se então nas próximas seções, os modelos utilizados.

4.1.1 Modelo Simétrico Clássico - dq

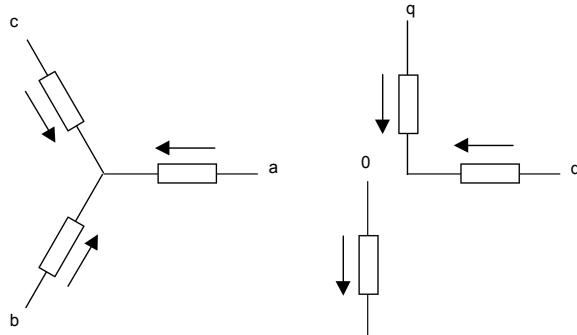
A necessidade de se caracterizar adequadamente o comportamento do motor operando em condições de falha visa auxiliar a detecção de tais defeitos de forma mais clara, impulsionando o desenvolvimento de métodos de monitoramento muito mais sensíveis à falha e imune à ruídos. O desenvolvimento de modelos de máquinas de indução permite entender os processos de falhas, assim como testar novos procedimentos para sua detecção de forma a dar suporte ao projeto, monitoramento e diagnóstico destes motores. Por meio da modelagem pode-se perceber os padrões dos defeitos e como eles aparecem nas variáveis monitoradas.

O desenvolvimento de modelos simples e de baixo custo computacional para a simulação de máquinas de indução trifásicas com defeitos é essencial. Dessa forma, os modelos propostos em Cunha, Lyra e Filho (2005), Baccarini, Menezes e Caminhos (2010) serão utilizados para modelar assimetrias no rotor e estator.

O modelo dq clássico de máquinas de indução é bastante simples. Ele surgiu com o intuito de se obter uma simplificação do modelo trifásico do MIT e assim resultar em um número menor de variáveis do sistema. Neste modelo substitui-se o sistema trifásico por um sistema ortogonal defasado de 90° entre si. Este modelo tem sido usado para prever o comportamento de vários tipos de máquinas, como as de indução, relutância síncrona

e com diferentes números de fases e com várias conexões diferentes, como, por exemplo, enrolamentos concentrados e de várias camadas. Na Figura 19, a disposição dos sistemas trifásicos e ortogonais é apresentada:

Figura 19: Sistema de coordenadas para modelagem trifásica e ortogonal de MITs.



Fonte: elaborado pela autora.

Considere os vetores $v_{\text{ort}}(t)$ e $v_{\text{tri}}(t)$ como os vetores das tensões no referencial ortogonal e no referencial trifásico:

$$v_{\text{ort}}(t) = \begin{pmatrix} v_d(t) \\ v_q(t) \\ v_0(t) \end{pmatrix}, \quad v_{\text{tri}}(t) = \begin{pmatrix} v_a(t) \\ v_b(t) \\ v_c(t) \end{pmatrix} \quad (129)$$

De acordo com a disposição geométrica dos referenciais e estendendo a definição dos vetores acima para, respectivamente, os vetores de corrente e fluxo $i_{\text{ort}}(t)$, $i_{\text{tri}}(t)$, $\varphi_{\text{ort}}(t)$ e $\varphi_{\text{tri}}(t)$, a transformação do sistema trifásico para o sistema ortogonal é dada por:

$$v_{\text{ort}}(t) = \frac{2}{3} A v_{\text{tri}}(t) \quad (130)$$

$$i_{\text{ort}}(t) = \frac{2}{3} A i_{\text{tri}}(t) \quad (131)$$

$$\varphi_{\text{ort}}(t) = \frac{2}{3} A \varphi_{\text{tri}}(t) \quad (132)$$

onde a matriz \mathbf{A} é dada por:

$$\mathbf{A} = \begin{bmatrix} 1 & -\frac{1}{2} & -\frac{1}{2} \\ 0 & \frac{\sqrt{3}}{2} & -\frac{\sqrt{3}}{2} \\ \frac{1}{2} & \frac{1}{2} & \frac{1}{2} \end{bmatrix} \quad (133)$$

O termo 2/3 é utilizado para que as grandezas no sistema ortogonal tenham a mesma magnitude do sistema trifásico.

Definindo-se como ω_1 a frequência síncrona do motor, P o número de pares de polos e ω_{mec} a velocidade mecânica do motor, supondo uma máquina simétrica, o modelo dq simétrico pode ser obtido por meio das equações seguintes, em um referencial ortogonal

λ genérico. As grandezas podem assumir sub índices s ou r , indicando sua natureza estatórica ou rotórica.

$$v_{ds} = R_s i_{ds} + \frac{d}{dt} \varphi_{ds} - \omega_\lambda \varphi_{qs} \quad (134)$$

$$v_{qs} = R_s i_{qs} + \frac{d}{dt} \varphi_{qs} + \omega_\lambda \varphi_{ds} \quad (135)$$

$$v_{dr} = 0 = R_r i_{dr} + \frac{d}{dt} \varphi_{dr} - (\omega_\lambda - P\omega_{mec}) \varphi_{qr} \quad (136)$$

$$v_{qr} = 0 = R_r i_{qr} + \frac{d}{dt} \varphi_{qr} + (\omega_\lambda - P\omega_{mec}) \varphi_{dr} \quad (137)$$

$$T = (3/2) * P * L_H * (i_{qs} i_{dr} - i_{ds} i_{qr}) \quad (138)$$

$$\varphi_{ds} = L_{\sigma_s} i_{ds} + L_H (i_{ds} + i_{dr}) \quad (139)$$

$$\varphi_{qs} = L_{\sigma_s} i_{qs} + L_H (i_{qs} + i_{qr}) \quad (140)$$

$$\varphi_{dr} = L_{\sigma_r} i_{dr} + L_H (i_{ds} + i_{dr}) \quad (141)$$

$$\varphi_{qr} = L_{\sigma_r} i_{qr} + L_H (i_{qs} + i_{qr}) \quad (142)$$

onde:

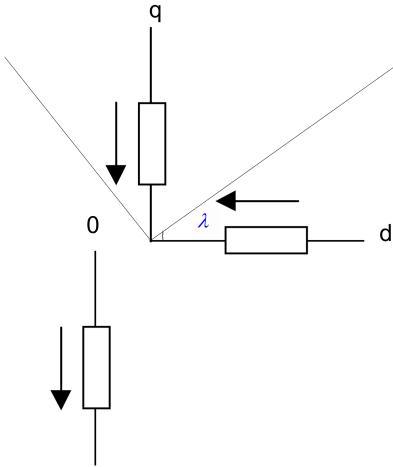
- ◻ T - conjugado eletromagnético;
- ◻ R_s - resistência equivalente de estator;
- ◻ R_r - resistência equivalente de rotor;
- ◻ L_{σ_s} - indutância de dispersão do estator;
- ◻ L_{σ_r} - indutância de dispersão do rotor e
- ◻ L_H - indutância de magnetização.

No modelo simétrico, as grandezas do referencial θ são desconsideradas. O referencial genérico gira com velocidade $\omega_\lambda = \frac{d}{dt} \lambda$ em relação a um referencial estacionário. A velocidade angular deste referencial genérico pode assumir valores típicos: fixo no estator, onde $\omega_\lambda = 0$, referencial fixo no rotor, onde $\omega_\lambda = P\omega_{mec}$ e referencial síncrono, onde $\omega_\lambda = \omega_1$. Na Figura 20 mostra-se um referencial ortogonal genérico.

4.1.2 Modelo Assimétrico - Inserção de falha de barras quebradas

Em Cunha, Lyra e Filho (2005) e Cunha (2006) é provado que o modelo clássico pode ser utilizado para calcular a corrente e a tensão em cada barra do rotor e em cada seção dos anéis de curto circuito da gaiola de esquilo. Desta forma, o modelo para barras quebradas utilizado neste trabalho é baseado em modificações do próprio modelo clássico simétrico. O modelo resultante é bastante simples e as assimetrias no rotor são inseridas

Figura 20: Sistema de referencial ortogonal λ genérico para a modelagem de MITs.



Fonte: eleborado pela autora.

por meio de uma transformação linear das correntes do eixo direto e em quadratura para um vetor de correntes de malhas no referencial do rotor.

Algumas considerações são feitas para a simplificação do modelo:

- ❑ Entreferro uniforme;
- ❑ Saturação no material magnético desprezível;
- ❑ Enrolamentos de estator idênticos, com eixos simétricos e senoidalmente distribuídos;
- ❑ Barras do rotor com distribuição uniforme em gaiola com eixos simétricos e
- ❑ Corrente de fuga e perdas por ventilação e atrito são desconsideradas.

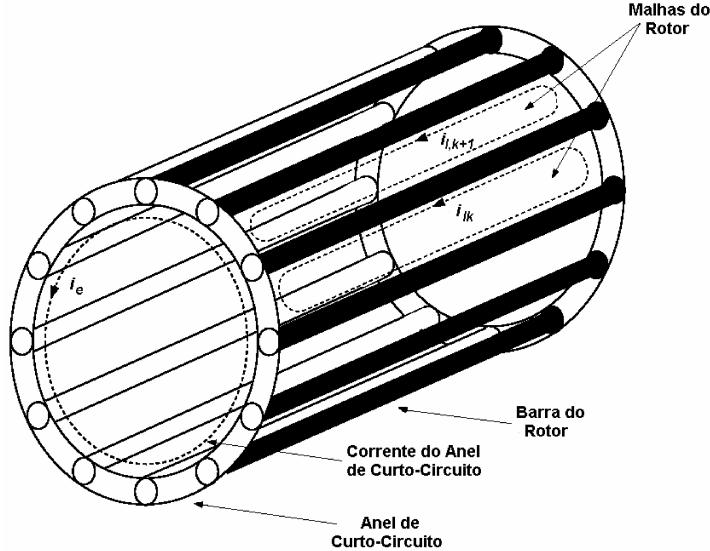
A inserção da falha de barras quebradas consiste em entender a gaiola de esquilo como um conjunto de malhas ou *loops*. Na Figura 21 pode-se observar que a gaiola possui $n + 1$ malhas, sendo que, n são idênticas e formadas entre barras, além de seções dos anéis de curto circuito. Uma das malhas é formada pelo próprio anel de curto-círcuito.

Seja o vetor $\mathbf{i}_l(t)$ o vetor representativo das correntes nas malhas, ou seja:

$$\mathbf{i}_l(t) = \begin{pmatrix} i_{l1}(t) \\ i_{l2}(t) \\ i_{l3}(t) \\ \vdots \\ i_{ln}(t) \end{pmatrix} \quad (143)$$

Quando um número de barras adjacentes se quebra, as correntes de malha referente as barras quebradas se modificam e tornam-se o vetor $\mathbf{i}_l^{novo}(t)$. Por exemplo, para a quebra

Figura 21: Modelagem das malhas no rotor de gaiola de esquilo.



Fonte: Cunha (2006).

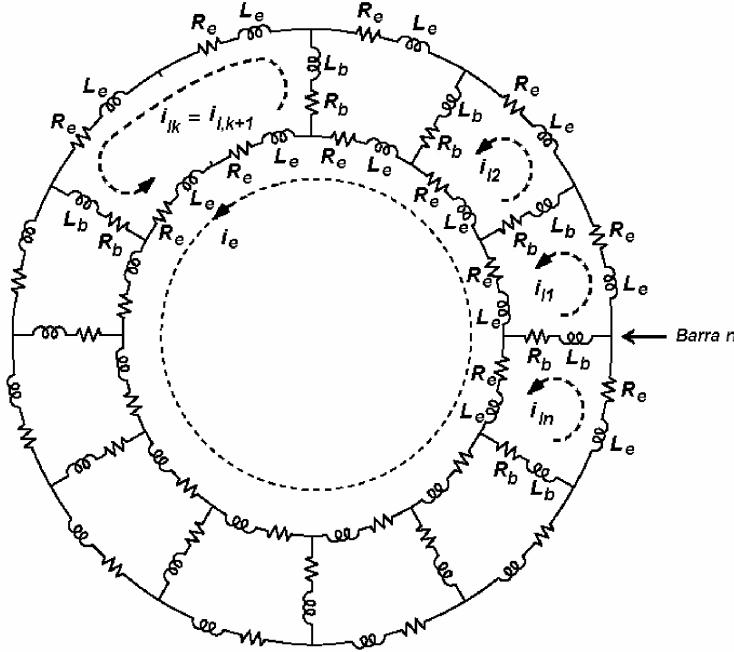
da $k^{\text{ésima}}$ barra, situação mostrada na Figura 22, o novo vetor de corrente é dado por:

$$\mathbf{i}_l^{novo}(t) = \begin{pmatrix} i_{l1}^{novo}(t) \\ i_{l2}^{novo}(t) \\ i_{l3}^{novo}(t) \\ \vdots \\ i_{lk}^{novo}(t) \\ i_{lk+1}^{novo}(t) \\ \vdots \\ i_n^{novo}(t) \end{pmatrix} = \begin{pmatrix} i_{l1}(t) \\ i_{l2}(t) \\ i_{l3}(t) \\ \vdots \\ \frac{(i_{lk}(t)+i_{lk+1}(t))}{2} \\ \frac{(i_{lk}(t)+i_{lk+1}(t))}{2} \\ \vdots \\ i_n(t) \end{pmatrix} \quad (144)$$

Para que essa interpretação possa ser usada a partir do modelo simétrico, uma transformação linear \mathbf{T} deve levar o vetor n -dimensional das correntes de malha para um vetor n -dimensional $\mathbf{i}_r^l(t)$ das correntes *dqo* do rotor.

$$\begin{pmatrix} i_{l1}(t) \\ i_{l2}(t) \\ i_{l3}(t) \\ \vdots \\ i_{ln}(t) \end{pmatrix} = \mathbf{T}^{-1} \mathbf{i}_r^l(t) = \mathbf{T}^{-1} \begin{pmatrix} i_{dr}(t) \\ i_{qr}(t) \\ i_{01}(t) \\ \vdots \\ i_{0n}(t) \end{pmatrix} \quad (145)$$

Figura 22: Modelagem das malhas no rotor de gaiola de esquilo



Fonte: Cunha (2006).

A matriz \mathbf{T} é dada por:

$$\mathbf{T} = \begin{bmatrix} \cos(\theta) & \cos(\theta + P\frac{2\pi}{n}) & \cos(\theta + 2P\frac{2\pi}{n}) & \cos(\theta + 3P\frac{2\pi}{n}) & \cdots & \cos(\theta + (n-1)P\frac{2\pi}{n}) \\ \sin(\theta) & \sin(\theta + P\frac{2\pi}{n}) & \sin(\theta + 2P\frac{2\pi}{n}) & \sin(\theta + 3P\frac{2\pi}{n}) & \cdots & \sin(\theta + (n-1)P\frac{2\pi}{n}) \\ f_{31} & f_{32} & 1 & 0 & \cdots & 0 \\ f_{41} & f_{42} & 0 & 1 & \cdots & 0 \\ f_{51} & f_{52} & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ f_{n1} & f_{n2} & 0 & 0 & \cdots & 1 \end{bmatrix} \quad (146)$$

As duas primeiras linhas da matriz \mathbf{T} são linearmente impendentes e referenciam os eixos direto e em quadratura de $\mathbf{i}_r^l(t)$. O restante dos valores nas duas primeiras colunas pode ser calculado da seguinte maneira:

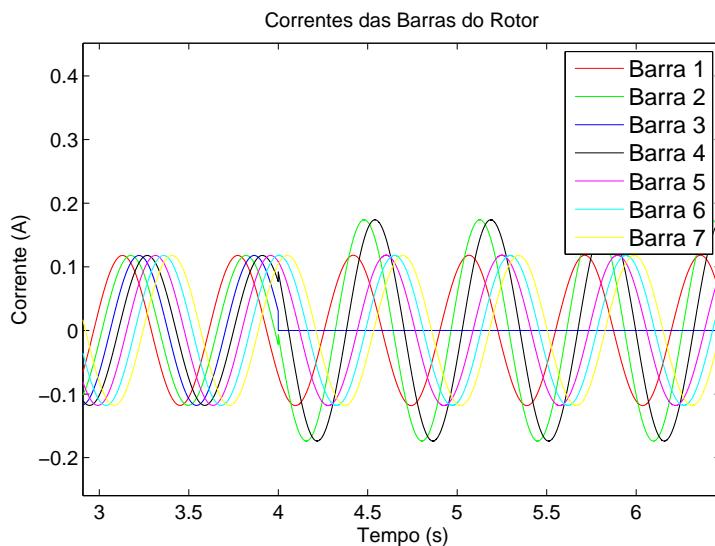
$$\begin{pmatrix} f_{i1} \\ f_{i2} \end{pmatrix} = \begin{pmatrix} 1 & \cos(P\frac{2\pi}{n}) \\ 0 & \sin(P\frac{2\pi}{n}) \end{pmatrix}^{-1} \begin{pmatrix} \cos(2P\frac{2\pi}{n}) & \cdots & \cos((n-1)P\frac{2\pi}{n}) \\ \sin(2P\frac{2\pi}{n}) & \cdots & \sin((n-1)P\frac{2\pi}{n}) \end{pmatrix} \begin{pmatrix} f_{i3} \\ \vdots \\ f_{in} \end{pmatrix} \quad (147)$$

É interessante observar que a sub matriz formada pela matriz T , descontadas as duas primeiras linhas, contribui para a formação dos componentes de sequência zero $i_0^1(t), \dots, i_0^n(t)$ desse sistema, que pode ser comparado à um sistema polifásico. A partir dessa transformação linear pode-se então inserir assimetrias nas barras do rotor.

A inserção de falhas é bastante simples. O motor tem sua dinâmica modelada pelo modelo simétrico, e a cada iteração, o vetor das correntes de malha $\mathbf{i}_l(t)$ é calculado por meio da relação (145), onde os valores da corrente de sequência zero, representadas por $i_0^1(t)$ até $i_0^n(t)$, são considerados nulos. O próximo passo é a introdução da assimetria, na qual, as correntes de malha recebem um novo valor, dado pela relação (144). Finalmente calcula-se o novo vetor $\mathbf{i}_r(t)$ com (145). Na existência da falha, esse novo vetor possuirá valores no eixo direto, em quadratura e de sequência zero. Porém, só os valores dos eixos d e q deverão ser realimentados no modelo simétrico.

Nos gráficos a seguir, ilustra-se como deve ser o comportamento das correntes nas barras no caso de 1bq e 2bq adjacentes. A inserção da assimetria é feita em $t = 4s$.

Figura 23: Corrente nas barras do rotor para 1bq (Barra 3).

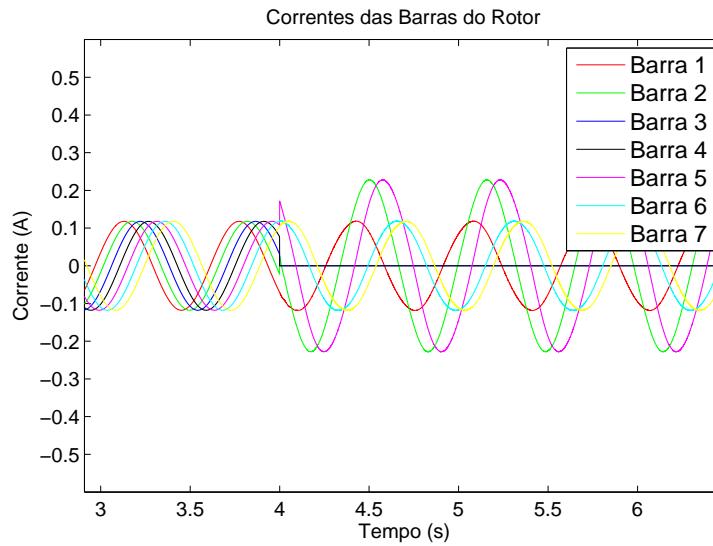


Fonte: elaborado pela autora.

4.2 Mineração de Dados, Seleção de Atributos, Diminuição da Dimensionalidade e Algoritmo Recursivo Baseado em Correlação

Segundo Witten e Frank (2005) a mineração de dados é definida como o processo de busca por padrões e informações essenciais em grandes quantidades de dados, de maneira automatizada ou semi automatizada. A mineração de dados também se insere nos paradigmas de aprendizagem de máquinas. Os padrões encontrados devem ser significativos e promover vantagens na aplicação de certa tarefa a ser realizada. Nesta investigação, como já explicitado anteriormente, sistemas de inferência serão utilizados para o diagnóstico das falhas. Dessa forma, dados deverão ser processados de forma correta para que

Figura 24: Corrente nas barras do rotor para 2bq (Barra 3 e Barra 4).



Fonte: elaborado pela autora.

esses sistemas também atuem corretamente. Os dados contêm amostras e atributos ou variáveis relativas à cada amostra.

Mineração de dados busca, então, solucionar problemas por meio de análise de dados que já foram processados e reunidos, envolvendo recursos multidisciplinares como ferramentas estatísticas, tecnologia de banco de dados, otimização, sistemas inteligentes, reconhecimento de padrões, visualização de dados, entre outros.

Nos problemas de classificação de padrões, a seleção de atributos, pode ser utilizada como uma ferramenta para aprender quais são os atributos ou variáveis mais relevantes frente às classes apresentadas a um determinado classificador. Um número grande de atributos irrelevantes pode "confundir" sistemas de aprendizado utilizado em problemas de decisão e classificação de padrões (WITTEN; FRANK, 2005). Dessa forma, é importante realizar antes da etapa de aprendizado e classificação, um estágio de seleção de atributos que elimine a maioria das variáveis irrelevantes.

A seleção de atributos não só traz menores riscos ao desempenho de classificadores e decisões, mas também promove a redução de dimensionalidade dos dados, que, se elevada, impede a utilização de certos sistemas inteligentes. A redução de dimensionalidade tem por consequência prover aos sistemas de aprendizado e decisão um conjunto de dados mais compacto e relevante, melhorando o desempenho dos algoritmos utilizados para a resolução dos problemas.

Frente a um profundo entendimento dos dados e do problema a ser resolvido, a seleção de atributos pode ser realizada manualmente, porém, a dificuldade em realizar tal tarefa cresce com o aumento do número de atributos. Na literatura correlata pode-se encontrar inúmeros algoritmos que selecionam atributos de forma automática.

Nos próximos parágrafos será dada ênfase ao algoritmo recursivo baseado em correlação.

O algoritmo Seleção de Subconjunto de Atributos Baseada em Correlação para Aprendizado de Máquinas, *Correlation Feature Selection* (CFS), avalia a relevância de subconjuntos de atributos para o problema de classificação, levando em conta a correlação entre esse subconjunto e as classes existentes. Desta forma, o algoritmo seleciona recursivamente atributos altamente correlacionados com a classe e com baixa correlação com os demais atributos do subconjunto (HALL; SMITH, 1999). Assim, o algoritmo elimina atributos irrelevantes, pois eles são preditores ruins para a classe, e também, elimina atributos redundantes, pois esses são altamente correlacionados com outros atributos.

A métrica utilizada pelo algoritmo para um subconjunto de N atributos é mostrada abaixo, onde r_{cf}^- e r_{ff}^- são a média de correlação com a classe e a média de intercorrelação dos atributos, respectivamente.

$$M = \frac{Nr_{cf}^-}{\sqrt{(N + N(N - 1)r_{ff}^-)}} \quad (148)$$

As correlações da equação (148) são calculadas por meio de uma medida de entropia denominada *symmetrical uncertainty* e é detalhada com mais profundidade em Hall e Smith (1999).

O melhor subconjunto de atributos seria encontrado se todas as possibilidades fossem testadas, porém isso é computacionalmente proibitivo. À vista disso, para determinar quais atributos serão inseridos no conjunto ótimo, de forma recursiva, vários métodos de busca heurística podem ser utilizados, como por exemplo, *hill climbing*, *best first* e *gridstepwise* (RICH; KNIGHT, 1991), que consistem em inserir atributos no subconjunto até que a métrica M comece a decrescer. Neste trabalho, o método de busca utilizado é o *gridstepwise* que realiza uma busca de atributos dentro de uma grade de combinações. Pode se iniciar com nenhum atributo, ou com um conjunto inicial de atributos. A busca heurística varre então a grade e apenas pára quando a adição ou deleção de qualquer outro atributo decresce a métrica M . Um ranking de atributos também pode ser produzido mediante do registro da sequência a qual os atributos foram escolhidos.

4.3 Sistemas de Inferência

Apesar deste trabalho estar voltado aos sistemas de inferência advindos da aprendizagem de máquinas, análises estatísticas para verificar se o conjunto de dados experimentais advinham de uma mesma população foram utilizadas. Na seção a seguir, faz-se uma breve explicação do teste estatístico.

4.3.1 Análise de variância Kruskal-Wallis

O teste Kruskal-Wallis é uma versão não paramétrica da Análise de Variância (ANOVA), no qual se compara as médias de grupos de dados para determinar se as amostras advêm de uma mesma população. A hipótese nula afirma que todas as médias das populações são iguais, enquanto a hipótese alternativa afirma que pelo menos uma é diferente.

Neste teste não paramétrico, a estatística F utilizada na ANOVA é substituída pela estatística chi-quadrado. Essa estatística é, então, utilizada para acusar o valor de significância da hipótese nula. Comumente declara-se que o resultado é significante se o valor da probabilidade P da estatística chi-quadrado for menor que 0,05 ou 0,1. Além disso, diferentemente da ANOVA, o teste Kruskal-Wallis não assume que os dados são provenientes de distribuições normais, o que flexibiliza os testes frente a qualidade dos dados.

Quanto, aos sistemas advindos da aprendizagem de máquinas, utilizam-se dois tipos diferentes de sistemas de inferência para completar o sistema de diagnóstico: as RNAs e os *SVMs*. A seguir uma breve análise dessas ferramentas é realizada.

4.3.2 Redes Neurais Artificiais

RNAs são modelos computacionais inspirados no cérebro humano e que possuem a capacidade de aquisição e manutenção do conhecimento. São compostas por unidades básicas de processamento, comparáveis aos neurônios biológicos, e interligações ponderadas por pesos, comparáveis às conexões sinápticas (SILVA; SPATTI; FLAUZINO, 2010; SILVA et al., 2016). Este sistema de inferência será utilizado para classificar a ocorrência das falhas, assim como sua severidade.

4.3.2.1 Principais Características

RNAs são capazes de modelar aspectos não-lineares de variáveis de entrada, assim como funções variantes no tempo, sendo usadas como ferramentas de reconhecimento de padrões, clusterização, aproximação de função, previsão e otimização, memórias associativas e controle de processos. Pesquisas dessas redes têm mais de meio século de história e sua aplicação tem se expandido constantemente.

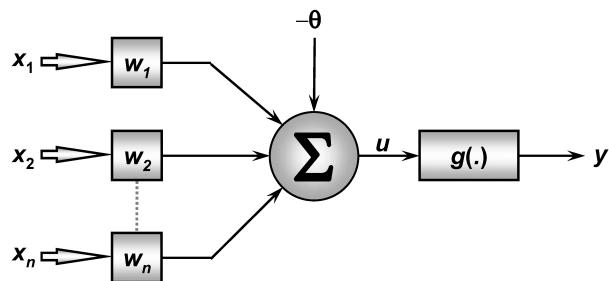
Pode-se dizer que as RNAs possuem como característica principal a adaptação de parâmetros internos (pesos sinápticos) a partir da apresentação de exemplos dos valores de entrada e saída de um banco de dados. Por meio de um processo de treinamento, realiza-se a aquisição do seu conhecimento, sendo capaz de operar estimando soluções que até então eram desconhecidas. Esta última habilidade ou característica da rede é chamada de habilidade de generalização (SILVA; SPATTI; FLAUZINO, 2010; SILVA et al., 2016). A tolerância à falhas é outra característica principal das RNAs, o que as tornam robustas a qualquer falha em sua estrutura, já que, esta é composta por inúmeras conexões

entre os neurônios artificiais, sendo o conhecimento, adquirido de forma distribuída entre os diversos neurônios. Os algoritmos utilizados na implementação de RNAs são facilmente empregados tanto em software quanto em hardware, já que, após o treinamento, simples operações matemáticas caracterizam a sua operação.

4.3.2.2 O Neurônio Artificial

Um neurônio artificial é tido como uma unidade básica de processamento que recebe vários estímulos de entrada e, mediante uma soma ponderada desses, resulta em uma resposta na saída (HAYKIN, 2008). A Figura 25 apresenta o diagrama de um neurônio artificial, primeiramente proposto por McCulloch e Pitts (1943).

Figura 25: Neurônio Artificial.



Fonte: Silva, Spatti e Flauzino (2010).

Tem-se que:

- $x_1, x_2, x_3, \dots, x_n$ são sinais de entrada advindos do meio externo e representam estímulos ao neurônio. São considerados atributos das variáveis monitoradas de um sistema e são geralmente pré-processados;
- $w_1, w_2, w_3, \dots, w_n$ são os pesos sinápticos obtidos durante o treinamento do neurônio. As entradas são multiplicadas pelos respectivos pesos sinápticos, dessa forma, pondera-se a importância das informações que chegam ao neurônio;
- Σ realiza um combinador linear dos sinais ponderados de entrada;
- θ é o limiar de ativação do neurônio ou *bias*;
- u é a saída do combinador linear denominada potencial de ativação. É resultado do combinador linear e o limiar de ativação;
- $g(\cdot)$ é a função de ativação, responsável por limitar a saída do neurônio em um intervalo de valores e
- y é o sinal de saída do neurônio. Pode ser utilizado como um sinal de entrada para neurônios sequencialmente conectados. (HAYKIN, 1999; SILVA; SPATTI; FLAUZINO, 2010).

Pelo exposto anteriormente, o potencial de ativação u e o sinal de saída y são determinados pelas seguinte expressões:

$$u = \sum_{i=1}^n w_i \cdot x_i - \theta \quad (149)$$

$$y = g(u) \quad (150)$$

Existem diversas funções de ativação e sua escolha é dependente do problema em questão. Elas se dividem em dois grandes grupos:

- **Diferenciáveis em todo o domínio:** função linear, função degrau ou degrau bipolar e função rampa. São amplamente empregadas em problemas de classificação de padrões e
- **Parcialmente diferenciáveis no domínio:** função logística, função tangente hiperbólica, função Gaussiana e função linear. São amplamente empregadas em problemas não lineares, em redes de múltiplas camadas neurais. A Tabela 1 traz um quadro resumo das funções expostas aqui (HAYKIN, 1999; SILVA; SPATTI; FLAUZINO, 2010).

4.3.2.3 Arquitetura das Redes Neurais Artificiais e Processos de Treinamento

Existem diversas arquiteturas de RNAs sendo estas responsáveis por diferenciar as redes nas formas de ligação entre os neurônios e no direcionamento da informação entre eles. Além disso, diversas topologias são encontradas para cada uma das arquiteturas. Quanto às topologias, as diferenças entre elas residem no número de neurônios utilizados ou na utilização de diferentes funções de ativação. Cada uma dessas arquiteturas é idealizada para um objetivo específico e sua topologia depende do problema em questão. O processo de treinamento é outro fator que diferencia as inúmeras RNAs. O processo de treinamento constitui-se da aplicação de um algoritmo que visa ajustar os pesos e limiares da rede de forma a aproximar suas respostas aos valores desejados. Independentemente da arquitetura, topologia ou treinamento, as redes neurais possuem três partes, denominadas de camadas e podem ser divididas em:

- **Camada de entrada:** É a camada responsável pela entrada de dados, medições ou sinais advindos do meio externo a partir de amostragens realizadas por experimentos e simulações. Essas entradas devem ser normalizadas individualmente dentro dos seus respectivos valores mínimos e máximos existentes no banco de dados disponível, levando-se em consideração a variação dinâmica das funções de ativação utilizadas nos neurônios;
- **Camada escondida ou oculta:** Camada que possui os neurônios responsáveis pela extração da informação requerida do processo e

Tabela 1: Principais funções de ativação.

Fonte: Silva, Spatti e Flauzino (2010).

Função de ativação	$g(u)$	Gráfico
Degrau	$g(u) = \begin{cases} 1, & \text{se } u \geq 0 \\ 0, & \text{se } u \leq 0 \end{cases}$	
Degrau Bipolar	$g(u) = \begin{cases} 1, & \text{se } u \geq 0 \\ -1, & \text{se } u \leq 0 \end{cases}$	
Rampa	$g(u) = \begin{cases} a, & \text{se } u \geq a \\ u, & \text{se } -a \geq u \geq a \\ -a, & \text{se } u \leq -a \end{cases}$	
Logística	$g(u) = \frac{1}{1+e^{-\beta \cdot u}}$	
Tangente Hiperbólica	$g(u) = \frac{1-e^{-\beta \cdot u}}{1+e^{-\beta \cdot u}}$	
Gaussiana	$g(u) = e^{\frac{-(u-c)^2}{2\sigma^2}}$	
Linear	$g(u) = u$	

- **Camada de saída:** Camada também formada por neurônios e responsável pela produção do valor final do requerido processo.

Dentre as arquiteturas mais conhecidas, pode-se citar:

- **Redes FeedForward (Camada única):** Neste tipo de rede, tem-se uma camada de entrada e uma única camada de neurônios que é a própria camada de saída. São utilizadas em reconhecimento de padrões e a informação é sempre unidirecional, sendo proveniente da entrada em direção à saída;
- **Redes FeedForward (Multicamadas):** Esse tipo de rede difere da anterior pela presença de uma ou mais camadas escondidas de neurônios. São comumente usadas em aproximadores de funções, reconhecimento de padrões e identificação e controle. A informação é sempre unidirecional sendo proveniente da camada de entrada em direção à camada de saída;
- **Redes Recorrentes:** São redes que contém retroalimentação entre neurônios de camadas diferentes. As aplicações são previsão/estimação, séries temporais, otimização e sistemas dinâmicos e
- **Redes com Estrutura Reticulada:** Consiste de uma disposição espacial de seus neurônios, normalmente formados por uma dimensão (*array*) ou duas dimensões (*grade*). São utilizadas em problemas de agrupamento (*clustering*), reconhecimento de padrões e grafos.

Já com relação aos treinamentos, pode-se citar os seguintes tipos:

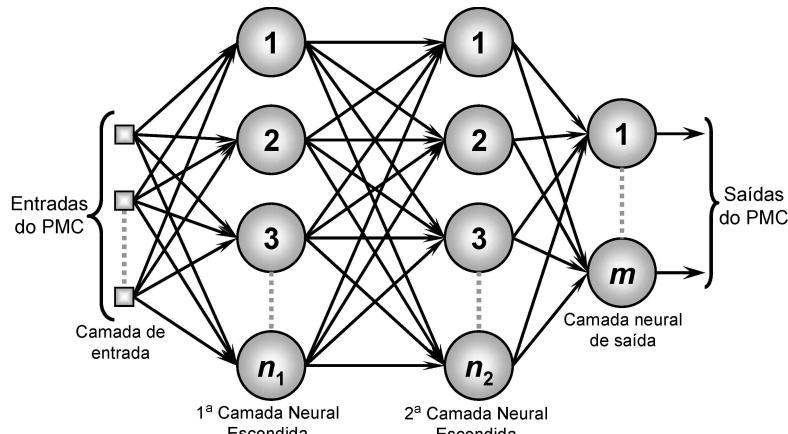
- **Supervisionado:** A rede é treinada a partir de dados que contém disponíveis as saídas desejadas para as entradas da amostra. A aplicação do treinamento supervisionado depende apenas da disponibilidade desta tabela de atributos/valores;
- **Não supervisionado:** Não há uma saída específica em relação aos estímulos de entrada. A rede se auto-organiza em correspondência às particularidades do conjunto de entrada;
- **Offline:** O ajuste de pesos e limiares é realizado após a apresentação de todos o conjunto de treinamento e
- **Online:** O ajuste de pesos e limiares é realizado após a apresentação de cada amostra de treinamento.

4.3.2.4 Rede *Perceptron* Multicamadas

As redes *Perceptron* Multi-Camadas (PMCs) são utilizadas nas mais diversas áreas de aplicação, como em aproximação universal de funções, reconhecimento de padrões,

controle de processos, previsão de séries temporais e otimização de sistemas. São caracterizadas por possuírem mais de uma camada escondida, conforme ilustrado na Figura 26 e seu treinamento é realizado de forma supervisionada.

Figura 26: Ilustração da rede PMC.



Fonte: Silva, Spatti e Flauzino (2010).

Nota-se que as RNAs mapeiam um espaço de entradas para um espaço de saídas e a especificação mais apropriada para o número de neurônios nas camadas escondidas do PMC é usualmente realizada de forma empírica, logo, não impõe garantia de que a topologia escolhida será a de melhor desempenho. O número de neurônios nas camadas escondidas está relacionado com a capacidade de aprendizagem. Quanto maior o número de neurônios, mais a rede terá condições de mapear o conjunto de entrada/saída. Entretanto, se esse número for excessivo, a rede pode apresentar problemas de generalização da aprendizagem. Já o número de camadas dependerá da complexidade e do tipo do problema considerado. Em aproximações de função, uma camada escondida é capaz de trabalhar como aproximador universal, mapeando não linearidades. Já em problemas de classificação de padrões, apenas uma camada escondida resolve a separação de conjuntos convexos. Com mais camadas pode-se classificar conjuntos não convexos.

Portanto, considerações sobre o tipo de problema, parâmetros de treinamento, disposição das amostras de entrada, entre outros, fazem parte dos fatores que influenciam na formação e escolha da topologia da rede.

4.3.2.5 Princípio de Funcionamento da rede *Perceptron Multi-Camadas*

Os sinais externos são apresentados à rede por meio da camada de entrada. As camadas escondidas são responsáveis por extrair ou mapear o conhecimento por intermédio dos pesos sinápticos e limiares de ativação, de forma a intrinsecamente modelar o sistema em questão. Os neurônios da última camada recebem os valores de saída das camadas anteriores e produzem uma resposta final da rede.

A Figura 27 ilustra a notação utilizada no equacionamento de uma rede PMC com quatro camadas, em que:

- ❑ $W_{ji}^{(L)}$ é o peso sináptico do j -ésimo neurônio da camada L conectado ao i -ésimo neurônio da camada $(L - 1)$;
- ❑ $I_j^{(L)}$ é a entrada ponderada do j -ésimo neurônio da camada L e $\theta_j^{(L)}$ é o limiar de ativação do j -ésimo neurônio da camada L , os quais são definidos por:

$$I_j^{(1)} = \sum_{i=1}^N W_{ji}^{(1)} \cdot x_i - \theta_j^{(1)} \quad (151)$$

$$I_j^{(2)} = \sum_{i=1}^{N1} W_{ji}^{(2)} \cdot Y_j^{(1)} - \theta_j^{(2)} \quad (152)$$

$$I_j^{(3)} = \sum_{i=1}^{N2} W_{ji}^{(3)} \cdot Y_j^{(2)} - \theta_j^{(3)} \quad (153)$$

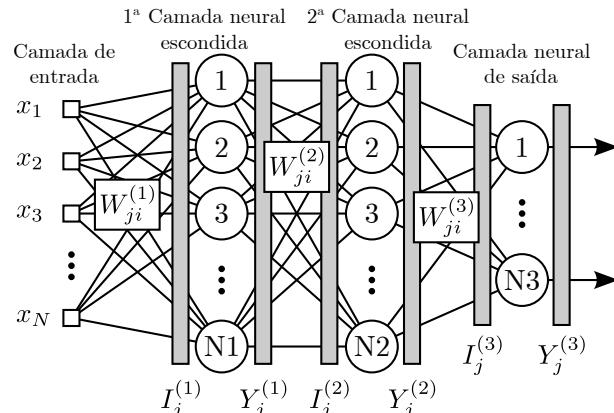
- ❑ $Y_j^{(L)}$ denota a saída do j -ésimo neurônio da camada L , os quais são calculados por:

$$Y_j^{(1)} = g(I_j^{(1)}) \quad (154)$$

$$Y_j^{(2)} = g(I_j^{(2)}) \quad (155)$$

$$Y_j^{(3)} = g(I_j^{(3)}) \quad (156)$$

Figura 27: Notação da rede PMC.



Fonte: Suetake (2012).

4.3.2.6 Processo de Treinamento das Redes *Perceptron* Multi-Camadas

O processo de treinamento do PMC é realizado mediante o algoritmo *Backpropagation* de forma supervisionada e offline. Este algoritmo constitui-se de dois passos principais:

1. **Passo Forward:** Atributos de um determinado padrão é aplicado nas entradas da rede e as informações são propagadas pelas camadas até as suas saídas. Ou seja, a rede produz os resultados com os valores atuais de seus pesos sinápticos e limiares e

2. Passo Backward: A partir das saídas, calcula-se o erro em relação a saída que seria desejada para a rede e a partir da camada de saída, de volta à camada de entrada, são ajustados os pesos W_{ij}^L objetivando a minimização do erro frente a um critério determinado.

A função representativa do erro entre a resposta dos neurônios e a saída desejada que deverá ser minimizada é dada por:

$$E(K) = \frac{1}{2} \sum_{j=1}^{N^3} (d_j(k) - Y_j^{(3)}(k))^2 \quad (157)$$

onde $d_j(k)$ representa o valor desejado da k -ésima amostra de treinamento. Nota-se que esta função pode possuir mínimos locais.

Dessa forma, o desempenho global do algoritmo de treinamento, frente a um conjunto de p amostras, pode ser analisado por meio do erro quadrático médio:

$$E_M = \frac{1}{P} \sum_{k=1}^p (E(k)) \quad (158)$$

Os detalhes para a implementação do algoritmo *backpropagation* podem ser consultados em Haykin (1999), Silva, Spatti e Flauzino (2010), Silva et al. (2016).

Após o treinamento do PMC, a rede poderá receber novas amostras para classificação, que não foram utilizadas para o seu treinamento, pertencentes à um conjunto, denominado de teste. Neste momento, a rede estará generalizando a sua função de decisão de classificação para outras amostras.

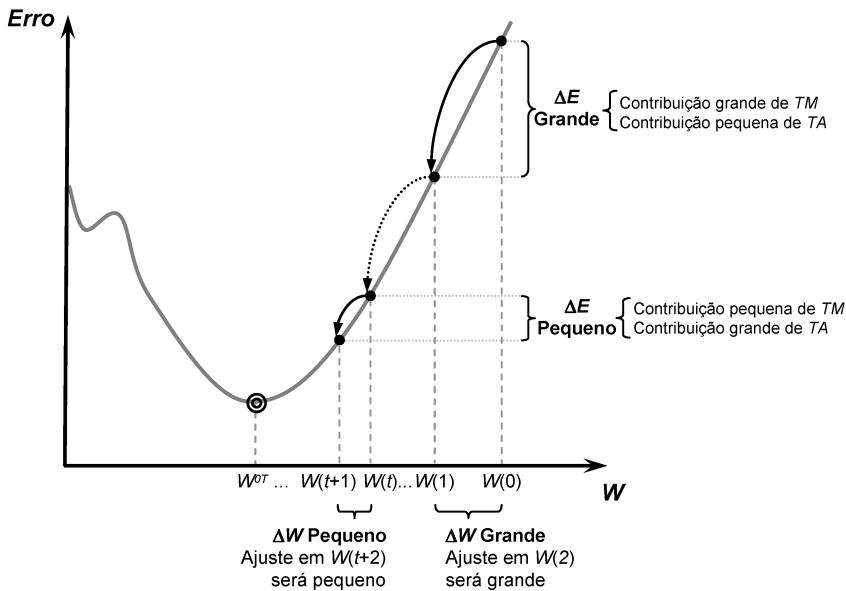
4.3.2.7 Termo de *Momentum*

A inserção do termo de *momentum* durante o treinamento da rede neural se dá com o objetivo de tornar mais eficiente o processo de convergência do treinamento da rede. Esse termo inserido no algoritmo de treinamento pondera o quanto os pesos foram alterados entre as duas iterações anteriores.

O algoritmo *backpropagation* minimiza a função representativa do erro quadrático médio por meio do método do gradiente descendente ou (*Least Mean Square*) e a taxa de aprendizagem indica o quão rápido é o processo de convergência em direção ao ponto de minimização da função erro. A taxa de *momentum*, que tem valor compreendido entre 0 e 1, imprime um passo maior de incremento em direção ao mínimo da função erro. Pode-se resumir o seu funcionamento como a seguir: se a solução atual estiver longe da solução final, a variação entre as matrizes de peso entre duas iterações consecutivas será bem considerável e, nesta situação, pode-se aumentar o passo de incremento em direção ao mínimo da função erro. Quando a solução atual estiver bem próxima da solução final, as variações nas matrizes de peso serão pequenas e, consequentemente, a contribuição do termo de *momentum* para o processo de convergência é também pequena.

A Figura 28 mostra a contribuição do termo de *momentum* na convergência em direção ao mínimo da função erro quadrático.

Figura 28: Contribuição do termo de *Momentum* (TM) e da taxa de aprendizagem (TA) na convergência do treinamento de redes PMC.



Fonte: Silva, Spatti e Flauzino (2010).

4.3.3 Support Vector Machines

SVMs são baseadas em algoritmos utilizados em classificação de padrões, regressão e detecção de novos padrões. Segundo Almeida (2002), as *SVMs* podem ser consideradas como algoritmos de aprendizado com uma camada escondida, treinamento supervisionado e baseados no princípio de minimização de risco estrutural, advindo das teorias de aprendizado estatístico. Nesta tese *SVMs* serão utilizadas, assim como as RNAs, para classificar e diagnosticar a ocorrência das falhas.

Em problemas de classificação de padrões o algoritmo maximiza a margem entre vetores (amostras) de treinamento e um hiperplano de separação entre padrões. Os vetores mais importantes que definem o posicionamento do hiperplano são chamados de vetores de suporte (*Support Vectors (SVs)*) .

A ferramenta pode ser utilizada em grandes quantidades de dados de alta dimensionalidade, exibindo boa generalização da aprendizagem. As *SVMs* possuem a capacidade de interpretar o modelo matemático dos dados por meio dos vetores de suporte e apresentam, dessa forma, uma grande vantagem frente a algoritmos que desempenham as mesmas tarefas.

A aprendizagem das *SVMs* envolve a otimização de uma função convexa e que não apresenta mínimos locais, além de apresentar poucos parâmetros para o seu treinamento

(ALMEIDA, 2002).

Nos primeiros trabalhos relacionados às *SVMs* em classificação de padrões (BOSER; GUYON; VAPNIK, 1992), os algoritmos eram utilizados apenas com dados linearmente separáveis, denominados como *SVMs* com margens rígidas (*hard margins*). Com o amadurecimento e a exploração da nova ferramenta, dados não linearmente separáveis passaram a ser tratados com erros de classificação mínimos (GUYON, 1999), dando origem às *SVMs* com margens suaves ou flexíveis (*soft margins*).

Nesta seção será apresentada a formulação básica das *SVMs* com *soft margins* e *hard margins*, além do conceito de *kernel* e espaço futuro.

4.3.3.1 *Support Vector Machines* em classificação binária de padrões e *hard margins*

Considere um problema de classificação binária de padrões, com classes linearmente separáveis. Seja x_i os vetores (amostras) de entrada, pertencentes ao espaço de entradas e $y_i = \pm 1$ a classe correspondente à determinada entrada. O índice i é dado para cada par (x, y) de forma que $i \in \mathbb{N}$ e $i = (1, \dots, m)$

Pode-se afirmar que para a minimização do erro de generalização, deve-se maximizar a margem Γ , ilustrada na Figura 29, isto é, a distância mínima entre um hiperplano de separação das duas classes e os dados de entrada de cada classe que estejam mais próximos a esse hiperplano (BENNETT; CAMPBELL, 2000).

Um possível hiperplano de separação de classes linearmente separáveis em um espaço de dimensão arbitrária é dado por:

$$\mathbf{w} \cdot \mathbf{x} + \mathbf{b} = 0 \quad (159)$$

onde, \mathbf{b} denota o vetor de limiar ou *bias*, \mathbf{w} o vetor de pesos e “.” o produto escalar das entradas. Após apresentado um possível hiperplano de separação define-se uma função de decisão de classificação na forma:

$$D(x) = sign(\mathbf{w} \cdot \mathbf{x} + \mathbf{b}) \quad (160)$$

Valores positivos na saída da função $D(x)$ remetem a entradas de classe +1 e valores negativos remetem a entradas de classe -1.

De forma a apresentar o desenvolvimento das *SVMs* fixam-se dois hiperplanos canônicos formados por vetores de suporte (*SVs*) que devem conter, cada um, as amostras de cada classe que sejam mais próximos do hiperplano de separação. Por canônico entende-se que cada novo hiperplano deve ser distante em 1 unidade do hiperplano de separação.

$$\begin{cases} \mathbf{w} \cdot \mathbf{x} + \mathbf{b} = 1 \\ \mathbf{w} \cdot \mathbf{x} + \mathbf{b} = -1 \end{cases} \quad (161)$$

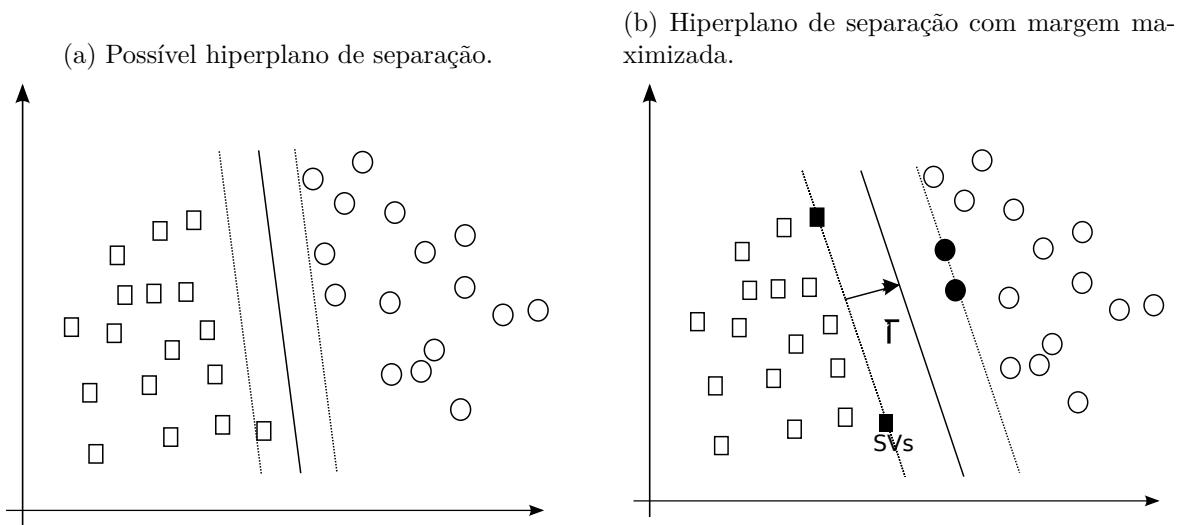
Para quaisquer x_1 e x_2 pertencentes aos *SVs*, um em cada lado, pode-se afirmar que:

$$\mathbf{w} \cdot \mathbf{x} = 2 \quad (162)$$

A margem Γ , ilustrada na Figura 29 (b), será dada pela projeção do vetor $\mathbf{x} = (\mathbf{x}_1 - \mathbf{x}_2)$ sobre o vetor $\mathbf{w}/\|\mathbf{w}\|$ normal ao hiperplano. Sabendo-se de (162), obtém-se que:

$$\Gamma = \frac{1}{\|\mathbf{w}\|} \quad (163)$$

Figura 29: Representação de hiperplanos de separação de classes.



Fonte: elaborado pela autora.

Os *SVs* são imperativos no posicionamento do hiperplano. Se retirados, o hiperplano mudará de posição. Se retirados vetores que não fazem parte dos *SVs* o hiperplano permanece o mesmo.

A maximização da margem implica na minimização de $\|\mathbf{w}\|$, ou seja, pode-se aplicar um problema de otimização restrita com a seguinte função custo:

$$\Phi(\mathbf{w}) = \frac{1}{2} \mathbf{w} \cdot \mathbf{w} \quad (164)$$

sujeita a seguintes restrições:

$$y_i [\mathbf{w} \cdot \mathbf{x}_i + b] \geq 1 \quad (165)$$

O problema de otimização tem como custo uma função convexa e as restrições são lineares. Aplicando a teoria dos multiplicadores de Lagrange, podem-se realizar os desenvolvimentos seguintes com a finalidade de se encontrar um ótimo para a função objetivo $L(\cdot)$ que representa um problema primal de otimização:

$$L(\mathbf{w}, b) = \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^m \alpha_i [y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1] \quad (166)$$

sendo que a condição $\partial L / \partial b = 0$ resulta em:

$$\sum_{i=1}^m \alpha_i y_i = 0 \quad (167)$$

Substituindo (167) em (166) obtém-se o problema de otimização dual, no qual, α representam os multiplicadores de Lagrange:

$$W(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{ij=1}^m \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (168)$$

As restrições tornam-se:

$$\alpha_i \geq 0 \quad (169)$$

$$\sum_{i=1}^m \alpha_i y_i = 0 \quad (170)$$

A partir da resolução do problema de otimização obtém-se a função de decisão $D(\cdot)$ do classificador com margem maximizada. Esta função pode então ser utilizada com um novo dado de entrada z a ser classificado, ou seja:

$$D(z) = \text{sign} \left[\sum_{j=1}^m \alpha_j y_j (x_j \cdot z) + b \right] \quad (171)$$

Os multiplicadores de Langrange nulos não são essenciais para a separabilidade do problema, já multiplicadores com valores unitários são os *SVs* e multiplicadores com grandes valores podem ser considerados dados espúrios (*outliers*).

Para problemas não linearmente separáveis a representação dos dados deve ser mapeada em um novo espaço de maior dimensão, de forma que o problema neste novo espaço possa tornar-se separável. Em (171), os dados são utilizados dentro de um produto interno; dessa forma, substitui-se este produto interno por outro de um espaço de dimensionalidade maior. O novo produto interno é definido como *kernel* $K(\cdot)$ e mapeia os pares de dados para o chamado espaço futuro, isto é:

$$x_i \cdot x_j \rightarrow K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j) \quad (172)$$

Inúmeras funções *kernel* podem ser utilizadas, como é o exemplo de funções Gaussianas e polinomiais, além de diversos algoritmos poderem definir *kernels*, desde que o Teorema a seguir seja respeitado.

Teorema 3 (kernel). Seja $K(\cdot)$ uma função, com c_1, \dots, c_n reais. Se a seguinte condição for respeitada:

$$\sum_{ij} K(x_i, x_j) c_i c_j \geq 0 \quad (173)$$

então esta função pode mapear um produto interno em um possível espaço de maior dimensão, ou seja, $K(x, y) = \phi(x) \cdot \phi(y)$

Funções *kernel* muito utilizadas, além da linear são as funções Gaussiana e polinomial, dadas por (174) e (175).

$$K(x, x') = e^{-\|(x-x')\|^2 \gamma} \quad (174)$$

$$K(x, x') = (\langle x, x' \rangle + 1)^d \quad (175)$$

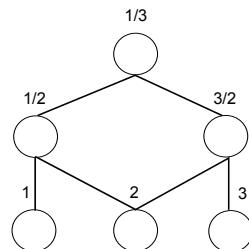
Com todo o discorrido, pode-se então resumir as etapas de treinamento de uma *SVM* utilizada em classificação binária de padrões por:

- Escolher uma função *kernel* $K(x_i, x_j)$;
- Maximizar $W(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{ij=1}^m \alpha_i \alpha_j y_i y_j K(x_i \cdot x_j)$ sujeito às restrições $\alpha_i \geq 0$ e $\sum_i \alpha_i y_i = 0$;
- Calcular o *bias* $b = \frac{1}{2} \left[\min \left(\sum_{i|y_i=+1} \alpha_i y_i K(x_i, x_j) \right) + \max \left(\sum_{i|y_i=-1} \alpha_i y_i K(x_i, x_j) \right) \right]$ e
- Obter a função de decisão $D(z) = \text{sign} \left(\sum_{i=1}^m \alpha_i y_i K(x, z) + b \right)$.

4.3.3.2 *Support Vector Machines* em classificação multiclasses de padrões e *soft margins*

Para pequenos números de classes, um método comum de classificação utilizado pelas *SVMs*, relatado na literatura, é denominado árvore de confrontação binária. Suponha na Figura 30 a existência de 3 classes. Uma primeira confrontação seria realizar uma classificação binária entre a classe 1 e 3 e com o resultado continuar com classificações binárias nos nós subsequentes até obter no resultado final uma determinada classe.

Figura 30: Método de confrontação binária de *SVMs* para três classes.



Fonte: elaborado pela autora.

Outro método é denominado "um contra todos", no qual para classificar k classes, constrói-se k modelos do classificador binário entre a k -ésima classe e todas as outras. Para classificar uma nova amostra passa-se por todos os k modelos e verifica-se qual classe obteve a maior incidência.

A maioria dos conjuntos de dados contém ruídos e assim como outros sistemas de aprendizagem, as *SVMs* podem resultar em erros de generalização. Este efeito de ruídos e

outliers podem ser reduzidos por meio da utilização do conceito de *soft margins*. Segundo Lorena e Carvalho (2007), com *soft margins*, permite-se que alguns dados possam violar a restrição dada por (165), introduzindo-se variáveis de folga ξ_i , ou seja:

$$y_i [\mathbf{w} \cdot \mathbf{x}_i + \mathbf{b}] \geq 1 - \xi_i \quad (176)$$

A otimização deve ser feita por uma nova função custo, que além de minimizar $\|\mathbf{w}\|$, minimiza a somatória da variável $C \sum_{i=1}^m \xi_i$, logo (164) torna-se:

$$\Phi(\mathbf{w}) = \frac{1}{2} \mathbf{w} \cdot \mathbf{w} + C \sum_1^m \xi_i \quad (177)$$

com a seguinte restrição:

$$0 \leq \alpha_i \leq C \quad (178)$$

onde o parâmetro C representa um variável de equilíbrio entre a complexidade do modelo e o erro de treinamento, ou seja, a variável realiza um compromisso entre erros de classificação durante o treinamento e a simplicidade da função de decisão. O valor ótimo de C deve ser obtido a partir de experimentação.

A tarefa de otimização será então maximizar a margem e ao mesmo tempo permitir que alguns vetores estejam dentro da margem, minimizando o efeito de alguns dados extremos no posicionamento do hiperplano. O problema primal passa a ser:

$$L(\mathbf{w}, b, \alpha, \xi) = \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i [y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 + \xi_i] - \sum_1^m r_i \xi_i \quad (179)$$

O problema de otimização passará a ter dois multiplicadores de Langrange, α_i e r_i :

$$\alpha_i \geq 0 \quad (180)$$

$$r_i \geq 0 \quad (181)$$

Aplicando-se as condições de $\partial L / \partial b$, $\partial L / \partial \mathbf{w}$ e $\partial L / \partial \xi$ e substituindo-se em (179) obtém-se a mesma função objetivo dada em (168), porém com as seguintes restrições:

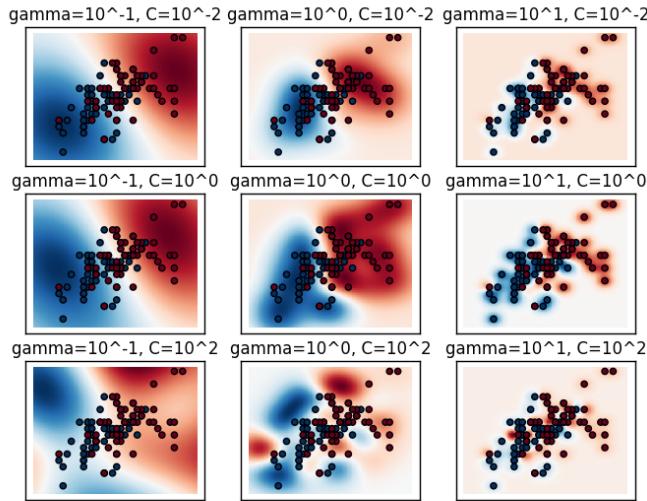
$$0 \leq \alpha_i \leq C \quad (182)$$

$$\sum_{i=1}^m \alpha_i y_i = 0 \quad (183)$$

O parâmetro de regularização pode também ser utilizado de forma desbalanceada, ou seja, quando se sabe que uma classe possui mais amostras que a outra. Dessa forma, o parâmetro C irá colocar mais ênfase em acertar as amostras da classe menos favorecida.

SVMs com *Kernel* linear são bastante simples. Já os *SVMs* com *Kernel* Gaussiano merecem maior atenção no que tange a sintonização de seus parâmetros, durante a aprendizagem. Os comportamentos do modelo são muito sensíveis aos parâmetros de regularização e da função *kernel*. Por exemplo, em *SVMs* com *Kernel* Gaussiano, se γ é muito alto, o raio de influência dos *SVs* irá apenas incluir os próprios *SVs*, enquanto que para valores pequenos de γ , o classificador é muito restrito e não captura a complexidade dos dados, como esta representado na Figura 31.

Figura 31: Função de decisão para vários parâmetros de uma SVM com *Kernel Gaussiano*.



Fonte: Scikit Learn Documentation - (SCIKIT... ,)

4.3.3.3 *Support Vector Machines para classificação de uma só classe - Detecção de Novidades*

O objetivo da classificação de padrões é distinguir dados de teste dentre um número de classes, usando dados de treinamento. Porém, muitas vezes detêm-se apenas dados de uma classe e dessa forma, o objetivo se torna descobrir se novos dados são iguais ou não aos dados do treinamento, chamado também de detecção de novidades. As *SVMs* de uma só classe ganharam bastante popularidade nas últimas décadas para realizar tal tarefa.

A utilização de *SVMs* para detecção de novidade foi proposta por Schölkopf et al. (2001). Basicamente, neste caso separa-se todos os pontos de dados da origem e maximiza-se a distância do hiperplano de separação. Isso resulta em uma função de decisão binária que retorna + 1 em uma pequena região do espaço de entradas e -1 em outro lugar. A função de minimização é ligeiramente diferente da formulação original dos *SVMs*:

$$\Phi(\mathbf{w}) = \frac{1}{2} \mathbf{w} \cdot \mathbf{w} + \frac{1}{\nu} \sum_{i=1}^m \xi_i - \rho \quad (184)$$

sujeita à seguintes restrições:

$$(\mathbf{w} \cdot \phi(x_i)) \geq \rho - \xi_i \quad (185)$$

$$\xi_i \geq 0 \quad (186)$$

Na formulação anterior, para classificação multi-classes, o parâmetro C decide a suavidade da função de decisão. Para a classificação de uma só classe, o responsável por este compromisso é o parâmetro ν .

De forma similar, utilizando-se as técnicas de Lagrange, a função de decisão torna-se:

$$D(z) = \text{sign}(\sum_{i=1}^n \alpha_i K(x, x_i) - \rho) \quad (187)$$

Este método cria assim um hiperplano que tem distância máxima da origem.

4.3.4 Problemas de Generalização - *Overfitting*

É necessário construir os classificadores utilizados nesta tese observando-se o fenômeno do *overfitting*, no qual obtém-se uma topologia em que a classificação realizada adere totalmente os valores de treinamento, porém não conseguem generalizar o aprendizado.

Um grande número de neurônios em uma RNA, assim como um grande número de camadas intermediárias, podem não indicar uma boa generalização do aprendizado das redes neurais artificiais. Ainda, valores extremos do parâmetro de regularização e de parâmetros do *Kernel* de *SVMs* podem significar problemas de generalização. Estas características, podem, inclusive, levar esses sistemas ao sobre-ajuste. Quando nessa situação, o erro de treinamento do classificador é aproximadamente nulo, porém, quando apresentado à dados de teste, apresenta erros elevados. Diminuir o número de camadas e neurônios pode ser uma solução, porém, pode-se chegar a reduzir a eficiência da rede.

Um procedimento comum para contornar o erro de *overfitting* em RNAs é denominado parada antecipada (*early stopping*). A parada antecipada consiste em dividir o conjunto de dados em três conjuntos, o de treinamento; o de validação e o de teste. Os conjuntos de treinamento e validação são apresentados paralelamente durante o processo de treinamento, porém, apenas o primeiro é utilizado para atualizar os pesos sinápticos. Durante o treinamento, o erro do conjunto de treinamento vem ininterruptamente diminuindo, assim como o de validação. A partir do momento em que o erro do conjunto de validação começa a aumentar verifica-se o começo de *overfitting* e o treinamento é então interrompido. Este mecanismo é usado em importantes trabalhos de classificação de falhas como em (SUETAKE, 2012). Porém, nesta tese, de maneira a verificar a ocorrência de *overfitting* das RNAs e *SVMs* utilizou-se a técnica de validação cruzada, como será apresentado a seguir.

4.3.5 Validação Cruzada de K partições

O método padrão para avaliar o desempenho de um algoritmo de aprendizado de máquina e estimar seu erro é a validação cruzada. A validação cruzada é uma maneira sistemática de obter os resultados do algoritmo de forma repetida e dessa forma diminuir a variância de testes únicos.

A validação cruzada consiste na divisão dos dados em K partições diferentes. Utilizam-se $K - 1$ partições para treinar o algoritmo e utiliza-se uma partição para o teste. Depois, com a mesma divisão, utilizam-se outras $K - 1$ partições para o treino e uma partição

para o teste. Realiza-se essa repetição por K vezes utilizando-se cada partição como subconjunto de testes por uma vez. Os resultados das K avaliações são então ponderados, ou seja, tira-se a média e desvio padrão das avaliações como métrica final de desempenho. Portanto, cada dado disponível é utilizado uma vez para teste e $K - 1$ vezes para o treinamento do algoritmo.

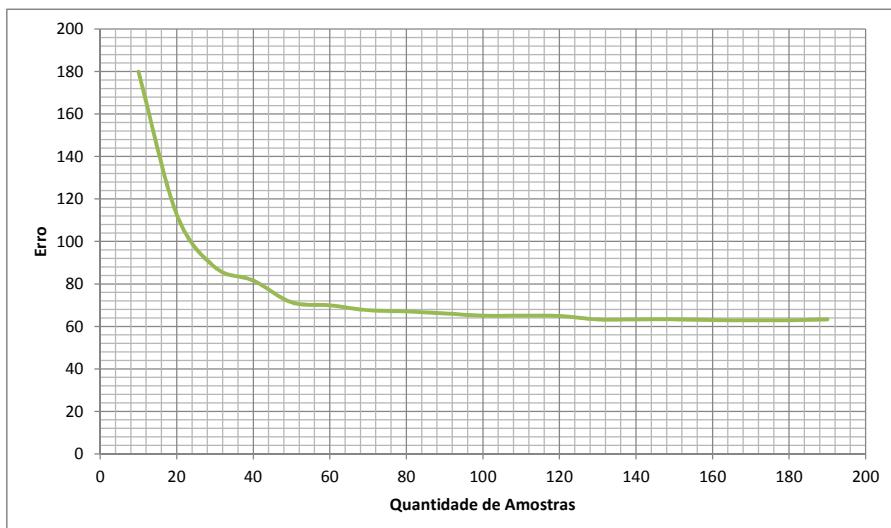
Uma topologia com média de acertos alta, porém com grande desvio padrão indica que o algoritmo não está generalizando o conhecimento de forma sistemática e o fenômeno do *overfitting* deve estar ocorrendo.

Para reduzir ainda mais a variância dos resultados, pode-se realizar a validação cruzada, com K partições, repetidas vezes, considerando-se diferentes distribuições de dados em cada partição. Esta avaliação melhora ainda mais a estimativa de generalização do algoritmo. Ademais, a validação cruzada estratificada analisa ainda mais a variância dos resultados. Neste tipo de validação cruzada, no caso de sistemas de classificação de padrões, garante-se, durante a divisão dos dados, que cada partição mantenha, aproximadamente, a correta proporção de dados de cada classe analisada.

4.3.6 Curvas de Aprendizagem

Uma das dificuldades nos problemas de aprendizado de máquina é saber qual a quantidade de amostras necessárias para o correto treinamento dos algoritmos. As curvas de aprendizagem apresentam o desempenho do classificador em relação a quantidade de amostras disponibilizadas para seu treinamento. A Figura 32 apresenta um exemplo de curva de aprendizagem (WITTEN; FRANK, 2005).

Figura 32: Exemplo de curva de aprendizado.



Fonte: Milion (2014).

Observa-se nas curvas de aprendizagem uma região onde um pequeno aumento no

número de amostras causa grande melhora na performance do algoritmo de aprendizagem. A partir de certo ponto, o aumento do número de amostras praticamente não impacta a performance e o erro de classificação converge (assíntota da curva de aprendizagem).

A curva de aprendizagem é levantada refazendo-se o treinamento do classificador, porém, com dados amostrados aleatoriamente. O treinamento é feito, então, com porcentagens crescentes de dados até que todo o conjunto de dados disponíveis seja utilizado. O classificador terá atingido todo seu potencial de generalização quando a curva de aprendizagem atingir sua assíntota. Caso essa convergência não seja alcançada, um aumento do número de amostras poderia melhorar o desempenho do classificador (WITTEN; FRANK, 2005).

4.4 Filtros FIR - Finite Impulse Response

Alguns sinais experimentais deverão passar por um processo de filtragem. A seguir, uma breve revisão sobre os filtros do tipo FIR é realizada.

Os filtros *Finite Impulse Response* (FIR) são filtros digitais bastante utilizados, pois eles são considerados estáveis e de fase linear, ou seja, eles inserem o mesmo atraso para as várias componentes de frequência. Durante o processo de filtragem, o atraso é facilmente corrigido por intermédio de um deslocamento no tempo do sinal. Um filtro FIR de tempo discreto e de ordem N realiza a seguinte operação:

$$\begin{aligned} y[n] &= b_0x[n] + b_1x[n-1] + \cdots + b_Nx[n-N] \\ &= \sum_{i=0}^N b_i \cdot x[n-i] \end{aligned} \tag{188}$$

onde:

- ◻ $x[n]$ é o sinal a ser filtrado no instante n ,
- ◻ $y[n]$ é a saída do filtro no instante n ,
- ◻ N é a ordem do filtro,
- ◻ b_i são os coeficientes do filtro, referentes ao valor da resposta ao impulso do filtro nos instantes $0 \leq i \leq N$

Este cálculo é conhecido como convolução discreta. A resposta ao impulso do filtro é dado ela série infinita:

$$h[n] = \sum_{i=0}^N b_i \cdot \delta[n-i] = \begin{cases} b_n & 0 \leq n \leq N \\ 0 & \text{caso contrário.} \end{cases} \tag{189}$$

CAPÍTULO 5

Aspectos da Bancada Experimental para Ensaios de Falhas em Motores de Indução Trifásicos

5.1 Disposição Geral da Bancada de Experimentos

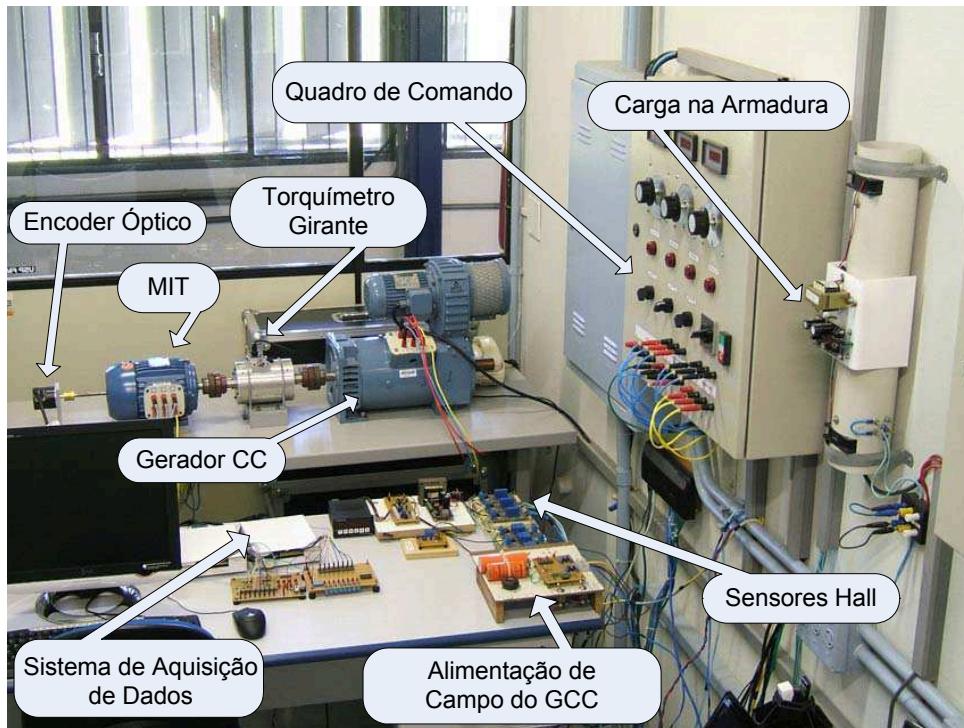
Neste capítulo é descrita toda a estrutura responsável pela aquisição dos dados experimentais gerados para a aplicação e o desenvolvimento do trabalho de identificação de falhas em MIT.

A Figura 33 ilustra a composição da estrutura dos laboratórios utilizados para a aquisição dos sinais, detalhadas a seguir:

1. **Bancada experimental:** O laboratório é composto por uma bancada experimental, na qual estão instalados o MIT; a Máquina de Corrente Contínua (MCC); o *encoder* e o torquímetro. A MCC atua como gerador e é acoplada ao MIT mediante um torquímetro rotativo, sendo responsável pela simulação experimental de uma determinada carga acoplada ao eixo do MIT;
2. **Circuito de alimentação do Gerador de Corrente Contínua (GCC):** Consiste em um circuito de alimentação da bobina de campo do GCC, cuja carga é conectada à bobina de armadura. O torque resistente imposto pelo gerador pode ser alterado, variando-se a tensão do enrolamento de campo, que é conectada a um filtro e um retificador monofásico. Alternativamente, tal ajuste pode ser realizado mediante a variação da carga acoplada no enrolamento de armadura;
3. **Quadro de comando:** O laboratório possui um quadro de comando no qual se realiza a escolha do acionamento (estrela ou triângulo), a escolha do tipo de alimentação (partida direta ou inversor), assim como o ajuste de tensão aplicada no MIT, e

- 4. Circuitos de acondicionamento de sinais:** São os circuitos utilizados no acondicionamento dos sinais dos sensores e que enviam os sinais tratados para a placa de aquisição de dados localizada em um computador.

Figura 33: Esquema geral do laboratório de ensaios de máquinas elétricas.



Fonte: elaborado pela autora.

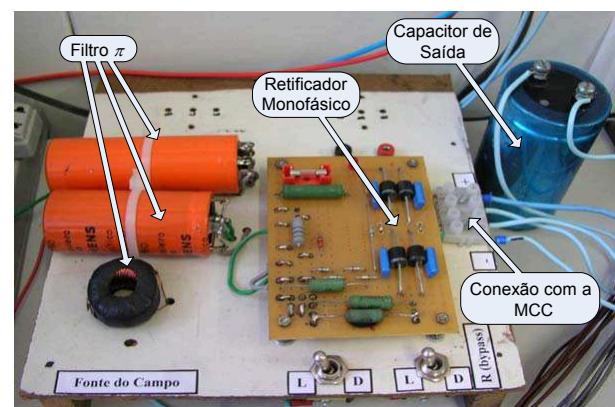
A 34 (a) ilustra o Variac de 1800 W, enquanto que a 34(b) mostra o circuito da fonte de tensão de alimentação do enrolamento de campo.

Figura 34: Excitação do enrolamento de campo do GCC.

(a) Variac



(b) Fonte de alimentação de campo.



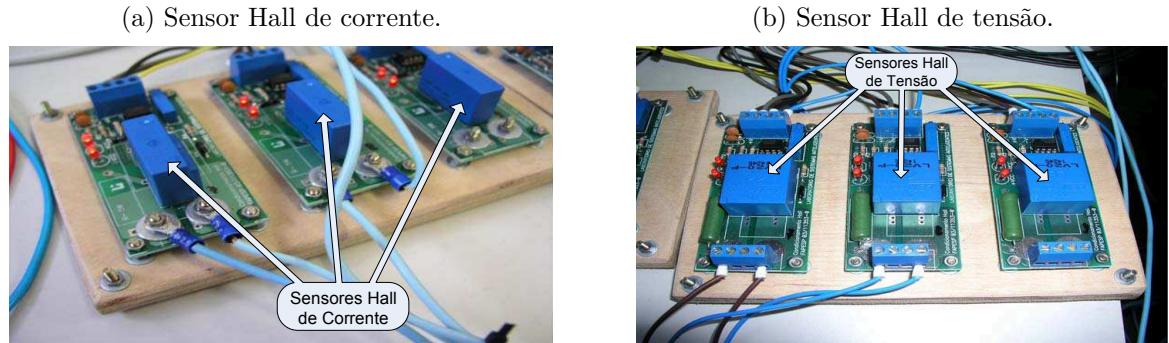
Fonte: elaborado pela autora.

O MIT utilizado no laboratório caracteriza-se por ser um motor linha *standard* do fabricante WEG, 1,0 cv, 220V/380V, 4 polos, 60 Hz, 4,1 Nm. O motor possui 58 espiras por bobina no estator e 6 bobinas por fase, totalizando, 348 espiras por fase. A sua gaiola de esquilo é formada por 34 barras.

A MCC possui 2 kW de potência, 190 V de tensão nominal de campo e 250 V de tensão nominal de armadura. O *encoder* óptico incremental apresenta uma resolução de 2000 pulsos por rotação.

As correntes do GCC são adquiridas por meio do sensor Hall de corrente LAH-25 NP do fabricante LEM (35(a)). O acondicionamento de sinal é realizado utilizando-se o amplificador operacional TL081 com ajuste de *offset*. As tensões do GCC são aquisitadas por intermédio do sensor Hall LV-20P do fabricante LEM (35(b)). Uma única placa de acondicionamento é adaptada para receber os sinais dos sensores Hall de corrente e tensão. Já as variáveis elétricas do MIT são mensuradas por meio de sensores Hall inseridos internamente ao quadro de comando.

Figura 35: Sensores Hall de corrente e tensão.



Fonte: elaborado pela autora.

O laboratório de pesquisa é equipado com um sistema de aquisição de dados composto por uma placa *National Instruments* modelo NI-DAQmx PCIe-6259, a qual dispõe de 32 canais analógicos de entrada de 16 bits, com taxa de aquisição de 1,25 Mega-amostras por segundo, 4 canais analógicos de saída de 16 bits, com taxa de 2,8 mega-amostras por segundo, e 48 canais de I/O digitais com capacidade de operar na frequência de *clock* de até 10 MHz. A placa é conectada no barramento PCI-Express do computador por um bloco conector SCB-68 que, além de prover a interface de conexões, permite também a implementação de filtros de sinais em hardware. O laboratório também conta com o oscilógrafo YOKOGAWA DL 750, que é capaz de realizar aquisições com altas taxas de amostragem.

Alguns rotores e motores foram preparados para simular as falhas elétricas e mecânicas dos MIT. Neste trabalho serão analisados defeitos de barras, com acionamento direto pela rede e com acionamento por inversor de frequência, porém a bancada conta com a possibilidade de simular falhas de curto-círcuito e rolamentos defeituosos.

Os sinais elétricos aquisitados para a parte experimental desta pesquisa foram processados nos ambientes MATLAB e WEKA.

5.2 Inserção de Defeitos nas Barras de Rotores

A inserção de defeitos nos rotores de MITs consistiu na perfuração, com caminho radial, do rotor, por meio de uma broca com 6,0 mm de diâmetro, que é suficientemente maior que a largura da barra da gaiola de esquilo. A 36(a) ilustra as etapas de seccionamento das barras. A 36(d) ilustra a imagem de um rotor com duas barras seccionadas.

Figura 36: Procedimento para a inserção de falhas em rotores.

(a) Marcação para encontrar o centro do rotor.



(b) Processo de seccionamento da barra da gaiola.



(c) Imagem da barra seccionada.



(d) Imagem de duas barras seccionadas.



Fonte: elaborado pela autora.

Sucessivas substituições de rotores defeituosos foram realizadas a fim de se constituir um banco de dados das variáveis monitoradas.

CAPÍTULO 6

Metodologia

Diante a justificativa e relevância do tema, apresentados nos Capítulos 1 e 2, e dos aspectos das ferramentas matemáticas e computacionais, expostos nos Capítulos 3 e 4, adotou-se um conjunto de estratégias para a realização e desenvolvimento de um sistema de detecção e classificação de falhas em MITs. A metodologia desenvolvida é dividida em conjuntos de atividades, apresentadas, de forma resumida, assim como suas conexões, na Figura 37.

O fluxograma explicita a sequência e estrutura de atividades que foram necessárias para a realização do objetivo central desta pesquisa, o qual é novamente salientado:

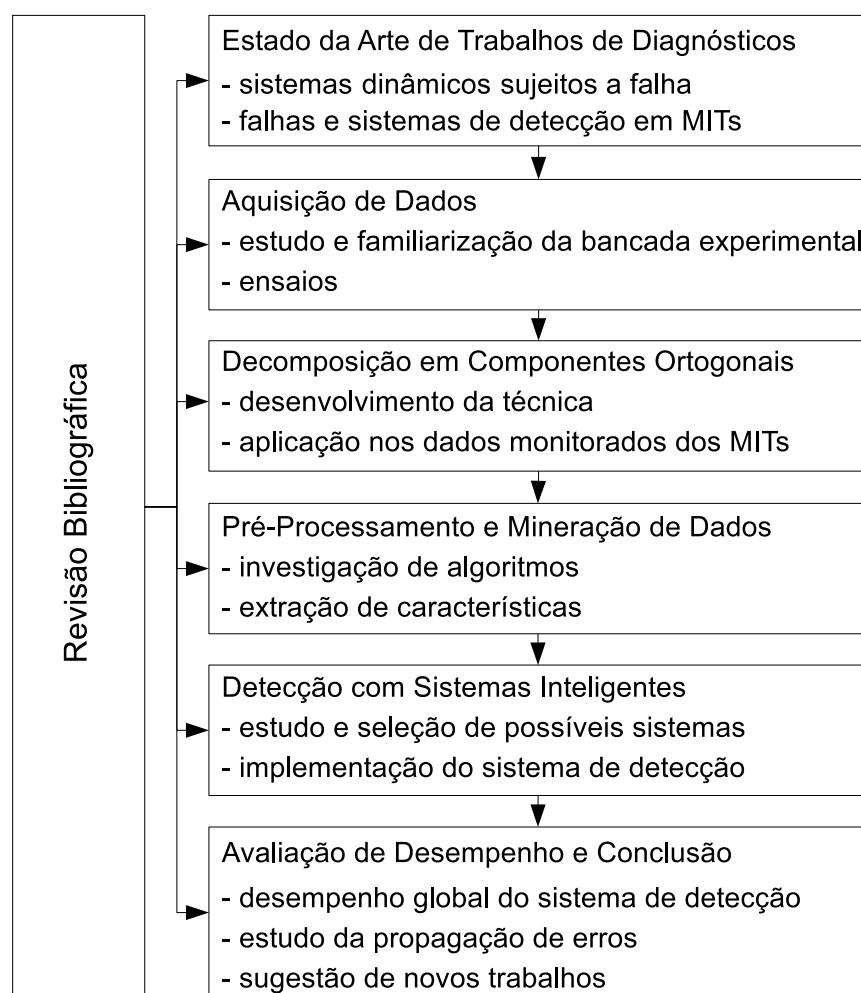
- Investigar, desenvolver, implementar e validar um método de diagnóstico automatizado de falhas em MITs, utilizando a ferramenta de DCO em conjunto com ferramentas de aprendizagem de máquinas.

Dentro desse contexto, os objetivos da pesquisa foram pautados em seis grandes grupos de atividades, que são detalhados a seguir:

1. Estudo do estado da arte de trabalhos de diagnósticos de sistemas dinâmicos sujeitos a falhas e, mais especificamente, de MITs;
2. Familiarização e estudo da bancada experimental e dos dados aquisitados para a realização da pesquisa;
3. Aprofundamento da técnica de DCO, estudo e desenvolvimento da técnica de DCO em sinais monitorados de tensão e corrente dos MITs. Investigação da aplicabilidade da ferramenta no problema em questão por meio de modelos matemáticos e aplicação em sinais reais;
4. Busca e aplicação de técnicas de processamento e mineração de dados, dedicadas à extração de características, as quais, utilizadas conjuntamente com a DCO,abilizem o sistema de diagnóstico e aumentem o desempenho do sistema final de detecção;

5. Seleção, projeto e utilização de sistemas inteligentes, os quais, a partir das características extraídas no processamento, sejam capazes de identificar a ocorrência e a severidade de falhas e
6. Avaliação de desempenho do sistema obtido.

Figura 37: Fluxograma da metodologia proposta.



Fonte: elaborado pela autora.

Por meio da metodologia desenvolvida, espera-se que esta tese contribua para a expansão das fronteiras da área do conhecimento de sistemas de diagnóstico de falhas em MITs e, ainda, de sistemas dinâmicos sujeitos a falhas e da área de processamento de sinais.

6.1 Simulações Computacionais

Foram simuladas, por meio de modelos matemáticos, diversas situações de falha nas barras do rotor em diferentes carregamentos, de forma a permitir o entendimento da DCO como ferramenta de processamento de sinais capaz de retornar índices altamente correlacionados às falhas. O intuito deste trabalho é propor uma metodologia de diagnóstico de quebras de barras que seja independente do carregamento do eixo rotativo do MIT e da frequência de acionamento. Assim, utilizou-se as simulações de forma a investigar índices que tenham alta correlação com o fenômeno da falha, além de monotonicidade e baixa variabilidade. Os modelos utilizados estão detalhados no Capítulo 4 e os resultados da simulação e as análises advindas desses resultados são discutidas no Capítulo 7.

6.2 Sistema de Diagnóstico

O sistema final de diagnóstico, que é detalhado de forma resumida na Figura 38 foi realizado com dados advindos da bancada experimental.

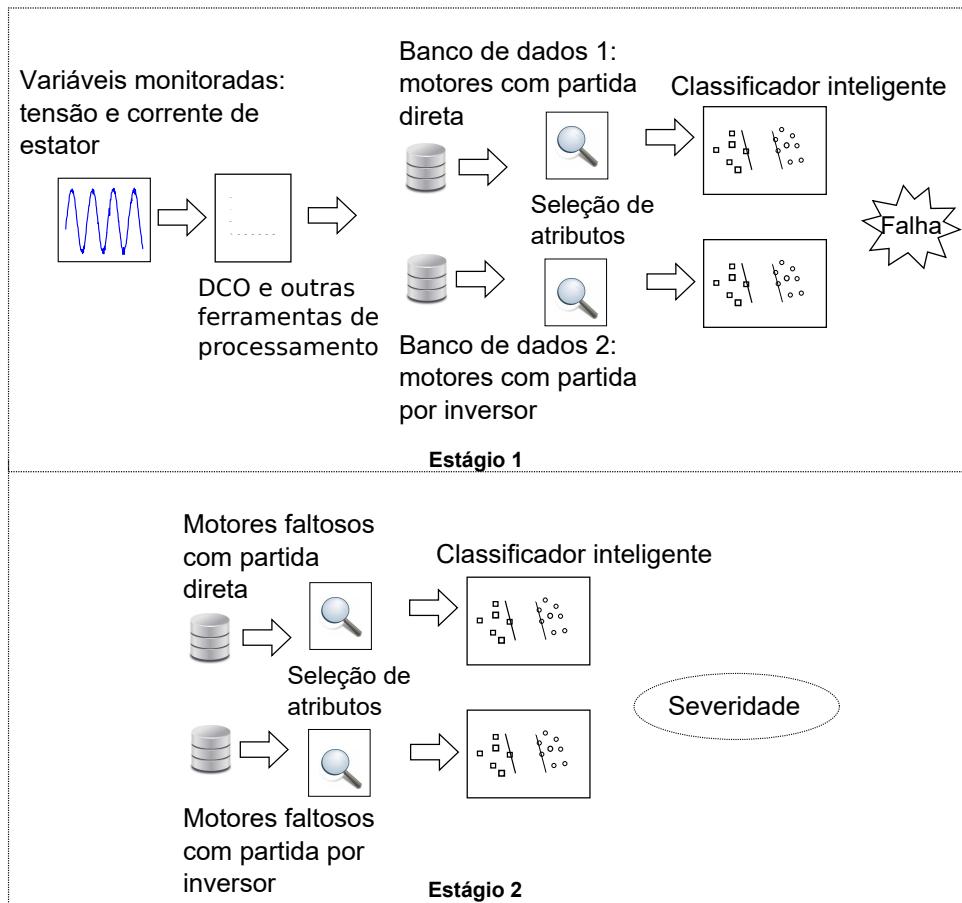
Para a validação dos sistemas e da aplicabilidade da DCO como ferramenta de processamento de sinais, ensaiou-se motores saudáveis e com falha de barras quebradas, de forma a constituir-se um estudo de caso para este tipo de falha. Os motores foram acionados diretamente pela rede e por inversores de frequência em diversas situações de carga constante.

O sistema monitora tensão e corrente de estator e então processa esses sinais com a ferramenta de DCO. Outros processamentos como a obtenção do valor RMS das componentes ortogonais são realizados. A seleção de atributos é utilizada para a redução de dimensionalidade dos bancos de dados e para a obtenção de um conjunto relevante de índices específicos às falhas. As detecções de falha são feitas por classificadores. Neste trabalho tanto *SVMs* quanto *RNAs* são utilizadas para o processo de diagnóstico. O primeiro estágio de classificação é feito para motores normais e faltosos. Em cascata com o primeiro, o segundo estágio é designado para classificação de severidade da falha, representado pelo número de barras quebradas.

6.3 Ensaios de Barras Quebradas e Aspectos da aquisição de sinais

Para a construção do banco de dados, foram realizados ensaios em motores saudáveis e motores com falha em partida direta com tensão de alimentação trifásica equilibrada e frequência de 60 Hz. A fim de se constituir um banco de dados robusto, aplicaram-se carregamentos de 0,5 Nm, 1,0 Nm, 1,5 Nm, 2,0 Nm, 3,0 N, 3,5 Nm e 4,0 Nm ao eixo dos MITs. A corrente de estator e a tensão de alimentação foram aquisitadas durante

Figura 38: Sistema de Diagnóstico proposto.



Fonte: elaborado pela autora.

aproximadamente 4 segundos em regime permanente. Dessa forma, um banco de dados de partida direta foi obtido, no qual, cada amostra (instância) é dada pela combinação ‘motor+carga’.

Já nos ensaios com partida por inversor de frequência, os experimentos foram realizados em diferentes frequências: 40 Hz, 45 Hz, 50 Hz e 55 Hz. Cada instância foi obtida pela combinação ‘motor+frequência+carga’, sendo os valores de torque os mesmos já citados.

Os seguintes motores sadios foram ensaiados:

- **Motor Normal:** Motor com rotor sadio. Este motor foi adaptado para também receber rotores com barras quebradas, de forma a simular as falhas;
- **Motor de Fábrica:** Motor novo sem nenhum tipo de adaptação;
- **Motor de Alto Rendimento:** Motor que apresenta características de construção e materiais diferentes de um motor normal e
- **Motor Adaptado:** MIT adaptado para ensaiar diversos curtos-circuitos no estator. Neste caso, não foram provocadas falhas de estator, sendo utilizado como um motor saudável.

A inclusão de diversos motores que tiveram adaptações realizadas é importante para tornar o diagnóstico robusto às situações reais de mudanças paramétricas como manutenção, troca de partes mecânicas e substituições de enrolamentos.

Diferentes rotores com distintos números de barras quebradas foram ensaiados, ou seja:

- Uma barra quebrada (1bq);
- Duas barras adjacentes quebradas (2bq);
- Quatro barras quebradas, sendo duas barras adjacentes quebradas em lados radialmente opostos (2x2bq) e
- Quatro barras adjacentes quebradas (4bq).

A maioria das quebras de barras em rotores são de barras adjacentes, pelos motivos já explicitados no Capítulo 2, ou seja, devido ao stress mecânico sofrido pelas barras que faceiam a barra quebrada. Dessa forma, optou-se por ensaiar a maioria das quebras como quebras adjacentes. Apenas um tipo de quebra, (2x2bq) tem barras quebradas em lados opostos, resultando em um distanciamento de 180° mecânicos. O banco de dados resultante é resumidamente ilustrado na Figura 39.

O banco de dados de partida direta resultou em 71 ensaios, considerando motores normais, com diversas severidades de falha e em diferentes carregamentos. Para o banco de dados com partida por inversores de frequência, condições normais e faltosas em diversos carregamentos resultaram em 125 ensaios diferentes.

A frequência de aquisição para os ensaios em partida direta foi de 3.84 kHz utilizando-se o sistema de aquisição do laboratório apresentado no Capítulo 5. Já para os casos de partida por inversores de frequência, o qual possui frequência de acionamento de 10 KHz a aquisição foi realizada em 100 kHz, utilizando-se o oscilógrafo DL 750. A tensão no barramento CC foi ajustada para a tensão plena da rede (311 V) e o algoritmo empregado foi o acionamento escalar V/f constante em malha aberta.

A ferramenta da DCO deve ser realizada com os sinais senoidais contínuos e periódicos. No caso dos motores com partida por inversor de frequência, esses sinais são chaveados como mostrado na Figura 40.

O espectro da tensão chaveada apresenta em seu componente fundamental a mesma amplitude e fase que o sinal de alimentação de referência. Isto é, apesar da tensão ser retangular, ela pode ser decomposta em duas parcelas: uma na frequência fundamental, que é idêntica à tensão de alimentação de referência e outra correspondente à soma de harmônicos que se situam nas proximidades dos múltiplos da frequência de chaveamento do inversor.

Assim, para que o processamento com a DCO seja correto, as tensões de alimentação devem ser filtradas. Desta forma, as modulações trazidas à corrente estatórica pela quebra

Figura 39: Banco de dados de MITs ensaiados com barras quebradas.

Instâncias - Banco de dados de partida direta		condição	motor	Torque (Nm)	
instâncias saudias	instâncias defeituosas				
normal	alto rendimento	0.5	normal	0.5	
				...	
		4.0		4.0	
		0.5		...	
				...	
	1 bb rotor	4.0	1 bb rotor	0.5	
				...	
		0.5		4.0	
		0.5		...	
				...	
4 bb rotor	alto rendimento	4.0	4 bb rotor	0.5	
				...	
		0.5		4.0	
		0.5		...	
				...	
	40 Hz	4.0	1 bb rotor	0.5	
				...	
		0.5		4.0	
		0.5		...	
				...	

Instâncias - Banco de dados de partida por inversor		condição	motor	Torque (Nm)	
instâncias saudias	instâncias defeituosas				
40 Hz	60 Hz	0.5	normal	0.5	
				...	
		4.0		4.0	
		0.5		...	
				...	
	... 40 Hz	4.0	4 bb rotor	0.5	
				...	
		0.5		4.0	
		0.5		...	
				...	
40 Hz	60 Hz	4.0	1 bb rotor	0.5	
				...	
		0.5		4.0	
		0.5		...	
				...	
	... 40 Hz	4.0	4 bb rotor	0.5	
				...	
		0.5		4.0	
		0.5		...	
				...	

Fonte: elaborado pela autora.

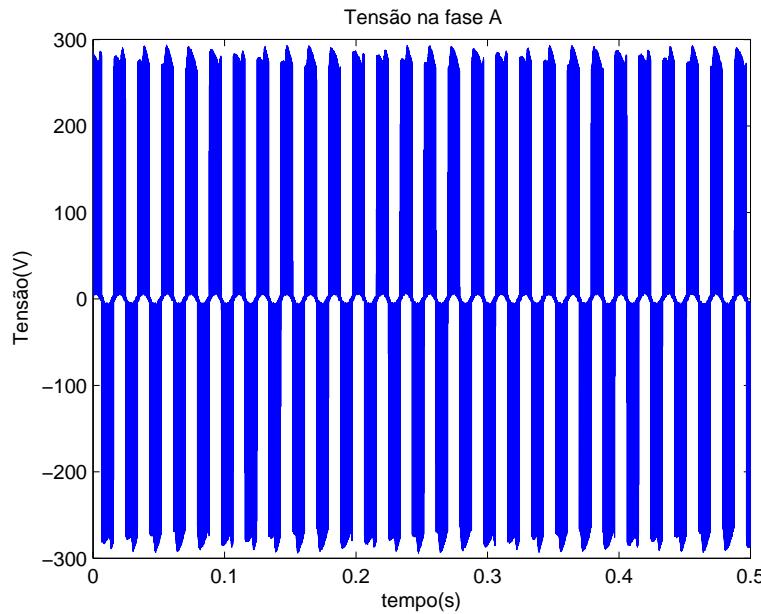
de barras no rotor serão traduzidas corretamente nas devidas componentes ortogonais. Um filtro passa baixa do tipo FIR com frequência de corte em 300 Hz é aplicado nos sinais de tensão. Pode-se perceber que a teoria de amostragem de Nyquist foi respeitada, a qual mostra que para uma reconstrução completa de um sinal, a frequência de amostragem deve ser de no mínimo duas vezes a frequência do sinal. Após a filtragem, as tensões fundamentais são obtidas, como representado na Figura 41.

Já as correntes elétricas nos MITs são filtradas pelo circuito de primeira ordem formado pelas resistências e indutâncias internas da máquina e já apresentam características contínuas e periódicas, apesar de apresentar distorções harmônicas, como apresentado na Figura 42. Sabe-se que quanto maior a frequência de chaveamento, menor a distorção de corrente. O aumento da frequência de chaveamento desloca os harmônicos para frequências maiores fazendo com que a atenuação provocada pela parte indutiva da impedância do sistema aumente.

6.4 Inferência

O diagnóstico de falhas é realizado com as ferramentas advindas da aprendizagem de máquinas descritas no Capítulo 4, ou seja, RNAs e *SVMs*.

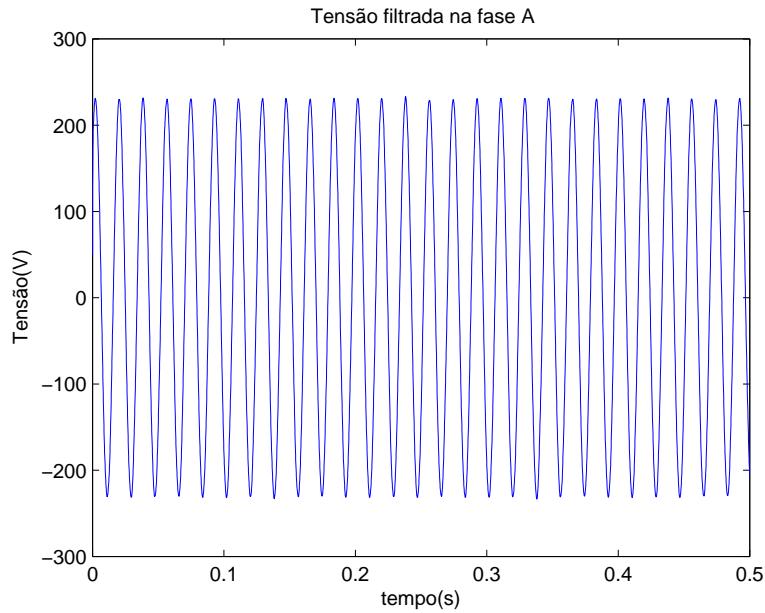
Figura 40: Tensão da fase A de um motor de 1 cv acionado por inversor de frequência.



Fonte: elaborado pela autora.

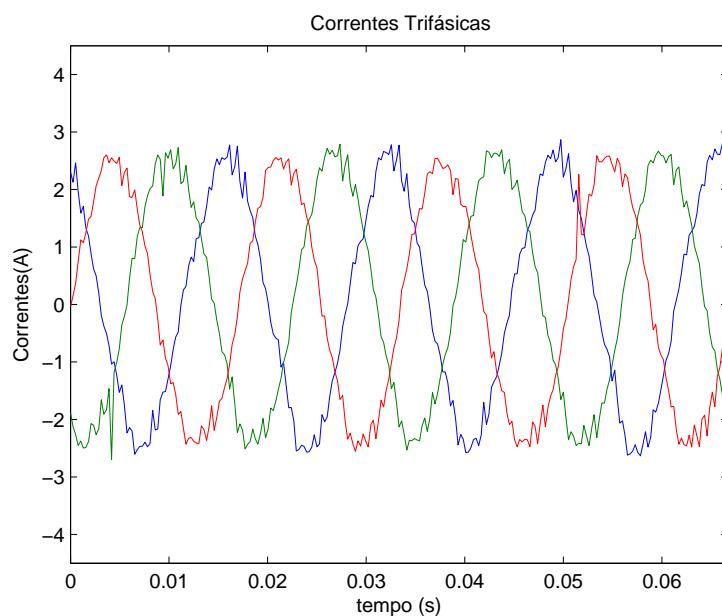
As *SVMs* foram escolhidas devido a sua eficiência em espaços de alta dimensionalidade. Dessa forma, se torna um bom classificador, com boa performance, para se estudar os resultados da redução de dimensionalidade. Além disso, as *SVMs* apresentam poucos parâmetros ajustáveis durante seu treinamento, tornando-se ótimas escolhas para a classificação. As *RNAs* são excelentes ferramentas de classificação e possuem um poder de generalização muito grande quando seus parâmetros são ajustados corretamente. Estes dois sistemas de inferência serão comparados no Capítulo 7.

Figura 41: Tensão filtrada da fase A de um motor de 1 cv acionado por inversor de frequência.



Fonte: elaborado pela autora.

Figura 42: Correntes trifásicas de um motor de 1 cv acionado por inversor de frequência.



Fonte: elaborado pela autora.

CAPÍTULO 7

Resultados e Discussões

Neste capítulo são apresentados os resultados obtidos pela aplicação da metodologia apresentada no Capítulo 6.

7.1 Simulações Computacionais

7.1.1 Efeitos da falha

Inicialmente, lançou-se mão de simulações computacionais de forma a interpretar os resultados da DCO como índices indicativos das falhas. As simulações foram implementadas no software Matlab através do *solver* de equações diferenciais ODE.

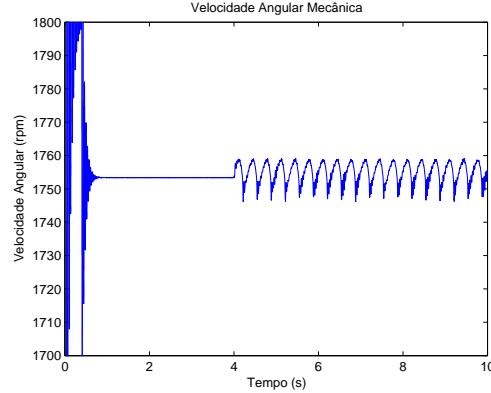
De forma a analisar a falha de barras quebradas, um motor de 2 hp, 60 Hz, 4 polos, 380 V, 28 barras no rotor, como proposto em Cunha, Lyra e Filho (2005), foi simulado. O ensaio deste motor, proposto já na literatura correlata, permite a validação correta das simulações realizadas neste trabalho, pois pode-se comparar os estados obtidos com os resultados anteriores reportados na literatura. Desta forma, pode-se garantir que a aplicação da DCO esta sendo feita em dados corretamente simulados. A frequência de escorregamento nominal desse motor é de 1,53 Hz e o torque nominal é de aproximadamente 8 Nm.

A simulação se inicia baseada no modelo simétrico dq e depois de 4 segundos uma falha de 4 bq é inserida no modelo. A Figura 43 mostra as curvas de velocidade e torque para situações distintas de carregamento desse motor. Como já discutido no capítulo Capítulo 2, pode-se observar a ondulação (ou *ripple*) tanto na velocidade quanto no torque do motor, fruto da assimetria na gaiola de esquilo. Esta ondulação possui frequência $f_b = 2sf_s$ dependente do escorregamento, que neste caso é próxima à 3 Hz. É possível notar que esta frequência de ondulação diminui em baixos carregamentos. São essas oscilações no torque e na velocidade que causam o aparecimento de bandas laterais no espectro da corrente de estator do motor.

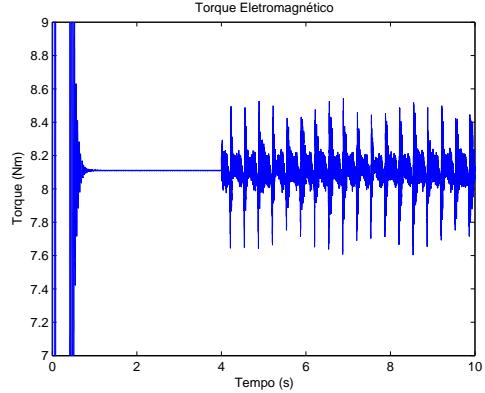
Na Figura 44 pode-se ver uma análise da FFT da corrente de estator para o motor com

Figura 43: Comparação dos efeitos de barras quebradas, no torque do motor e velocidade, para um MIT simulado com diferentes carregamentos. De 0 a 4 segundos o motor está sadio, e após 4 segundos insere-se um falha de 4bq.

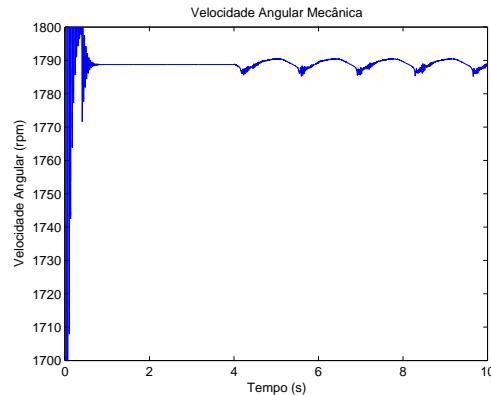
(a) Curva de velocidade para carga de 8 Nm



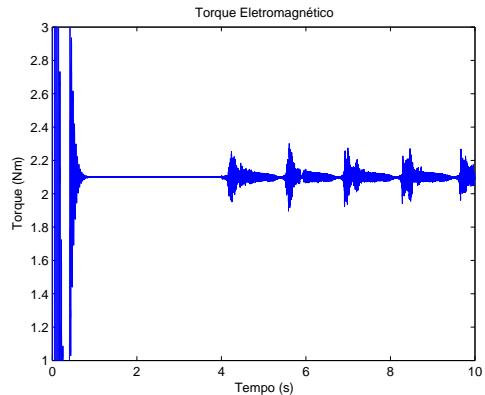
(b) Curva de torque para carga de 8 Nm



(c) Curva de velocidade para carga de 2 Nm



(d) Curva de torque para carga de 2 Nm



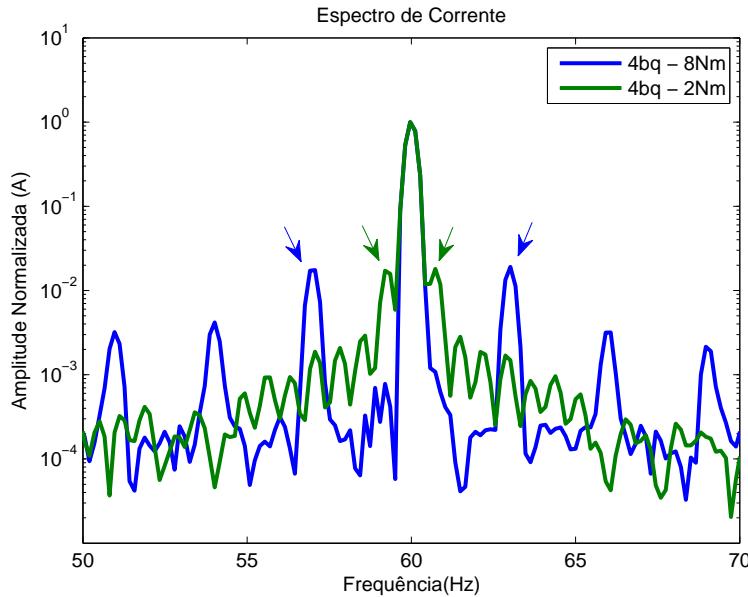
Fonte: elaborado pela autora.

4bq com carga nominal e com 25% da carga nominal. Percebe-se que a frequência das bandas laterais dependem do momento de inércia da carga. Fica claro que o espalhamento e a resolução espectral são de importância essencial para análises diagnósticas no domínio da frequência, principalmente em baixo torque, pois, observa-se que as bandas laterais se aproximam muito da componente de frequência fundamental e o espalhamento pode causar grandes prejuízos ao diagnóstico.

De forma a estudar-se os efeitos da falha de barras quebradas nas componentes ortogonais, processou-se os sinais de tensão e corrente com a técnica da DCO desde o início da simulação. Os valores RMS em respeito ao tempo das componentes ortogonais são mostrados na Figura 45. Como pode-se observar, durante o regime permanente em estado saudável, os valores RMS das componentes ortogonais são estáveis e constantes.

Pode-se perceber que as componentes $\|v_x^p(t)\|$ e $\|i_x^p(t)\|$, com $x = a, b, c$, respondem ao fenômeno da falha e oscilam com frequência $f_b = 2sf$, a qual, no caso analisado, é aproximadamente 3 Hz. Isto ocorre devido a modulação na corrente pela frequência das

Figura 44: Espectro de corrente da fase A do estator do motor simulado para carregamento de 8 Nm, 4bq e 2 Nm, 4bq.



Fonte: elaborado pela autora.

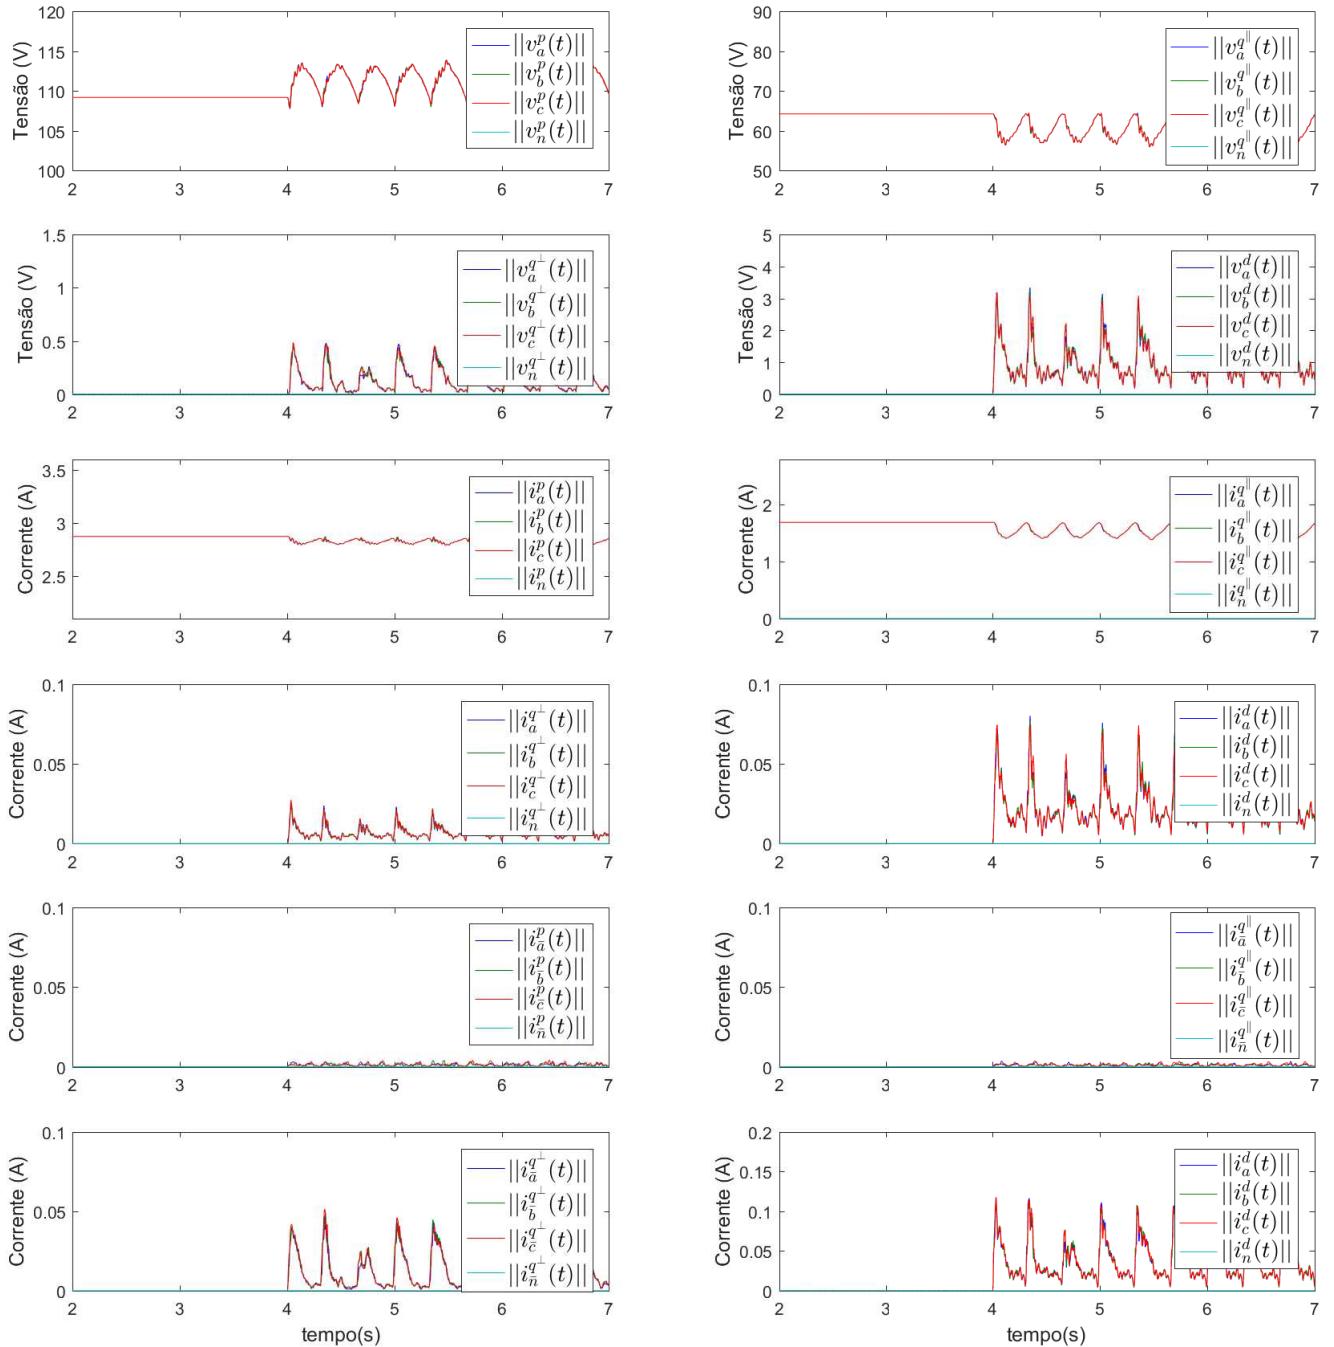
bandas laterais.

As componentes $\|v_x^{q\parallel}(t)\|$ e $\|i_x^{q\parallel}(t)\|$ também respondem à falha e as componentes $\|v_x^{\perp}(t)\|$ e $\|i_x^{q\perp}(t)\|$ se tornam não nulas quando a falha é provocada. Essas componentes traduzem a natureza reativa da falha de barras quebradas em um sistema que deixa de ser puramente senoidal, como discutido no Capítulo 3.

As componentes de tensão ortogonais ao plano das tensões de linha $\|v_{\bar{x}}^p(t)\|$, $\|v_{\bar{x}}^{q\parallel}(t)\|$, $\|v_{\bar{x}}^{q\perp}(t)\|$ e $\|v_{\bar{x}}^d(t)\|$ são nulas e não foram mostradas na figura, pois nesta simulação, as tensões de linha e de fase são ideais, simétricas e puramente senoidais, portanto, nenhuma parcela de tensão está fora do plano das tensões de linha. Por outro lado, as componentes de corrente ortogonais ao plano das tensões de linha $\|i_x^p(t)\|$, $\|i_{\bar{x}}^{q\parallel}(t)\|$, $\|i_{\bar{x}}^{q\perp}(t)\|$ e $\|i_{\bar{x}}^d(t)\|$ são não nulas na ocorrência da falha, pois, com a modulação na corrente de estator, pode-se afirmar que o plano não é capaz de gerar sozinho tais correntes. As componentes de neutro são nulas, pois não há desbalanço nas tensões de alimentação. Deve-se observar também que componentes que não podem ser representadas por elementos passivos se tornam não nulas depois da ocorrência da falha.

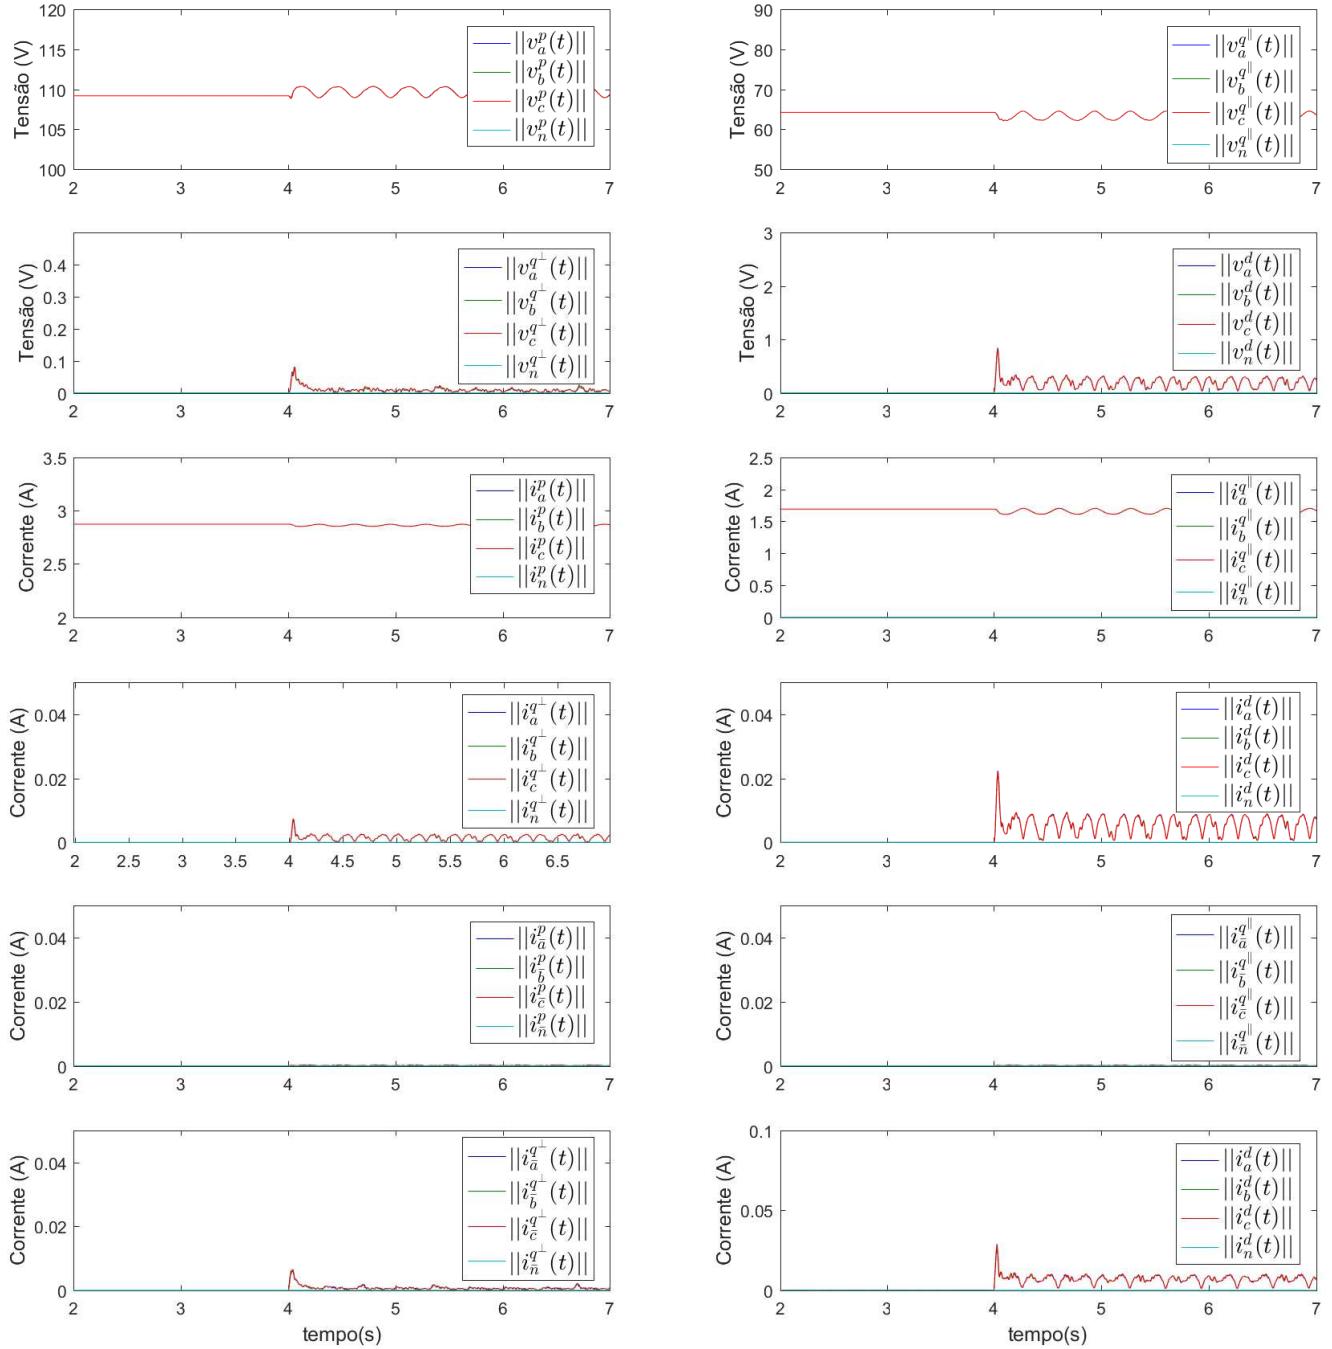
Quando sinais reais são analisados, componentes de tensão ortogonais ao plano são não nulas devido a possíveis desbalanços e conteúdos harmônicos na alimentação, como será explicitado nas discussões sobre os resultados experimentais. Observa-se pela Figura 45 que o valor RMS de componentes de tensão e correntes ativas, reativas, não lineares, e a oscilação de diversas componentes são extremamente correlacionadas com a falha. É importante frisar, então, que o valor RMS das componentes ortogonais formam um bom

Figura 45: Valores RMS das componentes ortogonais do motor simulado de 2 hp, 60 Hz, 4 polos, 380 V, 3.6 A e 28 barras no rotor. Em $t = 4$ s uma falha de 4bq é provocada.



Fonte: elaborado pela autora.

Figura 46: Valores RMS das componentes ortogonais do motor de 2-hp, 60 Hz, 4 polos, 380 V, 3.6 A e 28 barras no rotor. Em $t = 4$ s uma falha de 2bq é provocada.



Fonte: elaborado pela autora.

conjunto de indicadores para detectar barras quebradas.

Comparando-se a Figura 45 com a Figura 46, na qual alguns componentes são mostrados para o caso de 2 barras quebradas (2bq), percebe-se que a amplitude das oscilações aumenta com o número de barras quebradas.

7.1.2 Criação de índices para a classificação

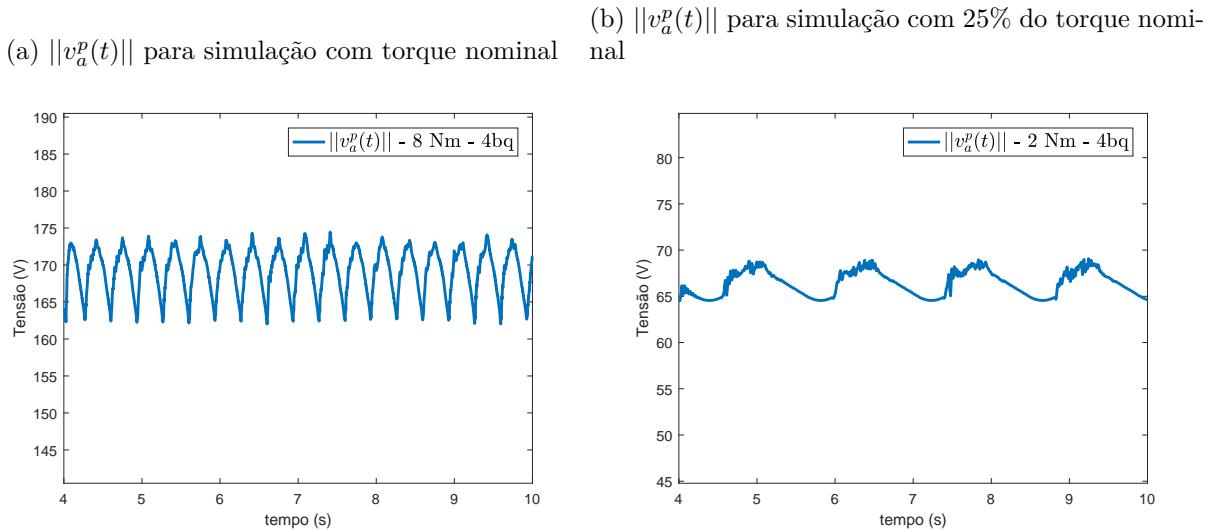
De forma a perpassar problemas com transformadas na frequência, como resolução espectral e espalhamento, pode-se obter métricas que utilizem o valor RMS das componentes ortogonais para serem usadas como entrada para os sistemas de decisão.

Para que esse conjunto de sinais possa ser usado no diagnóstico de falhas, índices devem ser criados partir das componentes ortogonais, que são sinais dependentes do tempo. Desta forma, as médias dos valores RMS dessas componentes em uma janela de aquisição podem ser utilizadas para formar um conjunto de índices relacionados ao acontecimento de uma falha.

Para um ciclo de trabalho onde o torque do MIT é mantido constante, a janela de aquisição de dados de tensão e corrente deve ser suficientemente larga para contemplar ao menos um período das oscilações dos valores RMS das componentes ortogonais, para que o cálculo de seus valores médios seja correto. Sabe-se de antemão que estes valores variam com frequência $f_b = 2sf_s$, assim, o período de aquisição mínimo é facilmente calculado. Se o motor estiver saudável, as componentes ortogonais apresentarão certas médias dos valores RMS dentro desta janela e esses valores serão tomados como base para classificar o estado do motor. Se o motor estiver sob falha, essas médias irão aumentar ou diminuir, dependendo da componente ortogonal em questão.

Na Figura 47(a) mostra-se as oscilações de $\|v_a^p(t)\|$ do motor simulado com carga nominal constante e 4bq. Já na Figura 47(b), mostra-se as oscilações quando o motor está com 25% do torque nominal e 4bq.

O intuito deste trabalho é propor uma metodologia de diagnóstico de quebras de barras que seja independente do carregamento do eixo rotativo do MIT. Como pode ser visto na Figura 47, para diferentes torques, os valores RMS das componentes ortogonais se modificam, já que o valor da corrente de estator também é alterado. Pode-se ver nessa figura que para o motor operando em carga nominal, o valor RMS médio da componente ortogonal é de aproximadamente 168 V, enquanto esta grandeza é próxima a 66 V para a situação na qual o motor opera com 25% do carregamento. É importante salientar ainda, que a janela de aquisição deve ser ajustada para conter, no mínimo, um número inteiro de ciclos de oscilação das variáveis. Consequentemente, para que um sistema de diagnóstico de quebras de barras de rotores, que utilize os valores RMS médios, seja independente do carregamento no eixo rotativo do MIT, uma normalização dos valores de corrente de estator pelos seus valores máximos na janela de aquisição deve ser realizada antes da aplicação da DCO.

Figura 47: Oscilação do valor eficaz da componente ortogonal $v_a^p(t)$ em diferentes torques

Fonte: elaborado pela autora.

De forma a se obter índices que tenham monotonicidade e baixa variabilidade com a severidade da falha e tendo-se como motivação a relação entre as componentes ortogonais com o consumo de potência do sistema e os trabalhos realizados por Drif e Cardoso (2009), Bossio et al. (2009b), Drif e Cardoso (2012), Drif e Cardoso (2014), verificou-se que um índice de severidade pode ser criado a partir dos valores eficazes das componentes ortogonais. No trabalho de Bossio et al. (2009b), mostra-se que as potências instantâneas variam caso ocorra um fenômeno de barras quebradas. No caso de motores saudáveis, essas grandezas são constantes, como já discutido no Capítulo 2. Os autores mostram, por meio da FFT das potências instantâneas que a relação entre o valor máximo e o valor médio das oscilações, tanto da potência ativa quanto da reativa, é aproximadamente proporcional ao número de barras quebradas no rotor.

Como as componentes ortogonais são relacionadas ao consumo de potência do sistema, verificou-se que o índice obtido pela relação entre o valor RMS máximo das componentes ortogonais dividido pelo seu valor médio dentro de uma janela de aquisição, se mantém aproximadamente constante para um mesmo número de barras quebradas, e assim, é monotônico com a severidade da falha.

Como exemplo, toma-se a componente $i_A^p(t)$, ainda não projetada no plano das tensões de linha. Recordando-se dos capítulos anteriores, essa é calculada por (190), que depende do produto interno entre $i_A(t)$ e $v_A(t)$, dados por (1) e (4) e que são novamente relembrados em (191) e (192), cujo cálculo é definido no período T da frequência de acionamento do motor.

$$i_A^p(t) = \langle i_A(t), v_A(t) \rangle \frac{v_A(t)}{\|v_A(t)\|^2} \quad (190)$$

$$v_A(t) = \sqrt{2}V \cos(\omega t) \quad (191)$$

$$i_A(t) = \sqrt{2}I \cos(\omega t - \varphi) + \sqrt{2} \sum_{k=1}^{\infty} [I_{b1} \cos((\omega - k\omega_b)t - \varphi_{b1}) + I_{br} \cos((\omega + k\omega_b)t - \varphi_{b2})] \quad (192)$$

Ainda, considera-se apenas a influência da primeira banda lateral nas análises ($k = 1$). Com isso, chega-se à seguinte expressão da corrente:

$$i_A(t) = \sqrt{2}I \cos(\omega t - \varphi) + \sqrt{2}I_b \cos((\omega - \omega_b)t - \varphi_{bl}) + \sqrt{2}I_b \cos((\omega + \omega_b)t - \varphi_{b2}) \quad (193)$$

Partindo-se de (193) para calcular $\langle i_A(t), v_A(t) \rangle$, tem-se que o resultado é composto de uma parcela referente ao motor saudável e outra parcela refere-se à falha ocorrida:

$$\langle i_A, v_A \rangle = \frac{1}{T} \int_{t-T}^t i_A(t) v_A(t) d\tau = \langle i_A(t), v_A(t) \rangle_s + \langle i_A(t), v_A(t) \rangle_f \quad (194)$$

A parcela $\langle i_A(t), v_A(t) \rangle_s$ é a potência ativa, como se vê em (195). Percebe-se que este termo é invariante no tempo, mostrando que a componente $i_A^p(t)$ é constante quando o motor não apresenta quebra de barras.

$$\langle i_A(t), v_A(t) \rangle_s = \frac{1}{T} \int_{t-T}^t \sqrt{2}I \cos(\omega t - \varphi) \sqrt{2}V \cos(\omega t) \tau = VI \cos(\varphi) \quad (195)$$

Quando o motor é saudável a projeção $i_a^p(t)$ de $i_A^p(t)$ no plano das tensões de linha continuará com valor RMS constante, sem oscilações. Quando a falha ocorre, essas projeções possuirão uma razão, não mais unitária, entre o valor RMS máximo e RMS médio. Esse índice, que neste trabalho denominou-se R , é dado, como exemplo, em (196) para uma componente ortogonal da fase A e se mostra interessante também pelo fato de ser já normalizado em relação ao torque de carga. Ou seja, todos os motores saudáveis em qualquer carregamento apresentam $R = 1$.

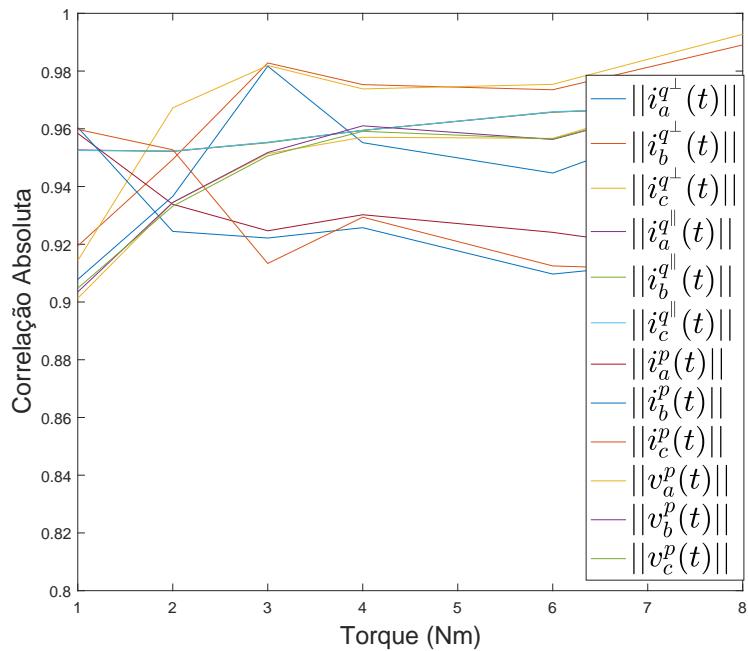
$$R \lVert i_a^p(t) \rVert = \frac{\max \lVert i_a^p(t) \rVert}{\text{mediana} \lVert i_a^p(t) \rVert} \quad (196)$$

Em casos práticos, deve-se utilizar a mediana como operador para o cálculo do índice R , já que, os carregamentos podem ser não múltiplos entre si e, desta forma, o número de oscilações dos valores RMS pode não ser inteiro dentro da janela de aquisição com a mudança do torque de carga.

Os desenvolvimentos matemáticos para outros termos das componentes ortogonais não serão aprofundados aqui, mas percebe-se que as componentes com índice q^{\parallel} em situações saudáveis são ligadas a potência reativa clássica. Já as componentes com índice q^{\perp} e d surgem quando o sistema deixa a situação saudável. No caso de uma falha, todas irão oscilar.

Uma análise de correlação entre esses índices ao evento da falha deve então ser levantada. A análise de correlação fornece um número que resume o grau de relacionamento linear entre variáveis. Na Figura 48, a correlação absoluta da relação R de algumas componentes ortogonais em relação ao estado do motor simulado (saudável ou faltoso com 1bq, 2bq e 4bq), em vários carregamentos, é traçada para uma janela de aquisição de 3 s. A janela de 3 s é suficiente para contemplar ao menos um número inteiro de oscilações na situação de menor torque (1 Nm). Pode-se observar que esses índices são robustos aos valores de torque de carga, mantendo boa correlação com o estado do motor.

Figura 48: Correlação entre os índices R de algumas componentes ortogonais em uma janela de 3 s como função do carregamento.



Fonte: elaborado pela autora.

Já na Figura 49, a correlação absoluta dos valores RMS medianos de algumas componentes ortogonais em relação ao estado do motor simulado (saudável ou faltoso com 1bq, 2bq e 4bq), em vários torques, é traçada para uma janela de aquisição de 3 s. Neste caso, os sinais das correntes estatóricas do motor simulado foram divididas pelos seus valores máximos, de forma a criar-se um índice normalizado em relação ao torque.

7.1.3 Distinção entre barras quebradas e cargas oscilantes

Uma grande preocupação que tange os diagnósticos de barras quebradas é sobre algumas condições de carga que podem causar efeitos parecidos com aqueles de barras quebradas nas grandezas elétricas do motor, ou seja, modulações na corrente de estator na frequência f_b , causando uma ambiguidade no monitoramento da falha. As estratégias

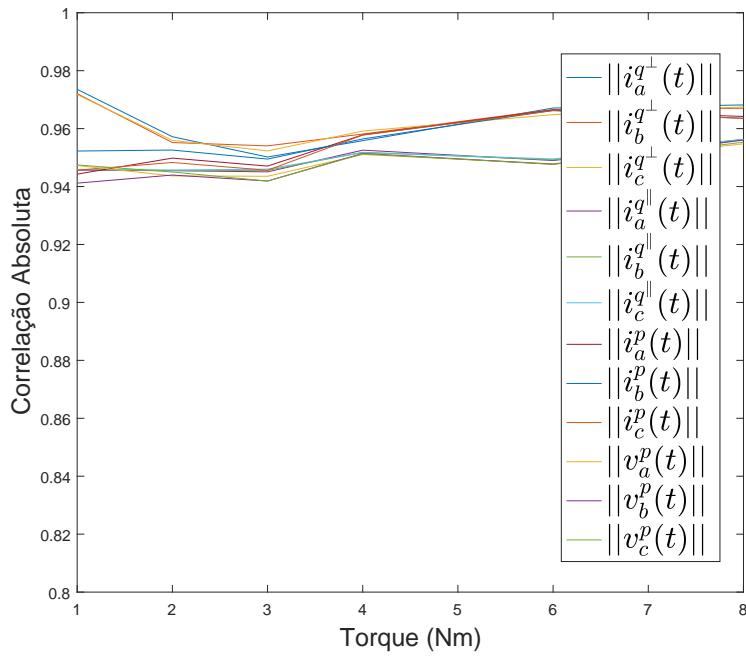


Figura 49: Correlação entre os valores RMS medianos das componentes ortogonais em uma janela de 1 s como função do carregamento.

gias de diagnóstico são usualmente baseadas na suposição de que os motores possuem carregamentos constantes, porém, condições anormais nas cargas ou cargas variantes no tempo podem impactar os índices característicos de falha (DRIF; CARDOSO, 2012). Como já discutido no Capítulo 2, algumas cargas como compressores alternativos e condições de defeito na transmissão podem inserir anormalidades no torque que causam as mesmas bandas laterais no espectro de motores com barras quebradas. O torque de uma carga oscilante ou de uma condição de falha na transmissão pode ser modelado da seguinte forma:

$$T_c = T_o + T_{osc} \cos(2\pi f_o) \quad (197)$$

onde T_o é o torque médio e T_{osc} é a amplitude do torque oscilante de frequência f_o .

Assim, se a frequência de oscilação da carga f_o for próxima à f_b , seus efeitos serão próximos dos efeitos de barras quebradas, pois uma oscilação no torque ocorrerá e, consequentemente, na velocidade, causando também bandas laterais na corrente de estator. Sistemas que observam apenas a amplitude dessas bandas laterais por meio de métodos baseados na análise da frequência não conseguem distinguir esse tipo de defeito (DRIF; CARDOSO, 2012). O diagnóstico diferencial de defeitos é um tema abrangente e deverá ser investigado em profundidade por trabalhos futuros. Porém, é de extrema importância já evidenciar se as componentes ortogonais conseguem diferenciar esses tipos de modulação da corrente. A fim de se analisar o comportamento das componentes ortogonais frente a uma carga oscilante, simulou-se o motor sadio na presença de um torque T_o nominal e T_{osc}

com 5% do valor nominal em uma frequência f_o próxima à frequência fb , como proposto em (DRIF; CARDOSO, 2012). Os resultados da simulação aparecem na Figura 50.

Pode-se observar nesta figura que os valores RMS das componentes ortogonais se mostram diferentes da condição de barra quebrada. É possível perceber que os valores $\|v_x^p(t)\|$ e $\|v_x^q(t)\|$, com $x = a, b, c$, possuem uma oscilação sem mudanças em seu valor médio e uma característica mais linear, diferentemente do que ocorre com barras quebradas. Além disso, na situação de barras quebradas, as oscilações possuem uma característica quadrática e a elevação ou diminuição dos valores médios prevalece. Outra mudança bastante notável ocorre nos sinais $\|i_x^p(t)\|$ e $\|i_x^q(t)\|$. Percebe-se que, para barras quebradas, a componente $\|i_x^p(t)\|$ possui uma pequena oscilação. Já para cargas oscilantes, o *ripple* dessa variável é muito grande. A componente $\|i_x^q(t)\|$ se comporta de forma contrária, ou seja, seus valores máximos são menores para cargas oscilantes e maiores para barras quebradas, sendo que nesta última situação há diminuição do valor médio. A quebra de barra não faz oscilar com veemência os componentes ativos da corrente. Além disso, pode-se perceber que as componentes $\|v_x^\perp(t)\|$ e $\|i_x^{q\perp}(t)\|$ são muito mais proeminentes no caso de barras quebradas, demonstrando, novamente, a característica reativa do defeito. Por fim, deve-se enfatizar que todas as componentes possuem formas de onda não lineares no caso das barras quebradas.

Como já explicitado, não será analisada em profundidade a utilização das componentes ortogonais em diagnóstico de cargas oscilantes, porém, uma análise prévia mostra que a ferramenta consegue diferenciar os dois casos, já que esta está intimamente ligada à natureza dos fenômenos e que índices poderiam ser criados de forma a diferenciar cargas oscilantes de barras quebradas.

7.2 Ensaios Experimentais

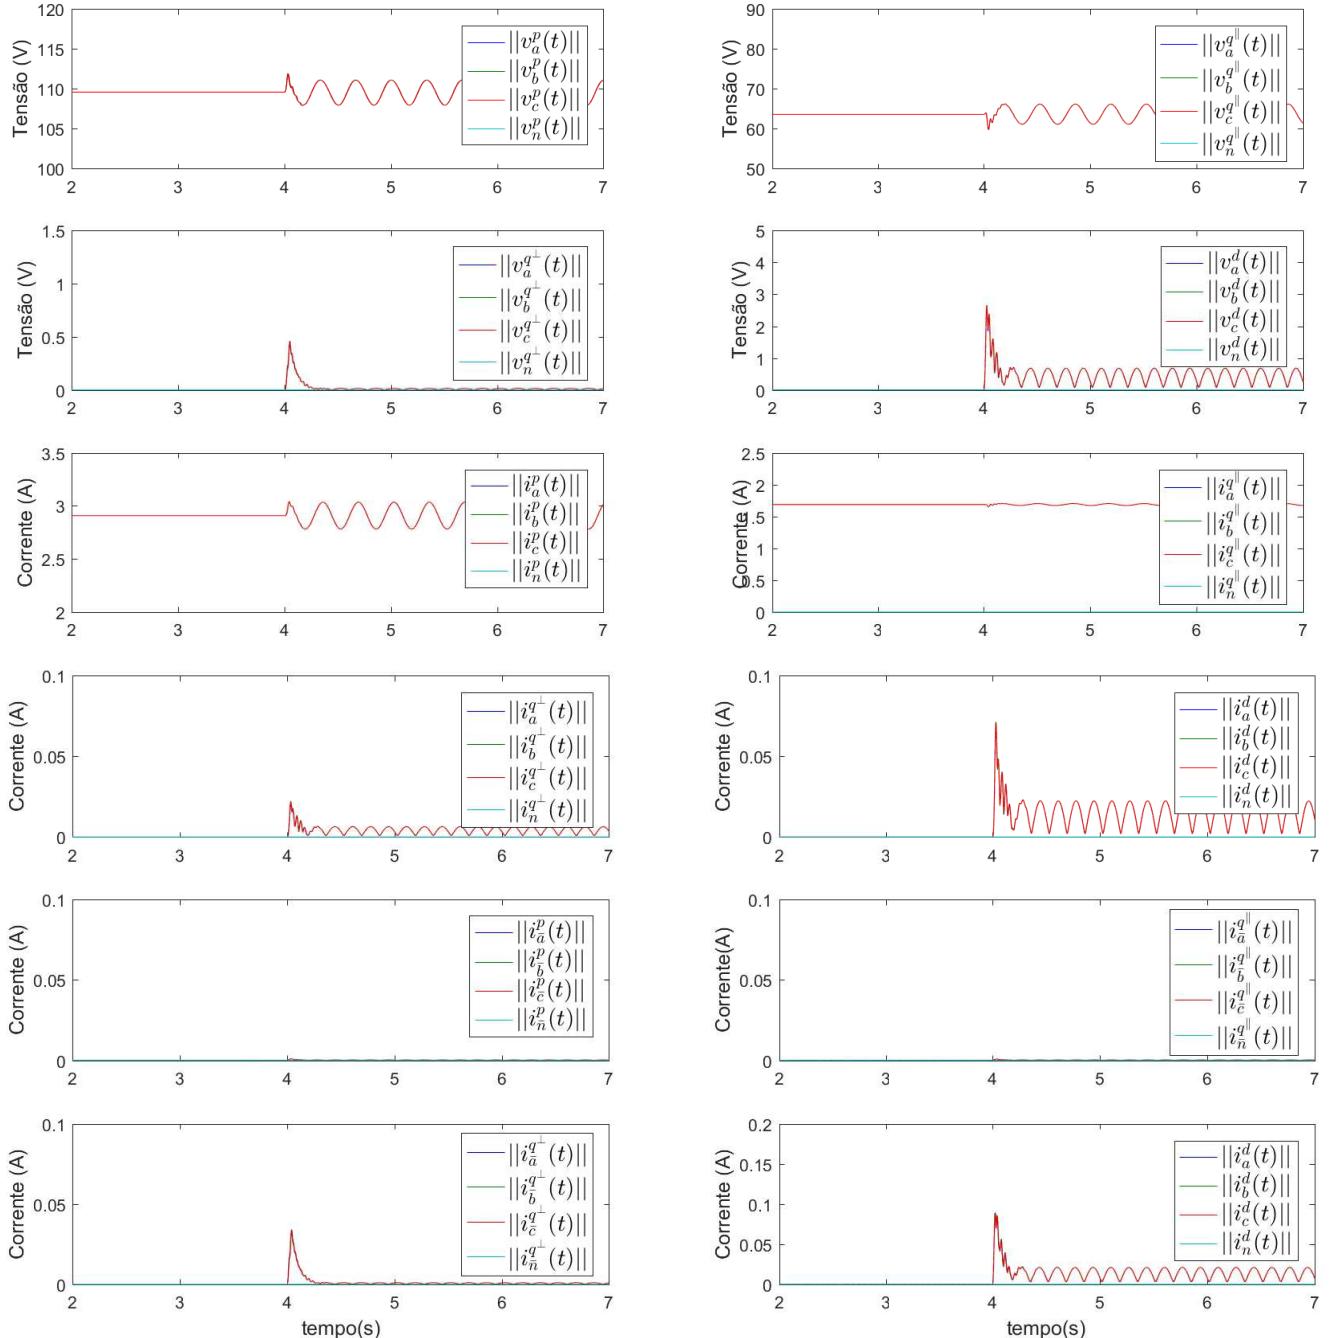
7.2.1 Barras Quebradas no Rotor

Ensaios experimentais foram realizados para aquisição de sinais elétricos de diversos MITs sadios ou com distintas barras quebradas e sob diversas condições de carga. O acionamento foi realizado com partida direta pela rede e com inversor de frequência. Os motores ensaiados são de 1,0 cv, 220 V/380 V, 4 polos, 60 Hz, 4,1 Nm de torque nominal, advindos da bancada experimental descrita no Capítulo 5 e por meio da metodologia de aquisição de sinais descrita no Capítulo 6.

7.2.2 Partida Direta

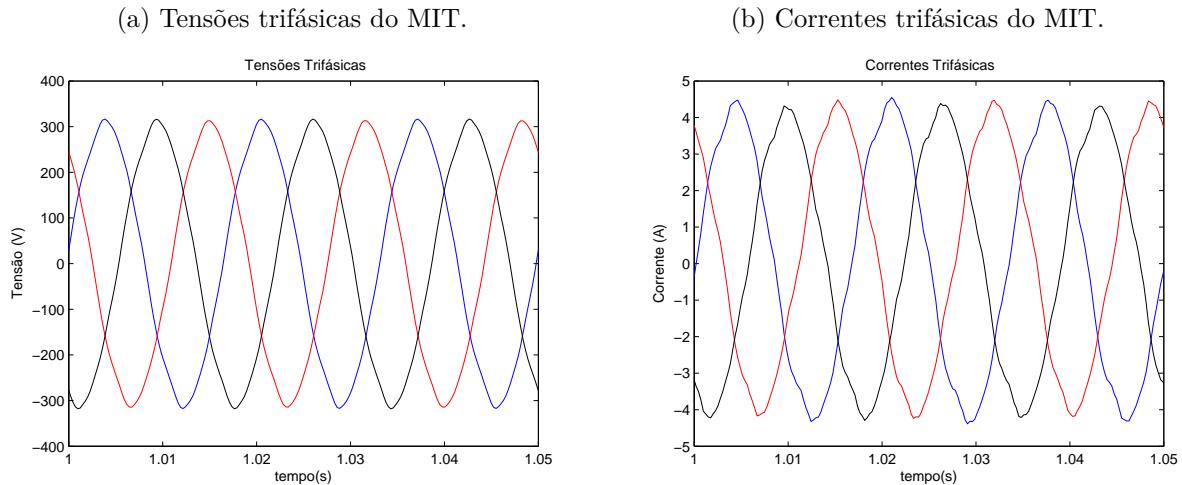
A Figura 51 ilustra as variáveis monitoradas de um ensaio de motor com rotor normal em regime permanente com carregamento de 4,0 Nm.

Figura 50: Valores RMS das componentes ortogonais do motor de 2 hp, 60 Hz, 4 polos, 380 V, 3.6 A e 28 barras no rotor. Em $t = 4$ s uma carga oscilante é simulada.



Fonte: elaborado pela autora.

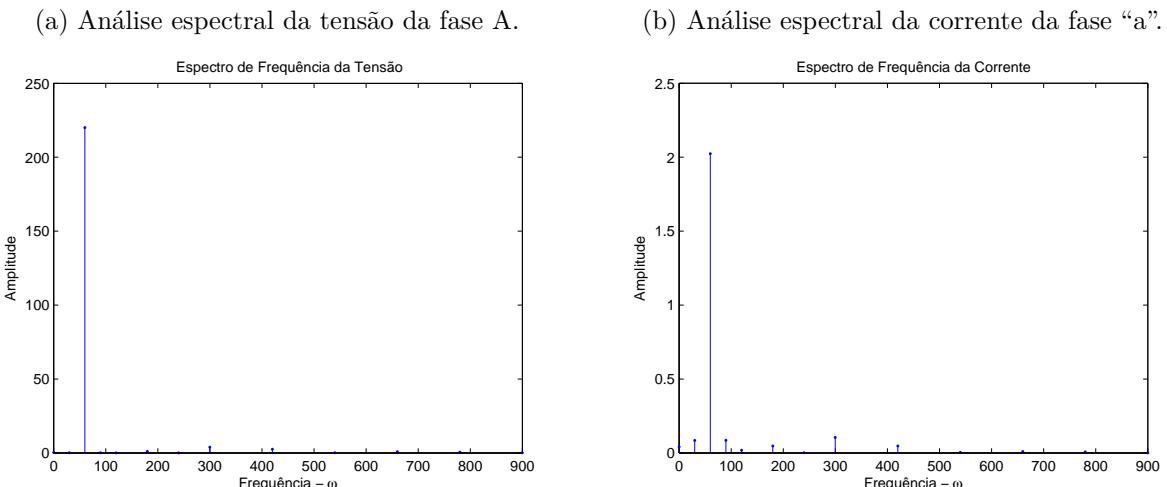
Figura 51: Tensões e correntes trifásicas do MIT normal sob carga de 4,0 Nm.



Fonte: elaborado pela autora.

Percebe-se que as tensões estão aproximadamente equilibradas e visualmente possuem baixas distorções. Em contrapartida, as correntes trifásicas apresentam uma pequena distorção. Já que esse motor é sadio, tal característica pode ser resultante das desigualdades entre os enrolamentos trifásicos e das irregularidades na distribuição do fluxo magnético nas ranhuras. A decomposição desses sinais nas séries de Fourier, apresentada na Figura 52, mostra que a frequência de 60 Hz é predominante, porém, nota-se também a presença das frequências de 30 Hz e 90 Hz, que não aparecem nas simulações. Segundo Choi et al. (2011) estas componentes de frequência são resultantes dos efeitos de vibração do motor e diminuem conforme o aumento do carregamento, já que a carga é um filtro mecânico.

Figura 52: Análise espectral da tensão e corrente da fase A do MIT normal sob carga de 4 Nm.

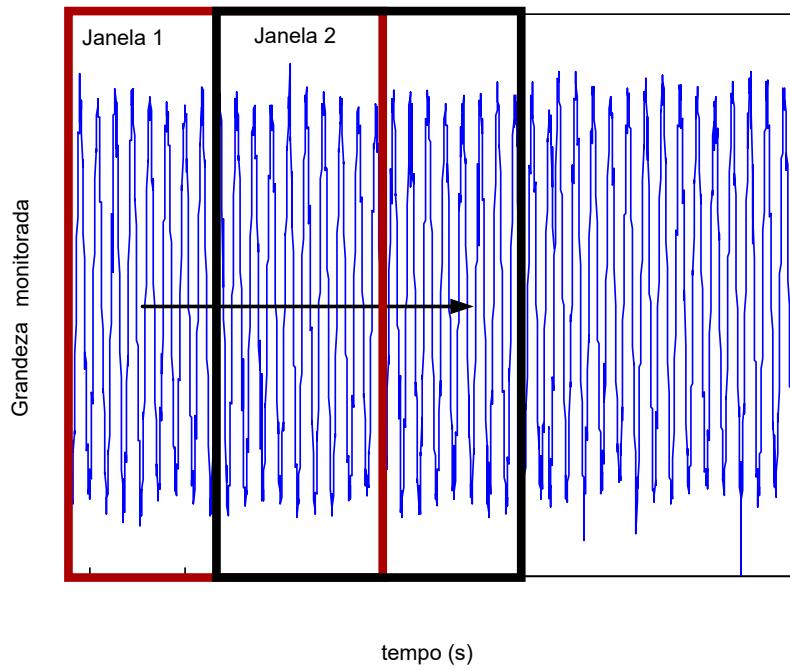


Fonte: elaborado pela autora.

Para o menor carregamento, na situação em vazio ($0,5 \text{ Nm}$), os motores possuem escorregamento de aproximadamente 0,6%. Desta forma, escolheu-se o tempo de 2,8 s para a janela de aquisição, o que contempla no mínimo dois ciclos de oscilações dos valores RMS das componentes ortogonais na situação de menor torque. Esta janela poderia ser de 1,4 s, pois contemplaria 1 ciclo inteiro de oscilações, porém, para que o cálculo da mediana possa ser mais acurado, optou-se por aumentar a janela.

O total de amostras do banco de dados em parida direta é de 71 casos (combinações ‘motor+carga’), dos quais 45 são amostras saudáveis e 26 são amostras faltosas. Para contornar o problema da baixa disponibilidade de dados, adotou-se a estratégia de aquisição por janela deslizante. Como a metodologia requer 2,8 s de aquisição dos sinais elétricos e a base de dados contém em média 4 s de sinal, realizou-se o deslocamento da janela de aquisição em aproximadamente 0,3 s até atingir-se o final dos sinais do banco de dados, conforme ilustrado na Figura 53. Embora uma parte dos dados seja redundante, outra parte dos dados possuirão informações distintas. No total, foram obtidas 5 janelas deslizantes.

Figura 53: Janela deslizante



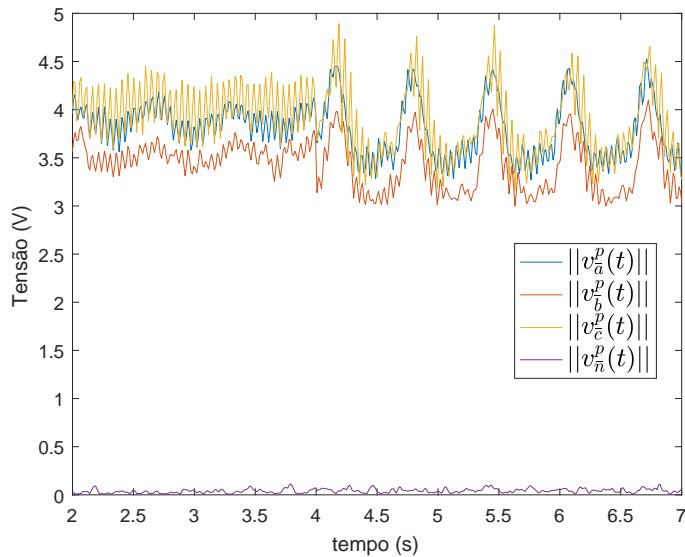
Fonte: elaborado pela autora.

Aplicou-se a DCO nos sinais de tensão e corrente de cada combinação ‘motor+carga’ para as 5 janelas deslizantes, resultando, então, em 355 combinações ‘motor+carga’, sendo dessas, 225 saudáveis e 130 com falha.

Diferentemente das simulações computacionais, as componentes de tensão que são ortogonais ao plano passaram a existir mesmo em motores saudáveis devido a ruídos e não linearidades nas tensões e no sistema de aquisição, como mostrado na Figura 54. Fica

evidente a característica não linear dessas componentes.

Figura 54: Valores RMS das componentes de tensão ortogonais ao plano das tensões de linha. Até 4 s estão os valores reais de um motor saudável com carregamento nominal. Depois de 4 s apresentam-se os dados reais de um motor com 4bq e carregamento nominal.



Fonte: elaborado pela autora.

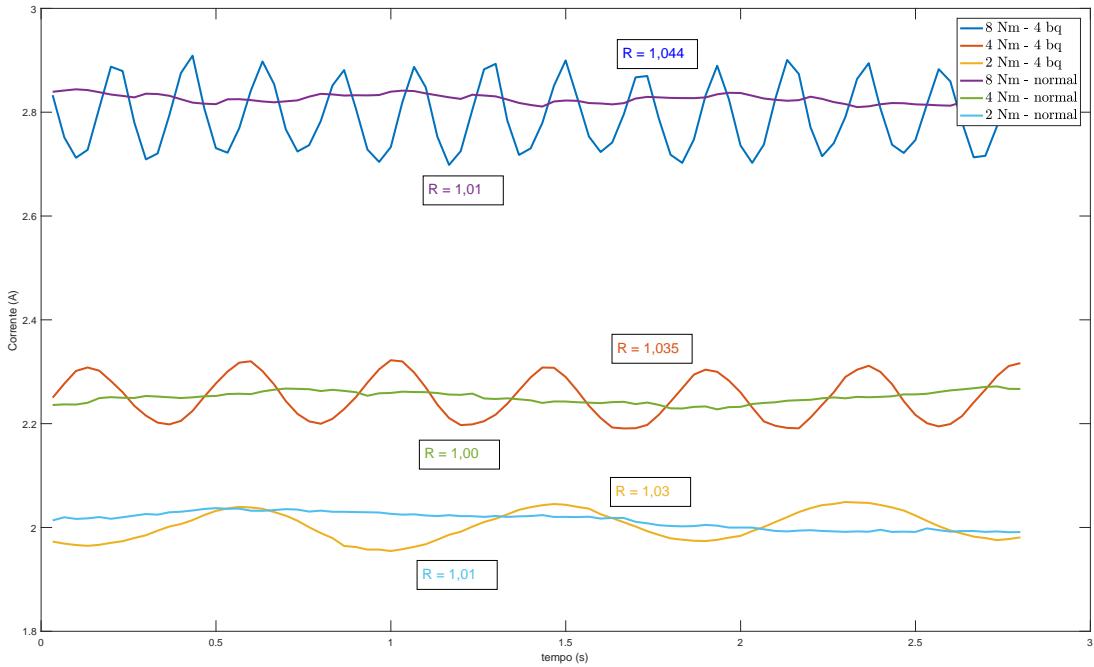
Optou-se por adotar os índices R de cada componente ortogonal na janela de 2,8 s como entrada para os sistemas de classificação, como evidenciado na Figura 56, na qual mostra-se os sinais RMS de motores com barras quebradas e saudáveis, assim como os respectivos valores da relação R . A decomposição em componentes ortogonais e o posterior cálculo do índice R resulta em um espaço de atributos de 64 dimensões, os quais foram normalizados entre 0 e 1.

Além da motivação trazida pela bibliografia correlata e pelos resultados das simulações computacionais, com intuito de motivar e fundamentar a investigação da classificação de motores normais e com defeito, em sinais reais, realizou-se uma análise estatística das amostras resultantes. Uma ANOVA assimétrica e não paramétrica do tipo Kruskal-Wallis foi aplicada com o objetivo de verificar se todos as amostras ensaiadas pertencem a uma mesma classe.

O valor resultante da análise estatística indica a probabilidade P de a hipótese nula ocorrer com relação aos atributos analisados. A hipótese nula consiste em considerar que os elementos analisados pertencem a uma mesma população. Um pequeno valor da estatística chi-quadrado indica que pelo menos uma média dos atributos da população analisada é diferente das outras médias e, deste modo, as amostras são de diferentes populações.

O resultado da análise da Tabela 2 lança dúvidas sobre a hipótese nula: *todas as amostras são extraídas de uma mesma população*. Ou seja, não se pode assumir que o grupo

Figura 55: Sinais RMS de motores com 4bq e motores saudáveis e seus respectivos valores R para a componente ortogonal $i_a^p(t)$.



Fonte: elaborado pela autora.

dos motores normais é igual ao grupo dos motores com defeito a partir do índice R das componentes ortogonais. Isso encoraja a investigação sobre a DCO ser uma competente ferramenta para extrair essas características. A tabela seguintes mostra o resultado da análise estatística realizada no caso de motores com partida direta.

Tabela 2: Teste estatístico. ANOVA para o banco de dados com o índice R dos valores eficazes das componentes ortogonais em partida direta.

SS	df	Ms (SS/df)	F	P
$4,60 \cdot 10^{10}$	1	$4,60 \cdot 10^{10}$	1070,86	$7,10 \cdot 10^{-235}$

Nas tabelas de ANOVA ainda é possível observar a alta variabilidade das amostras, onde:

- * SS: Soma dos erros quadrados;
- * df: Graus de liberdade;
- * MS: Erro quadrático médio (SS/df);
- * F: Estatística Chi-quadrado e

- ★ P: Probabilidade da ocorrência da hipótese nula.

De forma a diminuir o espaço de entrada de atributos para que classificadores de padrões possam ser utilizados com bom desempenho, aplicou-se o algoritmo de redução de dimensionalidade a partir de correlação CFS. Utilizou-se o software livre WEKA (HALL et al., 2009). O software WEKA possui uma coleção de algoritmos de aprendizagem de máquinas para tarefas de mineração de dados.

O algoritmo retornou o conjunto de atributos mais relevantes com a classe faltosa:

$$\begin{aligned} & \| i_a^p(t) \|, \| i_b^p(t) \|, \| i_c^p(t) \|, \| v_{\bar{a}}^{q\parallel}(t) \|, \| i_{\bar{c}}^d(t) \|, \| i_{\bar{n}}^p(t) \|, \| v_a^p(t) \|, \dots \\ & \dots \| i_{\bar{b}}^{q\parallel}(t) \|, \| v_n^p(t) \|, \| v_{\bar{c}}^d(t) \| \end{aligned}$$

Alguns atributos referenciam as 3 fases, enquanto outros não. Esse fato é, provavelmente, oriundo de certo desequilíbrio de tensão ou diferenças geométricas do motor. A pesar, das tensões estarem visualmente equilibradas, as componentes ortogonais são bastante sensíveis devido aos cálculos algébricos de seu algoritmo. Desta forma, repetiu-se o algoritmo CFS, porém, à cada novo atributo escolhido, incluiu-se as fases faltantes no conjunto. Assim, o conjunto reduzido de atributos resultou em:

$$\begin{aligned} & \| i_a^p(t) \|, \| i_b^p(t) \|, \| i_c^p(t) \|, \| v_{\bar{a}}^{q\parallel}(t) \|, \| v_{\bar{b}}^{q\parallel}(t) \|, \| v_{\bar{c}}^{q\parallel}(t) \|, \dots \\ & \dots \| i_{\bar{n}}^p(t) \|, \| v_a^p(t) \|, \| v_b^p(t) \|, \| v_c^p(t) \| \end{aligned}$$

O desempenho dos sistemas de classificação foi obtido mediante validação cruzada estratificada com 10 partições e repetida 10 vezes para diferentes combinações de partições. Como já discutido, a validação estratificada assegura que cada partição mantenha a proporção correta de dados de cada classe. Além disso, repetições em diferentes combinações de dados melhoraram os resultados sobre avaliações repetidas, por reduzir a variância da avaliação.

Os classificadores *SVM* utilizam kernel linear ou Gaussiano e seus parâmetros γ e C foram escolhidos por meio de validação cruzada simples para diversas topologias. O comportamento do modelo *SVM* com kernel Gaussiano é bastante sensível ao parâmetro γ . Se o parâmetro γ for muito elevado, o raio da área de influencia de um *SV* incluirá apenas ele mesmo e nenhuma quantidade de parâmetro C de regularização prevenirá o *overfitting*. Desta forma, a validação cruzada foi escolhida para testar as topologias e evitar o *overfitting*. Devido ao desbalanceamento do número de dados de cada classe, o parâmetro C foi utilizado com pesos diferentes para classificação assimétrica. Os pesos foram 225 para a classe normal e 130 para a classe com falhas, os quais refletem a proporção dos dados obtidos.

Os classificadores *PMC* tiveram o número de camadas escondida (*CE*), o número de neurônios nas camadas escondidas (*NCE*), a taxa de aprendizado (*T*) e a taxa de *momentum* (*M*) também escolhidos por validação cruzada simples.

Na Tabela 3 observam-se os resultados de classificação por *SVM* e *PMC* para os motores com partida direta em 60 Hz. Motores normais e com 1bq, 2bq, 2x2bq e 4bq foram analisados.

Tabela 3: Acurácia da classificação de motores normais e defeituosos e de severidade (1bq, 2bq, 2x2bq, 4bq) da falha para motores em partida direta utilizando-se o índice *R* e os sinais referentes à todas as fases.

Tipo	Classificador	Nº de	Acurácia (%)	Acurácia (%)
		entradas	média (desv. padrão)	média (desv. padrão)*
Falha	<i>SVM</i> ¹	64	100 (0,0)%	-
Falha	<i>PMC</i> ¹	64	100(0,0)%	-
Falha	<i>SVM</i> ²	10	100 (0,0)%	-
Falha	<i>PMC</i> ²	10	100 (0,0)%	-
Severidade	<i>SVM</i> ³	64	100 (0,0)%	100 (0,0)%
Severidade	<i>PMC</i> ³	64	100 (0,0)%	100 (0,0)%
Severidade	<i>SVM</i> ⁴	10	99,46 (1,97)%	-
Severidade	<i>PMC</i> ⁴	10	98,15 (3,96)%	-
Severidade	<i>SVM</i> ⁵	10	100 (0,0)%	99,85(1,08)%
Severidade	<i>PMC</i> ⁵	10	99,08 (2,74)%	98,00 (4,71)%

* Considerando-se 2x2bq=4bq

*SVM*¹ = *SVM*² = *SVM*³ = *SVM*⁴ ($C = 1,0$ kernel linear). *SVM*⁵ ($C = 50,0 \gamma = 1,0$ kernel Gaussiano). *PMC*¹ = *PMC*² = *PMC*³ = *PMC*⁴ ($T = 0,3 M=0,2 CE=0 NCE=0$). *PMC*⁵ ($T = 1 M=0,5 CE=0 NCE=5$).

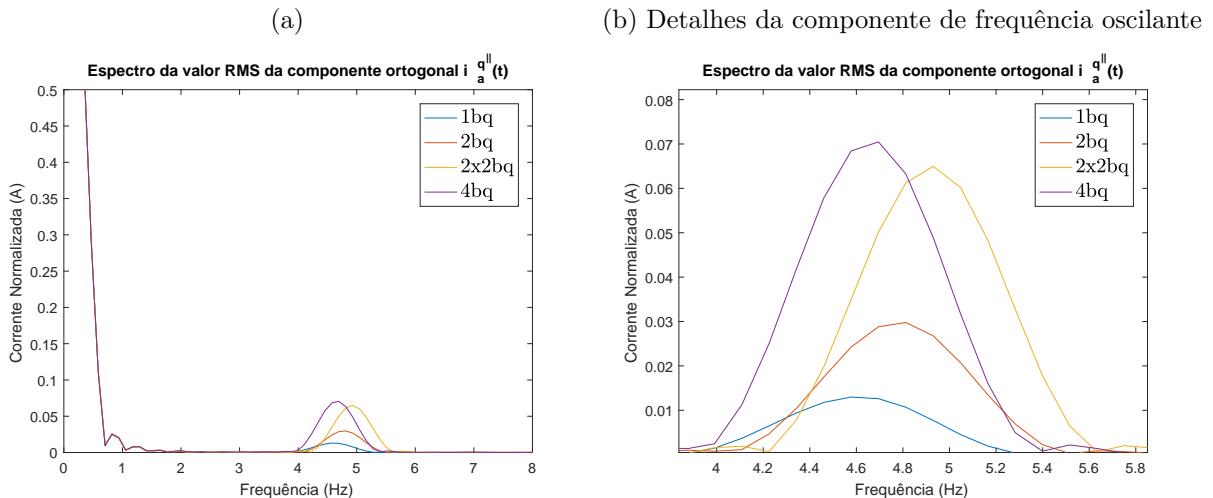
Pode-se observar que classificadores simples são capazes de extrair classificações de alta acurácia. Esse fato indica que o problema de classificação é perto de ser totalmente separável dentro da dimensionalidade dos atributos.

O sistema de identificação monitora também a severidade da falha, ou seja, identifica o número de barras quebradas. O sistema de severidade pode ser considerado um subsistema do sistema de classificação e os dados classificados como defeituosos devem ser enviados em cascata para esse subsistema. Para os propósitos de validação cruzada, o diagnóstico de severidade foi realizado utilizando-se todas as amostras com falhas do banco de dados original.

Os resultados da quarta coluna da Tabela 3 são referentes às classificações nas quais

as falhas de 4bq e 2x2bq estão sendo consideradas distintas, apesar das barras quebradas estarem sob polos de mesmo nome. Como já discutido no Capítulo 2, barras não adjacentes separadas de 180° elétricos possuem praticamente o mesmo efeito nas bandas laterais da corrente de estator, como mostrado em (SIZOV et al., 2009). Porém, está evidenciado na Figura 56 que as componentes ortogonais conseguem refletir a diferença entre ambos os fenômenos, já que a amplitude da oscilação do valor RMS das componentes ortogonais é diferente em cada caso. Nota-se também que há um pequeno desvio no valor da frequência de oscilação. Utilizando-se apenas uma classe para ambos os fenômenos, ou seja, apenas a classe de 4bq obtém-se uma performance pior dos classificadores, como evidenciado na última coluna da Tabela 3. Este fato mostra que os índices R advindos da DCO conseguem melhor distinguir efeitos diferentes do que se comparado à técnicas baseadas na assinatura espectral da corrente estatórica.

Figura 56: Espectro do valor RMS da componente ortogonal $i_a^{q\parallel}(t)$ para motores com 1bq, 2bq, 2x2bq e 4bq com carga nominal.



Fonte: elaborado pela autora.

Pode-se notar que a seleção de atributos é bastante interessante, pois, elimina-se atributos redundantes e irrelevantes. Para a classificação dos motores em falha ou saudáveis, a diminuição do espaço de entradas não interferiu no resultado dos classificadores, que obtém 100% de acurácia com kernel linear. Já para a análise de severidade, a acurácia de um *SVM* linear é muito próxima de 100% para um menor número de atributos e chega a uma classificação com 100 % de acurácia quando maiores restrições de margem são utilizadas em conjunto com um kernel Gaussiano, como é o caso do *SVM*⁵.

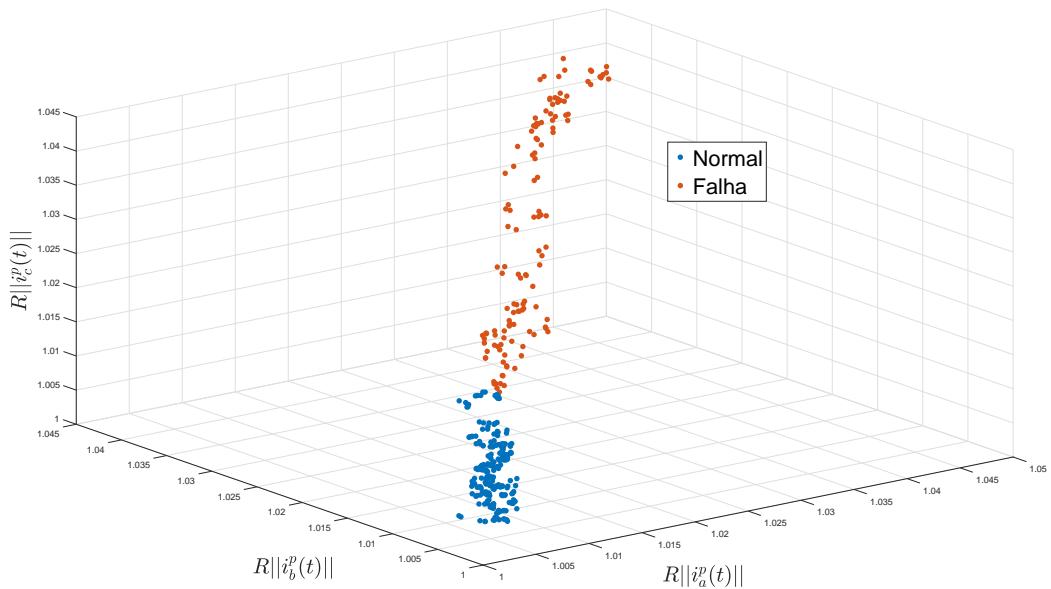
A rede PMC sem camada oculta teve maior queda em sua acurácia com a diminuição de dimensionalidade. De fato, neste espaço de menor dimensionalidade, para classificar a severidade da falha, a função de decisão dos classificadores, deixa de ser linear e dessa forma, uma camada oculta é necessária, mostrando-se que o problema de classificação se

aproxima de uma região convexa. O resultado de uma rede PMC com 5 neurônios na camada escondida se aproxima de 100%. Deve-se enfatizar que as redes neurais possuem mais parâmetros ajustáveis e se torna mais difícil a busca pela topologia ideal.

O classificador de severidade *PMC*⁵ apenas classificou erroneamente 1 amostra com falha de 2x2bq como possuidora de falha de 2bq em situação de vazio (0,5 Nm), dentre as 355 amostras.

Na Figura 57 estão representadas as amostras de motores faltosos e normais com relação aos três primeiros atributos escolhidos pelo CFS. Nota-se que o problema torna-se praticamente separável com apenas esses atributos. De fato, o classificador *SVM*² obtém performance de 98,98(1,42) com apenas esses 3 atributos de entrada.

Figura 57: Amostras de motores normais e com falha com relação aos três primeiros atributos escolhidos pelo CFS utilizando-se o índice R e os sinais referentes a todas as fases.



Fonte: elaborado pela autora.

Uma redução de dimensionalidade natural seria utilizar dados de apenas uma fase do motor. Essa prática reduziria o número de sensores de corrente, reduzindo-se o custo da solução. Na Tabela 4 encontra-se os resultados quando os 16 valores R referentes à fase A são utilizadas como entrada para os sistemas de classificação. Pode-se notar o excelente desempenho de topologias simples de classificadores.

Aplicou-se novamente o algoritmo de seleção de atributos, porém agora, no conjunto de índices da fase A. O algoritmo retornou apenas 5 atributos mais importantes, que são

listados a seguir:

$$\| i_a^p(t) \|, \| i_a^d(t) \|, \| v_a^p(t) \|, \| v_a^d(t) \|, \| v_n^p(t) \|$$

Na tabela Tabela 4 mostra-se os resultados de classificação com os atributos selecionados.

Tabela 4: Acurácia da classificação de motores normais e defeituosos e de severidade da falha (1bq, 2bq, 2x2bq, 4bq) para o banco de dados de motores em partida direta utilizando-se o índice R e os sinais referentes à fase A.

Classificador	Nº de entradas	Acurácia (%)	
		desv. padrão	
Falha	SVM^1	16	100 (0,0)%
Falha	PMC^1	16	100(0,0)%
Falha	SVM^2	5	100 (0,0)%
Falha	PMC^2	5	100 (0,0)%
Severidade	SVM^3	16	100 (0,0) %
Severidade	PMC^3	16	99,15 (2,42)%
Severidade	SVM^4	5	100,0 (0,0) %
Severidade	PMC^4	5	98,08 (3,52)%

$SVM^1 = SVM^2$ ($C = 50,0 \gamma = 0,75$ Kernel Gaussiano). $SVM^3 = SVM^4$ ($C = 50,0 \gamma = 4$ Kernel Gaussiano). $PMC^1 = PMC^2$ ($T = 0,1 M=0,1 CE=0 NCE=4$). PMC^4 ($T = 1 M=0,1 CE=0 NCE=10$).

Para uma investigação mais profunda sobre a dificuldade de diagnóstico em baixos carregamentos, as amostras foram separadas em 2 grupos de dados menores. O primeiro contém motores em vazio (0,5 Nm) até 40% do torque nominal. O segundo banco de dados contém instâncias de 75% a 100% do torque nominal. Como mostrado nas Tabelas 5 e 6, as saídas da classificação não resultaram em uma perda efetiva de acurácia para motores em baixo torque. Esse resultado confirma que usando-se os próprios sinais no tempo do motor como bases para a decomposição, mesmo pequenos efeitos nos sinais elétricos são percebidos. Pode-se ainda perceber pelas Tabelas 4 e 6 que a diminuição no número de atributos contribui para a melhoria dos classificadores.

Como já evidenciado, o diagnóstico de motores com baixos carregamentos é difícil não apenas pelo espalhamento espectral mas também porque os efeitos na corrente de estator

Tabela 5: Acurácia da classificação de motores normais e defeituosos dividido em: 0 a 40% do torque nominal e 75% a 100% do torque nominal utilizando o índice R e os sinais referentes a todas as fases para motores em partida direta.

Classificador	N^o de Entradas	Acurácia (%) média (desv. padrão)
$SVM - < 40\%$	64	100,0 (0,0)%
$SVM - > 75\%$	64	100,0 (0,0)%
$SVM - < 40\%$	10	100,0 (0,0)%
$SVM - > 75\%$	10	100,0 (0,0)%

$SVM (C = 1.0$ Kernel linear)

Tabela 6: Acurácia da classificação de motores normais e defeituosos dividido em: 0 a 40% do torque nominal e 75% a 100% do torque nominal utilizando-se o índice R e os sinais referentes a fase A para motores em partida direta.

Classificador	N^o de Entradas	Acurácia (%) média (desv. padrão)
$SVM - < 40\%$	16	99,34 (2,13)%
$SVM - > 75\%$	16	99,34 (2,11)%
$SVM - < 40\%$	5	100,0 (0,0)%
$SVM - > 75\%$	5	100,0 (0,0)%

$SVM (C = 100 \gamma = 0.1$ Kernel Gaussiano)

são muito pequenos. Os valores RMS das componentes ortogonais são modulados quando uma falha ocorre. A frequência e a amplitude dessa modulação dependem da carga, como em qualquer outra técnica de detecção via sinais elétricos, porém, com a DCO, o espalhamento não está presente e a detecção de barras quebradas ainda é possível mesmo em situações de baixo torque.

De forma a corroborar que os valores medianos das componentes ortogonais são também altamente correlacionados com o fenômeno da falha, verificou-se ainda o desempenho dos classificadores caso a mediana dos valores RMS das componentes ortogonais da fase A fosse adotada como entrada dos sistemas de classificação. Optou-se pela utilização dos *SVMs* dado a sua facilidade de implementação. Na Tabela 7 mostra-se os resultados de classificação com e sem a seleção de atributos. Os atributos selecionados para esse caso estão a seguir:

$$\| i_a^\perp(t) \|, \| v_a^p(t) \|, \| v_{\bar{a}}^\perp(t) \|, \| v_{\bar{a}}^d(t) \|, \| i_a^p(t) \|, \| i_a^d(t) \|$$

Tabela 7: Acurácia da classificação de motores normais e defeituosos e de severidade da falha (1bq, 2bq, 2x2bq, 4bq) para motores em partida direta utilizando-se os valores medianos e os sinais referentes à fase A.

Classificador	Entradas	Nº de	Acurácia (%)
		desv. padrão	média
Falha	<i>SVM</i> ¹	16	100,0 (0,0)%
Falha	<i>SVM</i> ²	6	100,0 (0,0)%
Severidade	<i>SVM</i> ³	6	100,0 (0,0) %
Severidade	<i>SVM</i> ⁴	6	100,0 (0,0) %

$$SVM^1 = SVM^2 = SVM^3 = SVM^4 \quad (C = 100 \gamma = 2 \text{ Kernel Gaussiano}).$$

Por meio desses resultados, pode-se concluir que inúmeros índices advindos dos valores RMS das componentes ortogonais mostram correlações robustas frente à condição de falha.

Como explicitado no Capítulo 1, pesquisas em detecção de falhas trazem classificadores de uma só classe como sistemas para tomada de decisão. A coleta de amostras de motores faltosos implica na quebra de equipamentos e ainda sabe-se não ser possível a obtenção de todas as situações de falha. Desta forma, aplicou-se uma *SVM* de uma só classe de forma a verificar se os índices criados a partir das componentes ortogonais são, de fato, bons índices para acusar as falhas. O classificador é treinado apenas com os motores saudáveis, e durante a classificação apenas reconhece motores saudáveis. Os motores com

falha são utilizados para testar o classificador e aqueles não reconhecidos são considerados novidades e devem ser avaliados como possuidores de falha.

Tabela 8: Acurácia da classificação de motores normais e defeituosos em partida direta utilizando-se *SVMs* de uma só classe com o índice R e os sinais referentes à fase A.

Classificador	Entradas	Nº de	Acurácia (%)
		Média (desv. padrão)	
Falha <i>SVM</i> ¹	16	96,79(2,39)%	
Falha <i>SVM</i> ²	5	98,59(2,24)%	

$SVM^1 = SVM^2 = (\nu = 0.001 \gamma = 0.008$ Kernel Gaussiano).

O resultado trazido pela Tabela 8 é promissor já que está dentro do novo paradigma da detenção de novidades, a qual facilita imensamente as aplicações práticas de diagnóstico de falhas. Com todos os resultados expostos pode-se afirmar que utilizando-se bons indicadores de falhas, ferramentas de diminuição de dimensionalidade e classificadores inteligentes pode-se obter sistemas de diagnósticos bastante acurados.

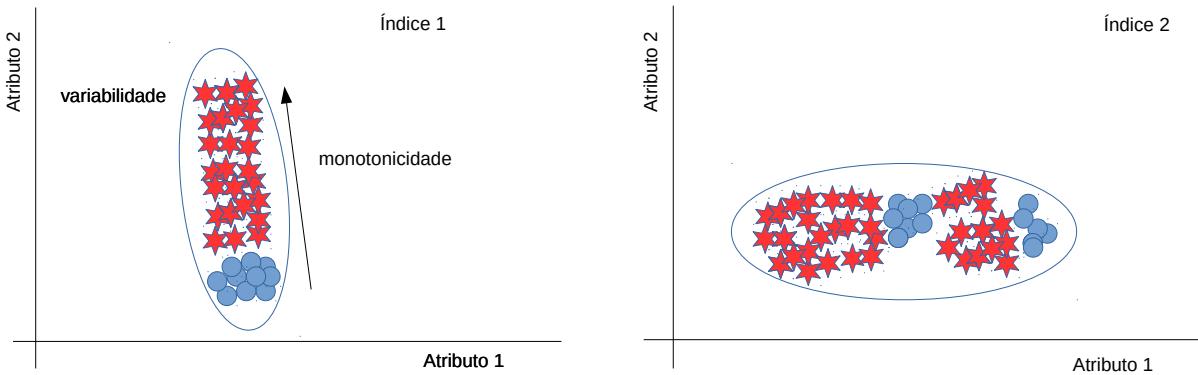
Tabela 9: Acurácia da classificação de motores normais e defeituosos em partida direta utilizando-se *SVMs* de uma só classe com os valores medianos e os sinais referentes à fase A.

Classificador	Entradas	Nº de	Acurácia (%)
		Média (desv. padrão)	
Falha <i>SVM</i> ¹	16	87,57(6,02)%	
Falha <i>SVM</i> ²	5	79,94(6,71)%	

$SVM^1 (\nu = 0.09, \gamma = 3,$ kernel Gaussiano) $SVM^2 (\nu = 0.09, \gamma = 8,$ kernel Gaussiano).

Nota-se pela Tabela 9 que o índice R dá melhores condições aos detectores de novidade para reconhecerem motores saudáveis e produzirem funções de decisão que englobe a classe saudável. Este resultado representa o fato do índice R possuir monotonicidade e baixa variabilidade frente ao fenômeno da falha. Para sistemas de classificação de uma só classe, essas características são de extrema importância. Na representação da Figura 58, mostra-se uma distinção entre índices com monotonicidade e sem monotonicidade. Considera-se ainda que a variabilidade é o indicativo de espalhamento do índice.

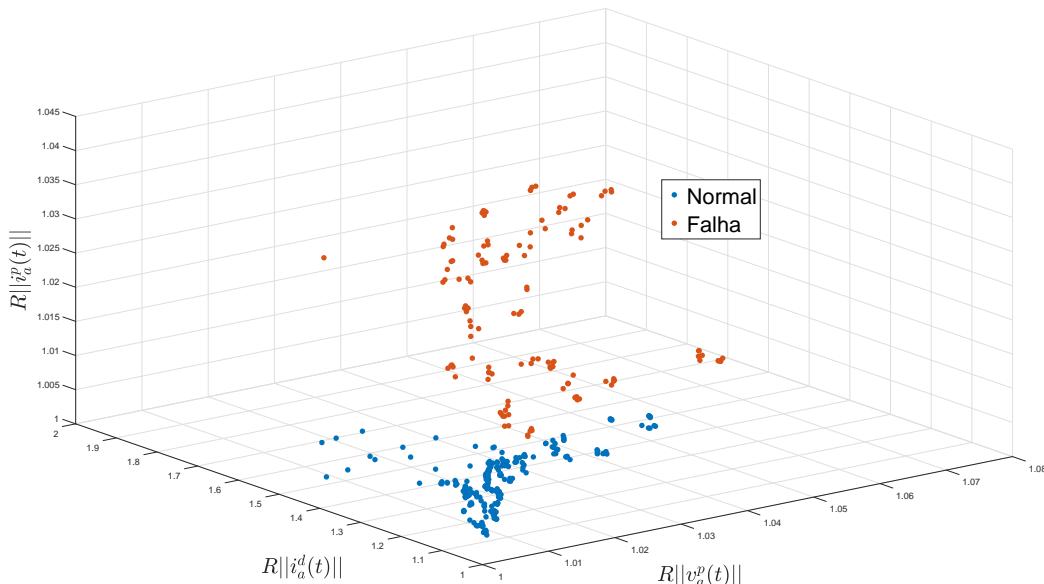
Figura 58: Índices correlacionados com a falha - Índice 1 com monotonicidade - Índice 2 sem monotonicidade



Fonte: elaborado pela autora.

Classificadores multiclasses são capazes de classificar índices não monotônicos e com alta variabilidade, porém, os classificadores de uma só classe terão dificuldades de englobar a classe saudável de maneira a garantir que novidades estejam fora do grupo. Na Figura 57 fica evidente que o índice R possui a característica de monotonicidade e baixa variabilidade, assim como na Figura 59, onde os três melhores atributos estão selecionados quando apenas a fase A é utilizada.

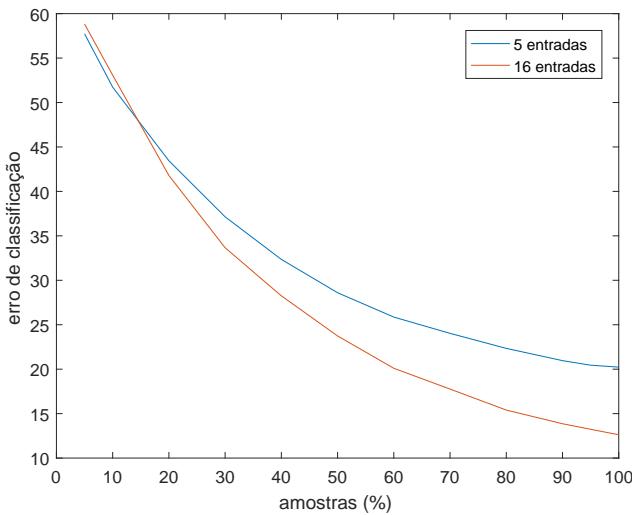
Figura 59: Amostras de motores normais e com falha com relação aos três primeiros atributos escolhidos pelo CFS utilizando-se o índice R e os sinais referentes a fase A.



Fonte: elaborado pela autora.

De forma a investigar se os detectores de novidade poderiam ter melhores performances caso mais amostras de motores estivem disponíveis (utilizando-se os valores RMS medianos das componentes ortogonais), traçou-se as respectivas curvas de aprendizado mostradas na Figura 60.

Figura 60: Curvas de aprendizagem para os detectores de novidade utilizando-se como entrada a mediana dos valores eficazes das componentes ortogonais referentes a fase A.



Fonte: elaborado pela autora.

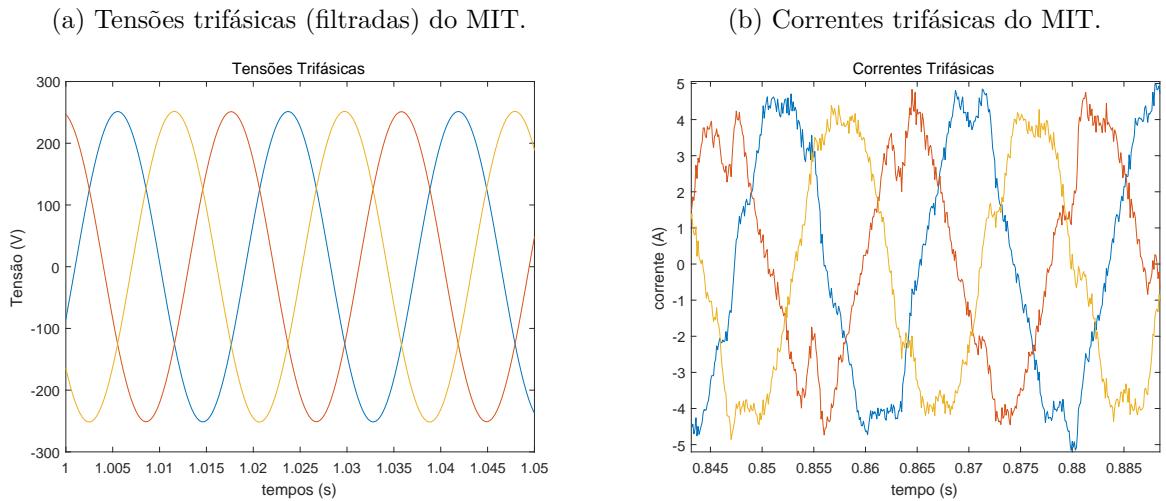
Nota-se que as curvas de aprendizagem dos classificadores SVM^1 e SVM^2 da Tabela 9 estão próximas a atingirem suas assíntotas. Desta forma, uma maior disponibilidade de dados não melhoraria significativamente a performance dos classificadores, confirmando, então, que seus piores rendimentos estão ligados à falta de monotonicidade e maior variabilidade dos índices de entrada calculados com os valores medianos das componentes ortogonais.

7.2.3 Partida por Inversor de Frequência

A Figura 61 ilustra as variáveis monitoradas de um ensaio de motor com rotor normal em regime permanente com carregamento de 4,0 Nm e acionado por inversor de frequência.

Por meio da discussão no Capítulo 6, as tensões foram filtradas com um filtro digital passa-baixas de forma a permitir os corretos cálculos da DCO. Em aplicações práticas, pode-se utilizar um filtro analógico passa-baixas nas tensões antes da conexão do inversor ao motor trifásico. Nesse caso, as amostras teriam aspecto semelhante àquelas em partida direta, já que as tensões no motor estariam filtradas à uma função senoidal com frequência fundamental. Porém, com o intuito de verificar se o diagnóstico é ainda viável utilizando-se os sinais de corrente adquiridos com distorções, aplicou-se apenas o filtro digital nos

Figura 61: Tensões e correntes trifásicas do MIT normal sob carga de 4,0 Nm, acionado por inversor de frequência em 55 Hz.



Fonte: elaborado pela autora.

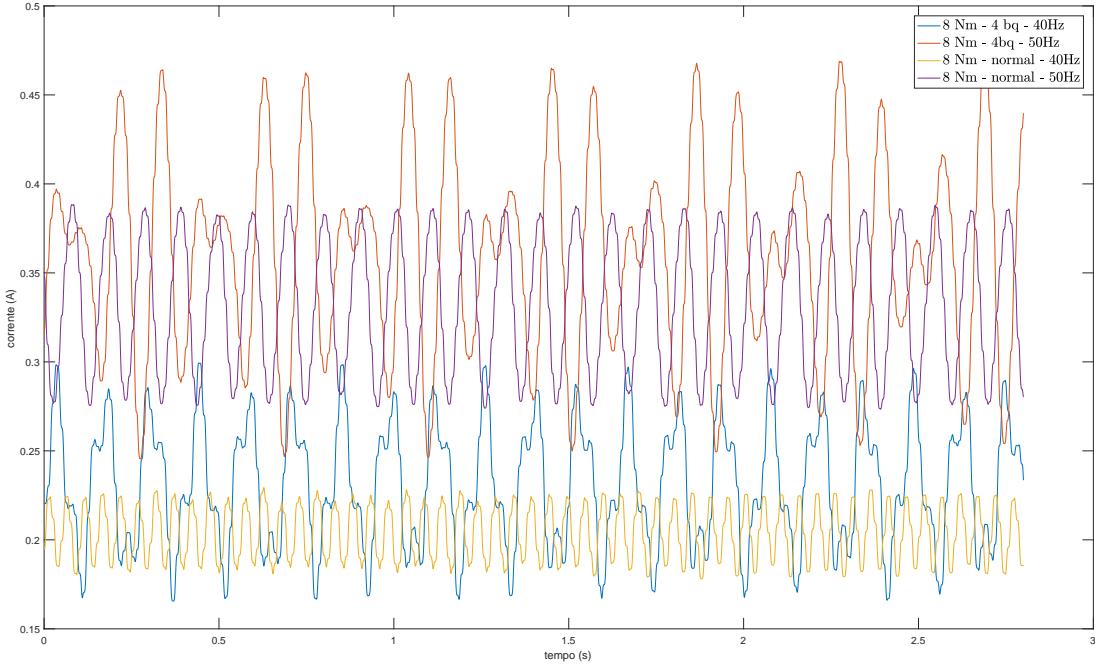
sinais de tensão, o que pode ser facilmente implementado em hardware ou software, desde que a frequência de amostragem respeite a teoria de amostragem de Nyquist.

O inversor de frequência trabalha com o algoritmo Volts-Hertz em malha aberta, ou seja, no qual, a razão entre as tensões de fase e a frequência fundamental de alimentação são mantidas constantes. Desta forma, independente da frequência de alimentação do inversor, a frequência de oscilação dos valores RMS das componentes ortogonais se mantém constante e depende apenas do carregamento, pois, a quantidade $fb = 2sf$ é constante. À vista disso, novamente, escolheu-se o tempo de 2,8 s para a janela de aquisição, o que contempla no mínimo dois ciclos de oscilações dos valores RMS das componentes ortogonais na situação de menor torque em qualquer frequência de acionamento.

O total de amostras do banco de dados em parida por inversor é de 185 casos (combinações ‘motor+carga+frequência’). Assim como no caso dos motores em partida direta, foram obtidas amostras de 5 janelas deslizantes, resultando em 925 amostras, das quais 320 correspondem a motores saudáveis e 625 amostras correspondem a motores com falha.

Na Figura 62 mostra-se os sinais RMS de motores com 4 bq e motores saudáveis para a componente ortogonal $i_a^p(t)$ na frequência de 40 Hz e 50 Hz. Pode-se observar que as distorções na forma de onda da corrente prejudicam o cálculo do fator R , devido à utilização do valor máximo para seu cálculo. Porém, viu-se nos resultados pertinentes ao motores em partida direta que o índice R apresenta boas características para ser utilizado como índice para detecção de novidades. Consequentemente, pode-se dizer que a utilização dos sinais de corrente não filtrados não permite a aplicação correta da técnica. Assim, filtrou-se também o sinal de corrente com o filtro digital passa-baixas. Os resultados dos classificadores multi-classes utilizando-se os sinais filtrados tanto de corrente quanto de tensão estão explicitados na Tabela 10.

Figura 62: Sinais RMS de motores com 4 barras quebradas e motores saudáveis em 40 Hz e 50 Hz, com carregamento nominal, para a componente ortogonal $i_a^p(t)$ sem filtragem dos sinais de corrente.



Fonte: elaborado pela autora.

Nota-se que a acurácia dos classificadores é próxima da acurácia para os casos em partida direta. Essa filtragem, permite, então, que se teste o índice R em detecções de novidade como descritos na Tabela 11. Observa-se que o índice R continua sendo um ótimo índice para o treinamento de classificadores de uma só classe, como pode ser observado na Tabela 11.

Na Figura 63 pode-se observar que os 3 primeiros atributos selecionados pelo CFS quando os sinais da fase A são utilizados, possuem também pequena variabilidade e alta monotonicidade com o fenômeno da falha. Neste caso, nota-se a presença de mais amostras faltosas do que amostras saudáveis.

Pode-se dizer que para a utilização de classificadores de detecção de novidades, deve-se filtrar com um filtro analógico, a tensão de alimentação do inversor de frequência, ou utilizar filtros digitais nas tensões e correntes após a aquisição, respeitando-se a teoria de amostragem de Nyquist de forma a se evitar modulações extras causadas pelo fenômeno de aliasing, que possam prejudicar o cálculo do fator R .

A tabela seguintes mostra o resultado da análise estatística realizada nos motores em partida por inversores de frequência com o índice R .

O resultado da análise da Tabela 12 lança dúvidas sobre a hipótese nula: *todas as*

Tabela 10: Acurácia da classificação entre motores normais e defeituosos e de severidade da falha (1bq, 2bq, 2x2bq, 4bq) para motores em partida por inversor de frequência utilizando-se o índice R e os sinais referentes à fase A.

Classificador	Entradas	Nº de	Acurácia (%)
		Tipos	Média (desv. padrão)
SVM^1	16	Falha	98,76(1,02) %
PMC^1	16	Falha	98,09(1,28) %
SVM^2	5	Falha	98,06 (1,31)%
PMC^2	5	Falha	97,20 (1,91)%
SVM^3	16	Severidade	98,76(1,02) %
PMC^3	16	Severidade	98,09(1,28)%
SVM^4	5	Severidade	98,49(1,49) %
PMC^4	5	Severidade	97,48(2,16)%

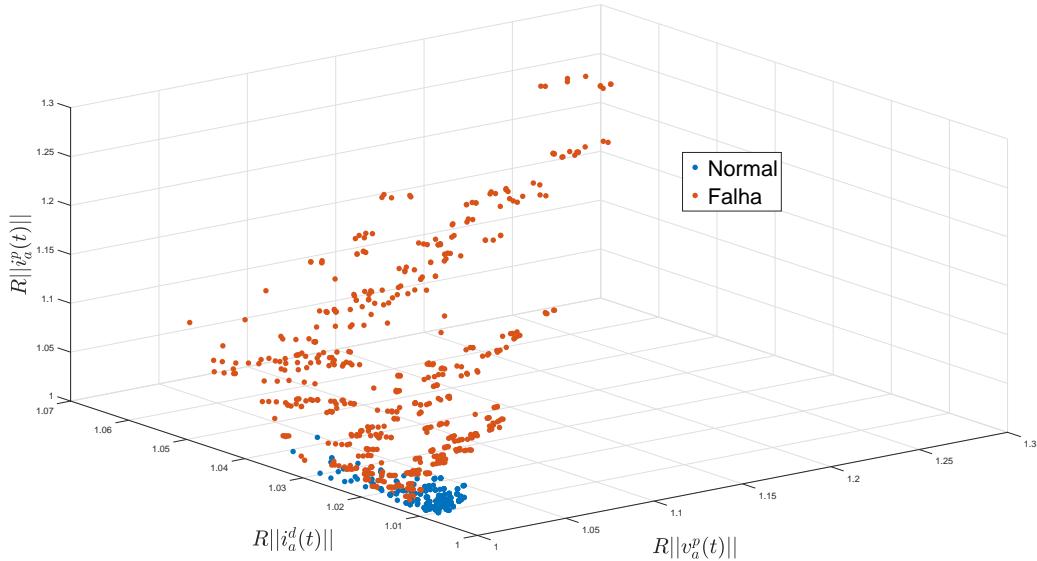
$SVM^1 = SVM^2$ ($C = 100$, $\gamma = 4$, kernel Gaussiano). $SVM^3 = SVM^4$ ($C = 100,0$, $\gamma = 8$, kernel Gaussiano). $PMC^1 = PMC^2$ ($T = 0,3$ M=0,2 CE=0, NCE=5) . PMC^4 ($T = 1$, M=0,1 CE=0, NCE=10).

Tabela 11: Acurácia da classificação de motores normais e defeituosos em partida direta utilizando-se SVMs de uma só classe com o índice R e os sinais referentes à fase A.

Classificador	Entradas	Nº de	Acurácia (%)
		Tipos	Média (desv. padrão)
SVM^1	16	Falha	95,39(2,59)%
SVM^2	5	Falha	95,40(2,42)%

$SVM^1 = SVM^2 = \nu = 0,001$, $\gamma = 0,008$ Kernel Gaussiano).

Figura 63: Amostras de motores normais e com falha com relação aos três primeiros atributos escolhidos pelo CFS utilizando-se o índice R e os sinais referentes a fase A.



Fonte: elaborado pela autora.

Tabela 12: Teste estatístico. ANOVA para o banco de dados com valores eficazes das componentes ortogonais em partida por inversor de frequência com apenas uma fase.

SS	df	Ms (SS/df)	(F)	p
$1,021 \cdot 10^{10}$	1	$1,021 \cdot 10^{10}$	559,39	$1,1407 \cdot 10^{-123}$

amostras são extraídas de uma mesma população. Ou seja, não se pode assumir que o grupo dos motores normais é igual ao grupo dos motores com defeito a partir do índice R das componentes ortogonais em partida por inversores de frequência. Novamente, o teste estatístico corrobora com os resultados atingidos pelos sistemas de inferência.

Diante os resultados obtidos para motores em partida por inversores de frequência, notou-se que o estágio de filtragem pela projeção dos sinais de fase no plano das tensões de linha não realiza uma filtragem ideal, o que leva à uma decomposição com modulações extras, como visto na Figura 62. O segundo princípio da DCO cabe principalmente à sinais que possuam harmônicas múltiplas de uma frequência fundamental, de forma que a decomposição no plano não carregue modulações. Além disso, essa filtragem é ideal para ruídos em modo comum, ou seja, que atingem as três fases simultaneamente.

Em consequência dessas conclusões, novas investigações sobre a filtragem e a estima-

ção de tensões e correntes trifásicas devem ser aprofundadas e estudadas em pesquisas posteriores de forma a permitir uma melhor utilização da técnica da DCO em sinais com modulação e ruídos que não sejam de modo comum. Uma investigação inicial de filtragem no domínio do tempo realizada pelos filtros de Kalman foi realizada durante o período de estágio de pesquisa no exterior na *University of California at San Diego* e culminou na publicação do artigo Liboni, Oliveira e Silva (2017) no periódico *International Journal of Electrical Power and Energy systems*. Essas formas de filtragem combinadas com a ferramenta de DCO devem, então, ser reportadas em futuras pesquisas.

Embora a DCO tenha um estágio de filtragem, as garras de corrente foram posicionadas dentro do painel do inversor de frequência e isto pode ter prejudicado a classificação. Uma posição menos ruidosa para as garras de corrente poderia representar uma melhora do sistema de classificação. De qualquer forma, os sistemas de diagnóstico ainda possuem um nível muito alto de acurácia.

CAPÍTULO 8

Conclusões

8.1 Conclusões

Neste trabalho, investigou-se sobre a identificação e diagnóstico de falhas em MITs com partida direta pela rede e por inversores de frequência, mais especificamente, sobre as quebras das barras dos rotores do tipo gaiola de esquilo. Utilizou-se para isso uma nova técnica de processamento de sinais denominada DCO unida a diferentes sistemas de aprendizagem de máquinas como RNAs e *SVMs*.

Nesse contexto pode-se então pontuar que todos os objetivos específicos da pesquisa foram atingidos, ou seja:

- ❑ Desenvolveu-se estratégias baseadas na técnica de decomposição ortogonal visando sua utilização como ferramenta de processamento de sinais para auxiliar na identificação de falhas em MITs e
- ❑ Utilizou-se sistemas advindos da aprendizagem de máquinas que, a partir das características extraídas no processamento, foram capazes de identificar a ocorrência de falhas e sua severidade.

Esses objetivos específicos culminaram em um estudo e investigação profunda da ferramenta de DCO e é tida como uma das principais contribuições desta tese. Desta forma, pôde-se:

- ❑ Disponibilizar maior investigação sobre a nova ferramenta, permitindo que esta possa ser testada e validada em outras áreas do conhecimento pela comunidade científica e
- ❑ Desdobrar a aplicação de uma nova ferramenta matemática na detecção de falhas em MITs.

A ferramenta de DCO está intimamente ligada aos conceitos de potência elétrica e ao fluxo de energia entre fonte e carga, e como mostrado nesta tese, possui um grande poten-

cial em contribuir com novas definições e teorias de potência em circuitos não puramente senoidais. Sua aplicação é bastante interessante para a compensação de reativos e para a identificação de fenômenos que façam com o que o sistema deixe a situação puramente senoidal. Espera-se que a investigação sobre a DCO fomente novas pesquisas em diversas áreas de aplicação da engenharia elétrica que faça uso dessa nova ferramenta.

A DCO está baseada em dois princípios advindos da álgebra linear. O primeiro é referente à decomposição de sinais elétricos em bases oriundas dos próprios sinais e que consegue heuristicamente representar a troca de potência ativa, reativa e àquela que não pode ser representada por elementos elétricos passivos. O segundo princípio é baseado na decomposição de sinais elétricos de fase nas tensões de linha. Essa decomposição acaba por realizar uma filtragem de ruídos de modo comum existentes nos sinais elétricos de fase.

Os dois princípios utilizados conjuntamente acabam por realizar então uma etapa de filtragem e uma de decomposição dos sinais no domínio do tempo e mediante a cálculos algébricos simples.

Particularmente, as falhas de barras quebradas induzem nas componentes ortogonais modulações que não são existentes em motores saudáveis. Como exposto na literatura, dificuldades associadas a métodos no domínio da frequência ainda são existentes, assim, como dificuldades de detecção em situações de baixos carregamentos. Nota-se que essas modulações são refletidas nos valores RMS das componentes ortogonais e, assim, permite-se a criação de índices relativos à falha calculados no domínio do tempo.

Os dados utilizados neste trabalho foram provenientes da bancada de experimentos, a qual é capaz de fornecer dados de diversos tipos de falhas. Os sinais monitorados de tensão e corrente foram pré-processados com a técnica de DCO. Os componentes resultantes foram então tratados com os operadores de valor eficaz. Finalmente, os dados foram normalizados e investigou-se a identificação de falha sob diferentes carregamentos.

Mostrou-se por meio de simulações computacionais e experimentos, que a aplicação da DCO nos sinais de tensão e corrente de MITs pode resultar em índices altamente correlacionados com as falhas. A classificação das falhas e o diagnóstico é então facilitada para os sistemas utilizados. Mostrou-se que o valor mediano dos sinais RMS das componentes ortogonais em uma janela de aquisição, assim como a relação entre os valores máximos e medianos desse sinais são índices altamente correlacionados com o fenômeno de barras quebradas.

A análise mostra que é possível identificar e diagnosticar os motores faltosos com as duas ferramentas testadas: RNAs e *SVM*. As RNAs apresentam mais parâmetros de ajustes e a possibilidade de otimização da identificação depende da validação cruzada de várias arquiteturas e topologias. Porém, topologias compactas foram testadas e obtiveram-se resultados satisfatórios. Já as *SVM* apresentaram resultados contundentes e mostraram-se uma ferramenta robusta e de fácil utilização. Desta forma, as ferramentas mostram-se

robustas e, quando adequadamente configuradas, conseguiram classificar corretamente os casos normais e defeituosos, assim como a severidade das falhas.

Mais especificamente, mostrou-se que índices monotônicos com a severidade da falha e com baixa variabilidade, como é o caso do índice que relaciona os valores RMS máximos e medianos das componentes ortogonais, são mais interessantes, já que estes permitem a utilização de classificadores de uma só classe e facilitam a implementação de sistemas de diagnósticos.

Dados todos os resultados apresentados no Capítulo 7 para motores com partida direta pela rede, a nova técnica deverá se mostrar muito conveniente para detectar falhas incipientes, pois o conjunto de índices é extremamente sensível ao fenômeno de uma falha. Este assunto poderá então ser investigado em futuras pesquisas.

Já para motores com partida por inversores de frequência, uma filtragem adicional deve ser realizada, ou por meio de filtros analógicos na tensão de alimentação dos motores ou por intermédio de filtros digitais de tensão e corrente, respeitando-se a teoria de amostragem de Nyquist. De frente aos resultados apresentados no Capítulo 7 para motores com partida com inversores de frequência, novos estudos sobre a etapa de filtragem da DCO devem ser realizados. Essa etapa de filtragem se mostra muito interessante para sistemas com presença de harmônicos múltiplos de uma frequência fundamental, porém no caso de sinais modulados como é o caso dos sinais elétricos advindos de MITs com falhas, esta etapa não se mostrou tão vantajosa e outros tipos de filtragem de sinais no domínio do tempo devem ser então futuramente estudados para a sua utilização em conjunto com o primeiro princípio das componentes ortogonais.

No desenvolvimento desta tese, uma profunda investigação acerca de trabalhos referentes a diagnóstico de falhas foi realizado, sobre os principais mecanismos de detecção de quebra de barras e sobre sistemas advindos da aprendizagem de máquinas aplicados aos sistemas de diagnósticos. Embora o trabalho tenha sido focado nas quebras de barra dos rotores, estima-se que a metodologia proposta possa ser aplicada e extrapolada para outros tipos de falhas encontradas nos MITs. Desta forma, certamente, trabalhos futuros poderão ser desenvolvidos com temas de pesquisas advindos de investigações realizadas nesta tese.

Conclui-se que este trabalho trouxe contribuições à área de diagnóstico de MITs, processamento de sinais, sistemas inteligentes, aprendizagem de máquinas e teoria de potências pela metodologia apresentada, que provou-se factível e implementável. Ademais, as diversas investigações deste trabalho abriram inúmeras novas frentes de pesquisas que serão detalhadas na próxima seção.

8.2 Trabalhos Futuros

Durante o desenvolvimento deste trabalho, novas frentes de investigação surgiram e que são listadas a seguir como sugestões para serem realizadas em trabalhos futuros:

- ❑ Aprofundar a investigação sobre a ferramenta de DCO como uma nova teoria de potências.
- ❑ Explorar a ferramenta de DCO para outros problemas da engenharia elétrica como compensação de reativos e filtragem.
- ❑ Análise e criação de índices advindos da aplicação da DCO em MITs objetivando-se a diferenciação entre o fenômeno de barras quebradas e a existência de cargas oscilantes no eixo rotativo do motor.
- ❑ Explorar o método obtido para quebra de barras do rotor e aplicá-lo no diagnóstico de curto-circuito de espiras do estator, rolamentos defeituosos e excentricidades mecânicas.
- ❑ Pesquisar o tempo da identificação de falha, quando utilizados como entrada do sistema de diagnóstico apenas os sinais mais importantes, a fim de se estudar a viabilidade de implementação do sistema de detecção em hardware.
- ❑ Aprofundar a investigação sobre outros tipos de filtragem de ruídos a serem utilizadas em conjunto com o primeiro princípio da DCO.
- ❑ Análise e criação de índices adequados à detecção de falhas incipientes.

8.3 Publicações

Este trabalho de pesquisa resultou em algumas publicações e aceitações de trabalhos em congressos e periódicos:

- ❑ LIBONI L. H. B.; OLIVEIRA, M. C. ; SILVA, I. N. On the estimation of balanced and symmetric three-phase signals. **International Journal of Electrical Power and Energy Systems**, 2017. v. 91, p. 155-165
- ❑ LIBONI, L. H. B. et al. Efficient signal processing technique for information extraction and its applications in power systems. **Electric Power System Research**, 2016, v.141, p. 538-548.
- ❑ LIBONI L. H. B.; OLIVEIRA, M. C. ; SILVA, I. N. Best modeling practices for optimal estimation of balanced and symmetric three-phase signals. **IEEE PES General Meeting**, July 16 - 20, 2017

- LIBONI, L. H. B.; FALUZINO, R. A. ; SILVA, I. N. . Diagnóstico de Barras Quebradas em Motores de Indução Trifásicos Baseado na Técnica de Componentes Ortogonais e Sistemas Inteligentes. **XII Simpósio Brasileiro de Automação Inteligente (SBAI)**, 2015, Natal.

Deve-se submeter ainda os resultados desta tese para periódicos de alto impacto, mostrando-se a obtenção de índices para a utilização de classificadores de uma só classe.

Durante a elaboração desta pesquisa, outras atividades e publicações foram concluídas.

- SILVA, I. N. da; SPATTI, D. H., FLAUZINO, R. A., LIBONI, L. H. B., ALVES, S. F. R. **Artificial Neural Networks: A practical Course**. Springer, 2016. ISBN 9783319431628.
- MILION, R. N., PALIARI, J. C., LIBONI, L. H. B. Improving consumption estimation of electrical materials in residential building construction. **Automation in Construction**, Volume 72, Part 2, 2016.
- SPATTI D. H., LIBONI, L. H. B. Computational Tools for Data Processing in Smart Cities. **Smart Cities Technologies**, Intech, 2016.
- SPATTI D. H., LIBONI, L. H. B. Emerging Technologies for Renewable Energy Systems. **Smart Cities Technologies**, Intech, 2016.
- CAROPRESO R. T., LIBONI, L. H. B., FERNANDES R. A. S., SILVA, I. N. Análise da Resposta de Redes Neurais do Tipo MLP Para Reconhecimento de Locutor Considerando Distintas Ferramentas de Pré-Processamento. **XI Simpósio Brasileiro de Automação Inteligente (SBAI)**, 2013.
- Estágio de pesquisa no exterior - University of California, San Diego.

Referências

- ALMEIDA, M. Barros de. **Treinamento de Svms Utilizando Reamostragem Baseada Em Erro e Estratégias A Priori de Seleção de Amostras**. Tese (Doutorado) — Universidade Federal de Minas Gerais, 2002.
- BACCARINI, L. M. R. **Detecção e Diagnóstico de Falhas em Motores de Indução**. Tese (Doutorado) — Universidade Federal de Minas Gerais, 2005.
- BACCARINI, L. M. R.; MENEZES, B. R. de; CAMINHAS, W. M. Fault induction dynamic model, suitable for computer simulation: Simulation results and experimental validation. **Mechanical Systems and Signal Processing**, 2010. v. 24, n. 1, p. 300 – 311, 2010.
- BACCARINI, L. M. R. et al. Svm practical industrial application for mechanical faults diagnostic. **Expert Systems with Applications**, 2011. v. 38, n. 6, p. 6980 – 6984, 2011.
- BALCI, M. E.; HOCAOGLU, M. H. Quantitative comparison of power decompositions. **Electric Power Systems Research**, 2008. v. 78, n. 3, p. 318 – 329, 2008.
- BATISTA, O. E. et al. Methodology for information extraction from oscillograms and its application for high-impedance faults analysis. **International Journal of Electrical Power & Energy Systems**, 2016. v. 76, p. 23 – 34, 2016.
- BELLINI, A. et al. Quantitative evaluation of induction motor broken bars by means of electrical signature analysis. **Industry Applications, IEEE Transactions on**, 2001. v. 37, n. 5, p. 1248–1255, Sep 2001.
- BENNETT, K. P.; CAMPBELL, C. Support vector machines: hype or hallelujah? **ACM SIGKDD Explorations Newsletter**, 2000. ACM, New York, NY, USA, v. 2, n. 2, p. 1–13, dez. 2000. ISSN 1931-0145.
- BINDU, S.; THOMAS, V. Diagnoses of internal faults of three phase squirrel cage induction motor - a review. In: **International Conference on Advances in Energy Conversion Technologies (ICAECT)**. [S.l.: s.n.], 2014. p. 48–54.
- BOSER, B. E.; GUYON, I. M.; VAPNIK, V. N. A training algorithm for optimal margin classifiers. In: **Proceedings of the fifth annual workshop on Computational learning theory**. New York, NY, USA: ACM, 1992. (COLT '92), p. 144–152. ISBN 0-89791-497-X.

BOSSIO, G. et al. Separating broken rotor bars and load oscillations on IM fault diagnosis through the instantaneous active and reactive currents. **IEEE Transactions on Industrial Electronics**, 2009. v. 56, n. 11, p. 4571–4580, Nov 2009.

BOSSIO, G. R. et al. Separating broken rotor bars and load oscillations on im fault diagnosis through the instantaneous active and reactive currents. **IEEE Transactions on Industrial Electronics**, 2009. v. 56, n. 11, p. 4571–4580, Nov 2009. ISSN 0278-0046.

CHOI, S. et al. Implementation of a Fault-Diagnosis Algorithm for Induction Machines Based on Advanced Digital-Signal-Processing Techniques. **IEEE Transactions on Industrial Electronics**, 2011. v. 58, n. 3, p. 937–948, Mar 2011. ISSN 0278-0046.

COBLE, J.; HINES, J. W. Identifying optimal prognostic parameters from data: a genetic algorithms approach. **Annual Conference of the Prognostics and Health Management Society**, 2009. Sep 2009.

CONCARI, C. et al. Validation of a faulted rotor induction machine model with an insightful geometrical interpretation of physical quantities. **IEEE Transactions on Industrial Electronics**, 2013. v. 60, n. 9, p. 4074–4083, Sep 2013.

COSTA, C. da; KASHIWAGI, M.; MATHIAS, M. H. Rotor failure detection of induction motors by wavelet transform and fourier transform in non-stationary condition. **Case Studies in Mechanical Systems and Signal Processing**, 2015. v. 1, p. 15 – 26, 2015. ISSN 2351-9886.

CUNHA, C. C. M. **Modelagem, análise e detecção de assimetrias de rotor em máquinas de indução**. Tese (Doutorado) — Tese de Doutorado, Universidade Federal de Minas Gerais (UFMG), 2006.

CUNHA, C. M.; LYRA, R.; FILHO, B. Simulation and analysis of induction machines with rotor asymmetries. **IEEE Transactions on Industry Applications**, 2005. v. 41, n. 1, p. 18–24, Jan 2005.

CZARNECKI, L. What is wrong with the budeanu concept of reactive and distortion power and why it should be abandoned. **IEEE Transactions on Instrumentation and Measurement**, 1987. IM-36, n. 3, p. 834–837, Sep 1987.

CZARNECKI, L. S. Considerations on the reactive power in nonsinusoidal situations. **IEEE Transactions on Instrumentation and Measurement**, 1985. IM-34, n. 3, p. 399–404, Sep 1985.

_____. Scattered and reactive current, voltage, and power in circuits with nonsinusoidal waveforms and their compensation. **IEEE Transactions on Instrumentation and Measurement**, 1991. v. 40, n. 3, p. 563–574, Jun 1991.

_____. Power theories and meta-theory of powers in electrical circuits. **Przeglad Elektrotechniczny (Proc. of Electrical Engineering)**, 2011. R87, p. 197–200, Aug 2011.

DRIF, M.; CARDOSO, A. The use of the instantaneous-reactive-power signature analysis for rotor-cage-fault diagnostics in three-phase induction motors. **IEEE Transactions on Industrial Electronics**, 2009. v. 56, n. 11, p. 4606–4614, Nov 2009.

- _____. Discriminating the simultaneous occurrence of three-phase induction motor rotor faults and mechanical load oscillations by the instantaneous active and reactive power media signature analyses. **IEEE Transactions on Industrial Electronics**, 2012. v. 59, n. 3, p. 1630–1639, mar. 2012.
- DRIF, M.; CARDOSO, A. J. M. Stator fault diagnostics in squirrel cage three-phase induction motor drives using the instantaneous active and reactive power signature analyses. **IEEE Transactions on Industrial Informatics**, 2014. v. 10, n. 2, p. 1348–1360, May 2014. ISSN 1551-3203.
- EBRAHIMI, B. M.; FAIZ, J.; AKIN, B. Pattern recognition for broken bars fault diagnosis in induction motors under various supply conditions. **European Transactions on Electrical Power**, 2012. v. 22, n. 8, p. 1176–1190, 2012. ISSN 1546-3109.
- FITZGERALD, A. E.; KINGSLEY, C.; UMANS, D. **Electric Machinery**. 6th. ed. [S.l.]: Bookman, 2006.
- FLAUZINO, R. **Identificação e Localização de Faltas de Alta Impedância em Sistemas de Distribuição Baseadas em Decomposição por Componentes Ortogonais e Inferência Fuzzy**. Tese (Doutorado) — Tese de Doutorado, Universidade de São (USP), 2007.
- GARCÍA-ESCUDERO, L. A. et al. Robust condition monitoring for early detection of broken rotor bars in induction motors. **Expert Systems with Applications**, 2011. v. 38, n. 3, p. 2653 – 2660, 2011.
- GARCIA-PEREZ, A. et al. The application of high-resolution spectral analysis for identifying multiple combined faults in induction motors. **IEEE Transactions on Industrial Electronics**, 2011. v. 58, n. 5, p. 2002–2010, May 2011.
- GHANBARI, T. Autocorrelation function-based technique for stator turn-fault detection of induction motor. **IET Science, Measurement Technology**, 2016. v. 10, n. 2, p. 100–110, 2016. ISSN 1751-8822.
- GHORBANIAN, V.; FAIZ, J. A survey on time and frequency characteristics of induction motors with broken rotor bars in line-start and inverter-fed modes. **Mechanical Systems and Signal Processing**, 2015. p. 427 – 456, 2015. ISSN 0888-3270.
- GODOY, W. F. et al. Application of intelligent tools to detect and classify broken rotor bars in three-phase induction motors fed by an inverter. **IET Electric Power Applications**, 2016. v. 10, n. 5, p. 430–439, 2016. ISSN 1751-8660.
- GU, F. et al. A new method of accurate broken rotor bar diagnosis based on modulation signal bispectrum analysis of motor current signals. **Mechanical Systems and Signal Processing**, 2015. v. 50?51, p. 400 – 413, 2015. ISSN 0888-3270.
- GUYON, I. **SVM Application List**. 1999. Disponível em: <<http://www.clopinet.com/SVM.applications.html>>.
- HALL, M. et al. The weka data mining software: an update. **ACM SIGKDD Explorations Newsletter**, 2009. ACM, v. 11, n. 1, p. 10–18, 2009.

HALL, M. A.; SMITH, L. A. Feature selection for machine learning: Comparing a correlation-based filter approach to the wrapper. In: **FLAIRS conference**. [S.l.: s.n.], 1999. v. 1999, p. 235–239.

HAYKIN, S. **Neural Networks - A Comprehensive Foundation**. Upper Saddle River, NJ: Prentice Hall, 1999.

_____. **Neural Networks and Learning Machines**. 3rd. ed. [S.l.]: Prentice Hall, 2008.

JOKSIMOVIC, G. et al. Stator-current spectrum signature of healthy cage rotor induction machines. **IEEE Transactions on Industrial Electronics**, 2013. v. 60, n. 9, p. 4025–4033, set. 2013.

LIBONI, L. H. et al. Efficient signal processing technique for information extraction and its applications in power systems. **Electric Power Systems Research**, 2016. v. 141, p. 538 – 548, 2016. ISSN 0378-7796.

LIBONI, L. H. B.; OLIVEIRA, M. C. de; SILVA, I. N. da. On the problem of optimal estimation of balanced and symmetric three-phase signals. **International Journal of Electrical Power & Energy Systems**, 2017. v. 91, p. 155 – 165, 2017. ISSN 0142-0615.

LORENA, A.; CARVALHO, A. de. Uma introdução às support vector machines. **Revista de Informática Teórica e Aplicada**, 2007. 2007.

MATIC, D. et al. Support vector machine classifier for diagnosis in electrical machines: Application to broken bar. **Expert Systems with Applications**, 2012. v. 39, n. 10, p. 8681 – 8689, 2012.

MCCOY, G. A.; DOUGLASS, J. G. Premium efficiency motor selection and application guide—a handbook for industry. **Washington State University Energy Program for the US Department of Energy's Office of Energy Efficiency and Renewable Energy**, 2014. 2014.

MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. **The Bulletin of Mathematical Biophysics**, 1943. Springer, v. 5, n. 4, p. 115–133, 1943.

MEHRJOU, M. R. et al. Rotor fault condition monitoring techniques for squirrel-cage induction machine - a review. **Mechanical Systems and Signal Processing**, 2011. v. 25, n. 8, p. 2827–2848, 2011.

MILION, R. N. **Método para prognóstico do consumo de materiais em instalações prediais elétricas utilizando sistemas inteligentes**. Tese (Doutorado) — Universidade Federal de São Carlos, 2014.

NANDI, S.; TOLIYAT, H. A.; LI, X. Condition monitoring and fault diagnosis of electrical motors-a review. **IEEE Transactions on Energy Conversion**, 2005. v. 20, n. 4, p. 719–729, 2005.

OSTOJIC, P. et al. Advanced motor monitoring and diagnostics. In: **Industry Applications Society 60th Annual Petroleum and Chemical Industry Conference**. [S.l.: s.n.], 2013. p. 1–9. ISSN 0090-3507.

- PAWLAK, M.; KOWALSKI, C. Low-cost embedded system for the im fault detection using neural networks. In: **XIX International Conference on Electrical Machines (ICEM)**. [S.l.: s.n.], 2010. p. 1–5.
- RANGEL-MAGDALENO, J. de J. et al. FPGA-based broken bars detection on induction motors under different load using motor current signature analysis and mathematical morphology. **IEEE Transactions on Instrumentation and Measurement**, 2014. v. 63, n. 5, p. 1032–1040, May 2014.
- RAZIK, H.; CORREA, M. de R.; SILVA, E. da. A novel monitoring of load level and broken bar fault severity applied to squirrel-cage induction motors using a genetic algorithm. **IEEE Transactions on Industrial Electronics**, 2009. v. 56, n. 11, p. 4615–4626, Nov 2009.
- RICH, E.; KNIGHT, K. **Artificial Intelligence**. [S.l.]: McGraw-Hill, 1991. (Artificial Intelligence Series).
- ROMERO-TRONCOSO, R. et al. FPGA-based online detection of multiple combined faults in induction motors through information entropy and fuzzy inference. **IEEE Transactions on Industrial Electronics**, 2011. v. 58, n. 11, p. 5263–5270, Nov 2011.
- SADEGHIAN, A.; YE, Z.; WU, B. Online detection of broken rotor bars in induction motors by wavelet packet decomposition and artificial neural networks. **IEEE Transactions on Instrumentation and Measurement**, 2009. v. 58, n. 7, p. 2253–2263, Jul 2009.
- SANTOS, F. M. d. C. **Identificação de Falhas em Motores de Indução Trifásicos Usando Sistemas Inteligentes**. Tese (Doutorado) — Universidade de São Paulo, 2013.
- SANTOS, F. M. d. C.; SILVA, I. N. da; SUETAKE, M. Sobre a Aplicação de Sistemas Inteligentes para Diagnóstico de Falhas em Máquinas de Indução - Uma Visão Geral. **Revista Controle & Automação/Setembro e Outubro**, 2012. v. 23, n. 5, p. Vol.23 no.5, 2012.
- SCHÖLKOPF, B. et al. Estimating the support of a high-dimensional distribution. **Neural computation**, 2001. MIT Press, v. 13, n. 7, p. 1443–1471, 2001.
- SCIKIT Learn Documentation. Disponível em: <http://scikit-learn.org/stable/auto_examples/svm/plot_rbf_parameters.html>.
- SEERA, M. et al. Condition monitoring of induction motors: A review and an application of an ensemble of hybrid intelligent models. **Expert Systems with Applications**, 2014. v. 41, n. 10, p. 4891–4903, 2014.
- SILVA, A. da; POVINELLI, R.; DEMERDASH, N. Rotor bar fault monitoring method based on analysis of air-gap torques of induction motors. **IEEE Transactions on Industrial Informatics**, 2013. v. 9, n. 4, p. 2274–2283, 2013.
- SILVA, A. da; POVINELLI, R.; DEMERDASH, N. A. O. Induction machine broken bar and stator short-circuit fault diagnostics based on three-phase stator current envelopes. **IEEE Transactions on Industrial Electronics**, 2008. v. 55, n. 3, p. 1310–1318, March 2008.

- SILVA, I. da et al. **Artificial Neural Networks: A Practical Course.** [S.l.]: Springer International Publishing, 2016. ISBN 9783319431628.
- SILVA, I. N. da; SPATTI, D. H.; FLAUZINO, R. A. **Redes Neurais Artificiais para Engenharia e Ciências Aplicadas.** São Paulo, SP: Artliber, 2010.
- SIZOV, G. et al. Analysis and diagnostics of adjacent and nonadjacent broken-rotor-bar faults in squirrel-cage induction machines. **IEEE Transactions on Industrial Electronics**, 2009. v. 56, n. 11, p. 4627–4641, Nov 2009.
- SMART, E.; BROWN, D.; AXEL-BERG, L. Comparing one and two class classification methods for multiple fault detection on an induction motor. In: **IEEE Symposium on Industrial Electronics Applications.** [S.l.: s.n.], 2013. p. 132–137.
- SOUALHI, A.; CLERC, G.; RAZIK, H. Detection and diagnosis of faults in induction motor using an improved artificial ant clustering technique. **IEEE Transactions on Industrial Electronics**, 2013. v. 60, n. 9, p. 4053–4062, Sep 2013.
- SUETAKE, M. **Sistemas Inteligentes para Monitoramento e Diagnósticos de Falhas em Motores de Indução Trifásicos.** Tese (Doutorado) — Universidade de São Paulo, 2012.
- TOLIYAT, H. et al. **Electric Machines: Modeling, Condition Monitoring, and Fault Diagnosis.** [S.l.]: Taylor & Francis, 2012. ISBN 9780849370274.
- WAIDE, P.; BRUNNER, C. U. Energy-efficiency policy opportunities for electric motor-driven systems. 2011. OECD Publishing, 2011.
- WITTEN, I.; FRANK, E. **Data Mining: Practical Machine Learning Tools and Techniques, Second Edition.** [S.l.]: Elsevier Science, 2005. (The Morgan Kaufmann Series in Data Management Systems). ISBN 9780080477022.
- YANG, T. et al. Feature knowledge based fault detection of induction motors through the analysis of stator current data. **IEEE Transactions on Instrumentation and Measurement**, 2016. v. 65, n. 3, p. 549–558, March 2016. ISSN 0018-9456.
- YE, Z.; WU, B.; SADEGHIAN, A. Current signature analysis of induction motor mechanical faults by wavelet packet decomposition. **IEEE Transactions on Industrial Electronics**, 2003. v. 50, n. 6, p. 1217–1228, 2003.